

# PanNuke 上的稀有细胞核是一个检测问题： 诊断、两个失败的数据侧修复，与反事实压力测试

## 中期报告（课程项目 bdd26）

金鑫豪 (Xinhao Jin)

2026 年 9 月 28 日

### 摘要

在 PanNuke 上，更换 backbone 只能带来 1-2 个 mPQ 点的收益，而 **Dead**（凋亡）类的 PQ 在所有已发表模型中停滞在 0.13-0.18。本中期报告回答两个问题：为什么，以及病理视觉-语言模型与可控生成模型这两类“新范式”能否撬动稀有类缺陷或鲁棒性评测。我们首先在官方 3-fold 协议下复现两个基线（HoVer-Net 0.456 mPQ、CellViT-UNI 0.500），并加入第三个评估器 HoVer-NeXt-T (0.458)——其初始移植得分 0.358 被证明是解码伪影而非模型差距。其次，我们证明 Dead 缺陷集中于**检测**而非分类：38.5% 的 Dead 真值核没有任何重叠预测；在这些漏检核内部，前景头沉默（平均核概率 0.16），而类型头却给出  $P(\text{Dead}) \approx 0.26$ 。第三，在预注册的多种子协议下，四类干预全部无效或有害：病理 VLM（CONCH）后处理重分类、免训练漏检找回、类别/尺寸加权的前景损失，以及数据侧的失败驱动 copy-paste（Dead PQ -0.031）与标签自洽的上下文内扩散合成（mPQ 持平）。第四，我们构建了  $3 \times 3$  数据集的零样本跨域基准（CoNIC、MoNuSAC、PUMA）与 *PanNuke-CF*——固定 PanNuke 标签、对组织上下文与染色做干预后重渲染的反事实测试集。反事实压力测试**反转**了真实跨域排序（6 个评估点 Spearman -0.89；架构均值 -1.00）：轴分解显示架构间的真实迁移差异几乎全部位于检测轴，而标签固定的渲染在构造上无法对检测施压；在它施压的分型轴上，反事实排序与真实迁移一致。结论：反事实渲染是有效的分型压力测试而非迁移代理；Dead 检测缺陷是架构性的——它对我们测试的所有损失级与数据级干预都免疫，并跟随模型跨域（三架构在 PUMA 上 Dead PQ  $\leq 0.006$ ）。

## 1 引言

细胞核实例分割与分类是计算病理学的标准任务，PanNuke [1] 是其标准基准：19 种组织、205,000 个标注核，以组织平均全景质量（mPQ）评测。其排行榜有一个醒目的形状：五年的架构进步压缩在约 1-2 个 mPQ 点内（HoVer-Net [2] 0.463  $\rightarrow$  CellViT-SAM-H [3] 0.498  $\rightarrow$  当前最佳约 0.51），而 **Dead**（凋亡小体）类始终停在 PQ 0.13-0.18，粘连核的 merge/split 错误也持续存在。两类新范式承诺比 backbone 工程更大的收益：病理视觉-语言模型 [8] 作为类型分类的先验，与可控生成模型 [10] 作为“组织模拟器”（定向合成训练数据，或在干预下重渲染评测图像）。

本项目按三个预注册支柱组织，附明确的通过/失败规则——其逻辑是：负结果只有在验收标准事先固定时才有价值。**A**：语言锚定的类型头（用 CONCH 文本空间攻击稀有类分类）；**B**：失败驱动的合成（用生成数据攻击 Dead/小核检测）；**C**：评测（用真实跨域迁移加反事实测试集攻击鲁棒性度量）。三个支柱现已全部关闭；本报告记录其发现。贡献如下：

1. **单一严格协议下的复现** (§3)：HoVer-Net、CellViT-UNI、HoVer-NeXt-T 以完全相同的方式在官方 3-fold 划分上训练与评测：last checkpoint、仅在验证折上调解码。顺带量化了一个已发布评测配方（16 个随机颜色 TTA 视图 + 在测试折上调阈值）能抬高多少分数 (§3.1)。

2. **Dead 缺陷的分解** (§4.5): 它是一个集中在小核与孤立核上的检测失败——前景头看不见, 类型头却部分“看见”——这正是一切类型侧干预失败的原因。
3. **预注册的负结果** (§4、§5): CONCH 重分类、免训练找回、损失重加权 (3 种子)、失败驱动 copy-paste、上下文内扩散合成全部无效或有害; 并给出了种子噪声标定, 说明多大的效应量才可信。
4. **3×3 架构 × 数据集零样本跨域基准** (§6.1), 其中 PUMA 是我们所能找到的唯一较大规模的外部凋亡 Dead 标签来源; CoNIC 与 MoNuSAC 的转换与核验管线一并给出。
5. **PanNuke-CF**: 标签固定的反事实渲染基准 (§6.2), 其有效性分析得到机理式判定: 外观反事实无法探测检测 (构造性限制), 因此在 mPQ 层面反转真实迁移排序, 但作为分型压力测试仍然有效。

所有结果来自同一代码库与同一评测器; 该评测器已对官方 PanNuke-metrics 做到逐位一致 (官方发布的 `class_stats.csv` 存在列交换 bug, 已在仓库中记录)。

## 2 相关工作

**PanNuke 模型。** HoVer-Net [2] 提出的水平-垂直 watershed 解码至今仍被多数后续工作 (以变体形式) 沿用。CPP-Net [6]、HoVer-NeXt [5]、CellViT [3] 及其后续 (LKCell、CellVTA、CellViT++ [4])、PromptNucSeg [7] 填满了 0.46–0.51 的 mPQ 区间。其中只有部分工作发布了按折权重; 若官方权重在全量数据上训练 (如 HoVer-Net 官方权重), 则只能作管线 sanity check, 绝不能作为测试结果——本报告全程执行这一区分。

**病理基础模型与 VLM。** 冻结病理基础模型在稠密任务上并不自动胜过 ImageNet CNN [9]; 病理 VLM CONCH [8] 在稠密预测上与纯视觉模型持平, 但额外提供对齐的文本空间。纯提示接口在细胞核上失败严重 (SAM3 式提示在 PanNuke 类任务上 mIoU < 10%); 最接近的已有工作 (PromptNu、MONCH) 要么没有官方 PanNuke 配置, 要么只做语义分割。我们未找到“病理 VLM 文本空间 + 实例分割 + 官方 PanNuke mPQ”的先前工作。

**生成式增强与压力测试。** 已有报道合成数据对稀有类有帮助 (DiffMix、HistoSmith、NucleiMix [11]), 但据我们所知没有工作在官方 3-fold PanNuke 协议下以 mPQ 报告; 已有研究使用非标准划分与 Dice/AJI/F1。影像模型的反事实压力测试已在放射学中演示 [12]; 我们不知道实例分割的对应工作。PixCell [10] (连同其 Cell-ControlNet) 是当前最强的开源可控细胞核生成器, 是我们合成实验与反事实渲染器的共同底座。

## 3 实验设置

**数据与协议。** PanNuke 第 1–3 折, 官方划分 (train/val/test = 1/2/3、2/1/3、3/2/1); 所有数字为 *last-checkpoint* 模型的 3-split 均值, 不做基于测试集的早停。外部数据集 (§6.1) 为零样本: 每个数据集固定到 PanNuke 5 类的类别映射, 缺失类按官方协议从 mPQ 中排除。

**指标。** 官方组织平均 mPQ/bPQ (对 PanNuke-metrics 的逐位一致复现)、strict mPQ (对图中不存在类的 FP 计罚而非忽略)、AJI/AJI<sup>+</sup>、检测  $F_d$  与分类  $F_c$  (12 px 质心匹配)、以及 IoU 0.5 的错误分解 (matched / merged / missed-no-overlap / missed-poor-shape / split, 按类拆分)。TTA (8 个二面体变换, HV 通道重映射) 单独报告。

表 1: 官方 3-fold 协议下的基线 (3-split 均值; last checkpoint; 无 TTA, TTA 在括号内)。“已发表” = 论文自报数字 (其各自配方)。

| 模型                | mPQ           | bPQ           | Dead PQ     |
|-------------------|---------------|---------------|-------------|
| HoVer-Net (本文)    | .4564 [.4666] | .6613 [.6714] | .127 [.128] |
| 已发表               | .463          | .660          | .139        |
| CellViT-UNI (本文)  | .4995 [.5047] | .6654 [.6706] | .176 [.177] |
| 已发表 (CellViT++)   | .492          | .664          | .154        |
| HoVer-NeXt-T (本文) | .4579         | .6367         | .136        |
| 已发表               | .477          | .656          | .154        |

**噪声标定 (用于每个判定)。** 同一 CellViT-UNI 配方的 3 个种子: 种子 std 在 mPQ 上为 0.0021, 但在 Dead PQ 上为 **0.0074**; Dead 的图像 bootstrap CI 半宽为 0.02–0.03。我们由此执行: 单种子 Dead 变化低于约 0.01–0.015 视为噪声; 每个干预的判定必须是 3 种子 (或多折) 结论, 附配对、组织分层图像 bootstrap 95% CI; 决策只在验证折上做。

### 3.1 基线

表 1: 两个经典基线均复现 (HoVer-Net 略低于原文, 与常见复现一致; CellViT-UNI 略高于原文)。HoVer-NeXt-T 需要移植, 初始只得 0.358 mPQ; 消融表明预测图本身没有问题, 损失全部在解码。其发布的 0.477 配方平均 16 个随机空间 + 颜色 TTA 视图, 并在测试折上调每类阈值。我们改用它自身的验证解码 (平坦 fg/seed 阈值), 只在每个 split 的验证折上调参——与其它基线同一协议——得到 0.4579。二者之差 (0.458 vs 0.477) 度量了测试侧调参与随机颜色 TTA 的价值; 值得注意, 这个量级 (0.02 mPQ) 大于排行榜上多数名次差距。HoVer-NeXt-T 作为第三评估器的价值在于不同的错误画像: 三者中 merge 率最低 (0.096–0.101, HoVer-Net 约 0.14), missed-background 更高。

## 4 支柱 A: Dead 缺陷是检测缺陷

### 4.1 CONCH 语义存在于上下文尺度 (可行性)

对真值核的零样本 CONCH 分类: 紧裁剪接近随机 (32px: 0.27), 全上下文 patch 加半径受限注意力池化达到平衡准确率 0.695 (R = 32px, 每 patch 一次前向); LLM 形态学描述比裸类名高 8–11 个点。Dead 是最可被文本识别的类 (召回 0.88), 却也是分割模型最差的类——但在自然分布下其零样本精度仅约 0.10, 只能作为互补信号。线性头的文本锚定初始化只在少样本制度 (每类  $\leq 25$  核) 有帮助; 全量 PanNuke 标注下无关紧要。这把支柱 A 从分类重定向到检测。

### 4.2 管线内重分类: 无效

把 CONCH (零样本或线性探针) 融合进 CellViT-UNI 的类型决策, 所有旋钮在验证折上调 (表 2): 没有任何配置超过管线自身的 seg-vote 类型; 重校准对照与最佳融合持平。TTA 下, 验证调参为两种融合都选择了  $\alpha = 0$ 。

### 4.3 免训练找回: 无效

在原始 NP/HV/TP 图上扫描 96 个配置 (前景混合、Dead 先验增强、blob 阈值、孤立体找回; 3 splits, 验证集选择): 每个族与仅调阈值的对照差距在  $\pm 0.0004$  test mPQ 之内。漏检的 Dead 核无法从该模型的输出中找回。

表 2: CellViT-UNI 上的后处理重分类, split 1 (测试折 3)。

| 方法                          | val mPQ | test mPQ | test Dead PQ |
|-----------------------------|---------|----------|--------------|
| seg vote (管线)               | .4835   | .4951    | .142         |
| + 类别偏置重校准                   | .4873   | .4953    | .135         |
| × CONCH 零样本 ( $\alpha=.1$ ) | .4835   | .4938    | .141         |
| × CONCH 线性 ( $\alpha=.3$ )  | .4836   | .4920    | .141         |
| CONCH 线性单独                  | .3645   | .3821    | .145         |

表 3: CellViT-UNI 在折 3 上的错误分解 (IoU 0.5; 真值核占比)。

| 真值类          | matched     | merged | missed      | miss(形状) | split | 匹配后类型正确 |
|--------------|-------------|--------|-------------|----------|-------|---------|
| Neoplastic   | .811        | .048   | .092        | .040     | .009  | .905    |
| Inflammatory | .849        | .046   | .079        | .023     | .004  | .817    |
| Connective   | .752        | .038   | .153        | .044     | .013  | .794    |
| Dead         | <b>.470</b> | .089   | <b>.385</b> | .048     | .008  | .690    |
| Epithelial   | .837        | .042   | .075        | .036     | .011  | .930    |

#### 4.4 损失侧消融：无效或是交换

split 1 上的像素加权前景 CE, 配 3 种子基线: Dead 像素权  $\times 11$  (M1) 无效; 完全均衡采样器 (C1) 无效; 小核权  $\times 6$  (M2) 在一个种子里看似有希望 (+0.0042 test mPQ, CI 不含 0), 但 3 种子上 mPQ  $-0.0010$   $[-0.0043, +0.0022]$ , 且 bPQ 显著下降  $-0.0024$   $[-0.0048, -0.0002]$ , Dead 增益  $+0.0108$   $[-0.0021, +0.0238]$  不显著——这是一次交换而非贡献, 也干净地演示了该基准上单种子 mPQ 效应低于约 0.004 就是种子运气。

#### 4.5 诊断：Dead 性能在哪里丢失

表 3: 38.5% 的 Dead 核没有任何重叠预测 (其它类 8–15%), 而 Dead 匹配后类型正确率为 0.69——损失以检测为先。在漏检的 Dead 核内部, 前景头沉默 (平均 NP 概率 0.164; 17% 中有响应), 类型分支却给出  $P(\text{Dead}) \approx 0.26$  (其它类漏检核约 0.01): 网络“看见”了前景头丢弃的死亡物质。尺寸贡献很大 (Dead 中位面积 107 px, 其它类 368; 24% 的 Dead  $< 60$  px, 其它类 6%), 但外观效应在尺寸分层后依然存在: 大 Dead ( $> 200$  px) 的漏检率是其它大类核的 6 倍 (0.214 vs 0.035)。定性上 (图 1), 漏检 Dead 是核碎裂碎片、乏染色质的嗜酸性小体与模糊标注。结论: 要么改检测, 要么改数据——由此定义支柱 B。

## 5 支柱 B: 失败驱动的合成同样无法修复检测

### 5.1 失败布局长什么样

折外失败挖掘 (split-2 模型预测折 1; 折 3 测试上模式相同): 漏检 Dead 是孤立的——零接触邻居的 Dead 漏检率 0.39–0.42 (占全部 Dead 的约 90%), 漏检 Dead 与其它核接触的比例  $< 5\%$ 。merge 是同类簇现象 (73–82% 的 merged Dead 与另一 Dead 接触: 核碎裂碎片群)。直觉假设的跨类接触在数据中罕见且不是失败模式。因此原计划的“Dead 紧贴 Neoplastic”干预被替换为: (1) 向空基质插入孤立小核; (2) 密集同类簇。




图 1: Dead 真值核 (绿色) 与预测 (黄色), CellViT-UNI 折 3: 漏检 Dead 是没有前景响应的微小暗色碎片与乏染色质凋亡小体。

## 5.2 CP1: 失败驱动 copy-paste 是有害的

供体核 (50–400px, Dead 权重 0.4) 以 8px 间距粘入无核基质, 且在几何/光度增强之前粘贴 (粘贴核与宿主 patch 同步增强; v1 的可学习捷径由视觉审查发现并修复, 同时修复的还有边界碎片与未标注核碰撞)。相对 3 种子基线结果 (split 1, 测试折 3):  $\Delta mPQ +0.0009 [-0.0024, +0.0043]$ , 但  $\Delta Dead -0.0310 [-0.0576, -0.0100]$  (TTA 一致)。损伤在分型而非检测: 匹配 Dead 的类型正确率  $.690 \rightarrow .609$ , 混淆双向增加。值得注意的是验证折在 Dead 上指向相反方向 (+0.0235): Dead PQ 在折间摆动约 0.05, 这是噪声规则的第三次独立确认。解释: 把真实外观移植进新上下文, 教会模型 “干净基质中的孤立小核” 是一个 Dead-ish 线索, 从而模糊了类型边界。

## 5.3 上下文内合成 (PixCell): 从外观差距到结构性标签阻断

PixCell-256 + Cell-ControlNet, 以折 1 真实掩码为条件: 放置是忠实的 (约 95% 的掩码对象在正确位置/尺寸渲染, 中位 IoU 0.68), 但 20 $\times$  生成器在 40 $\times$  PanNuke 上有结构性外观差距 (平色块染色质、高频 -24%、大掩码欠渲染且尺寸偏置)。LoRA 适配 (两轮, r16 与 r8 加快照选择) 使每个图像空间指标都更差, 路线放弃; 改用对配对真实 patch 的 Reinhard LAB 迁移关闭颜色差距 (OD-L1 0.072 $\rightarrow$ 0.009)。锁定配方 (基座 + 配对上下文 + Reinhard) 下, 32 图冒烟的视觉审查通过 (颜色与配对真实相差约 3/255), 但审查暴露了一个结构性阻断: ControlNet 条件是二值掩码, 上下文 embedding 不含类别信息——生成器无法表达类别定向的外观——729 个保留对象中 0 个被教师判为 Dead ( $P(Dead) \leq 0.005$ )。强行使用供体类别标签会精确复现 CP1 的失败 (标签与外观矛盾)。SYN1 因此采用类别无关、教师自治的标签——它只能经由检测起作用: 1146 张合成图以

表 4: 零样本跨域 (3-split 均值, 无 TTA)。域内 mPQ: CellViT 0.4995、HoVer-Net 0.4564、HoVer-NeXt-T 0.4579。

| 模型           | 数据集     | mPQ               | bPQ   | $F_d$ |
|--------------|---------|-------------------|-------|-------|
| CellViT-UNI  | CoNIC   | .3351 $\pm$ .0037 | .5314 | .7816 |
|              | MoNuSAC | .2495 $\pm$ .0218 | .5616 | .7652 |
|              | PUMA    | .4518 $\pm$ .0031 | .7177 | .8831 |
| HoVer-Net    | CoNIC   | .2610 $\pm$ .0061 | .5136 | .7669 |
|              | MoNuSAC | .0370 $\pm$ .0003 | .2756 | .3658 |
|              | PUMA    | .3203 $\pm$ .0139 | .7136 | .8714 |
| HoVer-NeXt-T | CoNIC   | .2786             | .4811 | .725  |
|              | MoNuSAC | .1123             | .4025 | .628  |
|              | PUMA    | .3813             | .6888 | .848  |

50% 混合, 其余与基线配方完全一致。结果 (测试折 3): mPQ 0.4900 vs 基线 0.4951 (3 种子区间 0.4910–0.4951 的底部), Dead 0.1521 vs 0.1424 (约 +1 点, 处于种子噪声边缘;  $PQ^+/DQ^+/SQ^+$  全平: 这点 Dead 收益来自更好的类型配对而非更好的分割), Inflammatory  $-1.0$ – $1.6$  点。按预注册规则判定: 无效。

## 5.4 支柱 B 判定

在不重训生成器条件的条件下, Dead/小核检测缺陷无法被可用的数据侧杠杆修复: 真实外观移植 (CP1) 主动伤害 Dead 分型, 标签自洽的上下文内合成 (SYN1) 无效。连同支柱 A 的无效结果 (重分类、找回、损失重加权), 该缺陷看起来是架构性的。

# 6 支柱 C: 跨域与反事实评测

## 6.1 真实跨域零样本: $3 \times 3$

外部数据集 (已转换并通过拼接图审查): **CoNIC** (19,476 tiles; 剔除 112 张源自 PanNuke 的 patch;  $20 \times \rightarrow 2 \times$  上采样; 类 Inflamm/Epith/Conn)、**MoNuSAC** test (443 tiles; Inflamm/Epith)、**PUMA** 黑色素瘤 (3,278 tiles; PanNuke 5 类齐全, 含 1,991 个凋亡  $\rightarrow$  Dead 核——我们找到的唯一较大外部 Dead 来源; GT 由 HoVer-Net 初始化、病理学家校正, 绝对召回有上限, 但对所有模型公平共享)。

表 4: 所有模型都退化, 但方式不同。HoVer-Net 在 MoNuSAC 上几乎崩溃 ( $F_d$  0.37; 各 split 0.26–0.78): 检测失败。PUMA 上没有模型检测崩溃 ( $F_d$  0.85–0.88)——损失在分型 (HoVer-NeXt-T strict mPQ 0.31 vs mPQ 0.38), 且尽管有 1,991 个凋亡真值核, **三架构的 Dead PQ 均  $\leq 0.006$** : Dead 失效模式跟随模型跨域。TTA 无法挽救迁移 (CoNIC +0.005, MoNuSAC  $-0.001$ )。真实域降 (域内减外部均值 mPQ) 的架构排序为 CellViT 0.152 < HoVer-NeXt-T 0.199 < HoVer-Net 0.246, 在每个数据集上一致。

## 6.2 PanNuke-CF: 标签固定的反事实渲染

500 张折 3 patch, GT 标签固定, 由 (冻结) 生成器在因子化外观干预下重渲染——上下文 {配对, 换组织}  $\times$  Reinhard 目标 {自身, donor}——得到 control/stain/ctx/tissue 四臂, 外加未触碰的 real 图像与 3 个生成器种子的 control 重复 (噪声底)。生成器噪声比下述效应小一个数量级 (control 重复 mPQ std 0.002–0.006)。两个标定事实: 生成的 control 图像比真实更容易分割

表 5: PanNuke-CF, 架构在 2 个 split 上的均值 (mPQ; 括号为相对 control 均值的配对  $\Delta$ , 图像 bootstrap 95% CI 除 HoVer-NeXt-T stain 外均不含 0)。

| 架构           | real | control | stain        | ctx          | tissue       |
|--------------|------|---------|--------------|--------------|--------------|
| CellViT-UNI  | .495 | .449    | .426 [−.023] | .259 [−.190] | .258 [−.191] |
| HoVer-Net    | .449 | .439    | .373 [−.066] | .300 [−.140] | .293 [−.146] |
| HoVer-NeXt-T | .456 | .425    | .417 [−.008] | .262 [−.163] | .261 [−.164] |

表 6: 轴分解 (架构均值): 每个降幅拆为检测 ( $F_d$ ) 与分型 (bPQ−mPQ 间隙增量)。架构间的真实迁移差异位于检测轴, 而 CF 压力在检测轴上架构齐平。

| 架构           | 真实 (域内 − 外部) |             |       | CF ctx (control − ctx) |       |       |
|--------------|--------------|-------------|-------|------------------------|-------|-------|
|              | mPQ          | $F_d$       | 分型    | mPQ                    | $F_d$ | 分型    |
| CellViT-UNI  | .154         | <b>.007</b> | +.088 | .190                   | .102  | +.082 |
| HoVer-Net    | .246         | <b>.163</b> | +.069 | .140                   | .084  | +.034 |
| HoVer-NeXt-T | .199         | <b>.045</b> | +.085 | .163                   | .090  | +.064 |

轴匹配 rank agreement (全部 6 点 / 架构均值):  
mPQ: −0.89 ( $p=.033$ ) / −1.00; 检测  $F_d$ : −0.83 ( $p=.058$ ) / −1.00; 分型: +0.71 / +1.00。

(bPQ 0.78 vs 0.67), 但携带类型不一致的外观 (strict mPQ 0.36 vs 0.45) ——因此 CF 比较永远是臂对 control, 绝不直接对 real; 空白 patch 必须剔除 (上下文 embedding 是内容通道)。

上下文交换是强压力源 (Epithelial PQ 崩塌 0.24–0.43, 而  $F_d$  只降 0.08–0.10: 它摧毁的是类型信息), 染色是弱压力源。验证问题是: 这些反事实降幅能否在评估器之间预测真实跨域降幅。

### 6.3 有效性: 反事实压力反转真实排序

在 6 个评估点 (3 架构  $\times$  2 splits) 上, CF 降幅 vs 真实域降: Spearman  $\rho = -0.89$  (ctx, 精确置换  $p = 0.033$ ), tissue −0.89, stain +0.43 不显著。在架构均值上 (诚实检验; 同一架构的两个 split 近似重复) ctx 与 tissue 都给出  $\rho = -1.00$ : 完全倒置——域内最受上下文交换伤害的模型 (CellViT) 是真实迁移中最鲁棒的, 反之亦然。

表 6 给出机理。架构间的真实迁移差异集中在检测轴 (CellViT 的  $F_d$  损失 0.007; HoVer-Net 0.163——其 MoNuSAC 崩溃), 分型间隙增量则彼此接近 (0.07–0.09)。但标签固定的渲染无法对检测施压: 生成器在固定位置重渲染形态完好的核, CF 的  $F_d$  降幅因此在架构间齐平 (0.08–0.10), 不携带排序信息。在 CF 能施压的地方——上下文/染色错配下的分型——其排序与真实分型迁移一致 (架构均值  $\rho = +1.00$ ; 全部 6 点 +0.71/+0.83)。诚实的警示:  $n = 3$  个架构 (架构均值  $|\rho| = 1$  的精确  $p = 1/3$ ; 可辩护的证据是 3 架构  $\times$  2 splits 的完全符号倒置加上轴机理), 且架构间真实分型差异 (区间 0.069–0.088) 远小于检测差异 (0.007–0.163)。

**判定。** PanNuke-CF 是有效的分型压力测试——它与真实迁移一致地排序各架构的分型鲁棒性——但它不是迁移代理: 当作代理使用会反转排序, 因为其盲区 (检测) 恰是真实迁移差异所在。仅干预外观的反事实继承这一构造性限制; 探测检测鲁棒性需要对布局 (密度、杂乱、伪影) 的干预, 而非外观。

## 7 讨论

**为什么三个支柱一起走向负结果。** 三个支柱共享一个隐含假设——Dead 性能受限于信息 (语言先验) 或数据 (合成样本), 而非检测架构。诊断给出了相反的证据: 漏检 Dead 核在 83% 的像素

级上没有前景响应，类型分支却已经“看见”它们；语言侧融合、后处理找回、损失重加权（3种子）、真实外观移植、标签自洽的上下文内合成都没有移动检测。该缺陷与  $40\times$  下 NP 头的分辨率/架构一致——这是一个我们尚未在架构上检验的假设（如更高分辨率的前景监督），也是主要的开放方向。

**评测方法论。** 三条有证据的教训：(1) PanNuke 的种子噪声依赖类别 (mPQ 0.002 vs Dead 0.007)，且验证折的 Dead 信号可能与测试相反 (CP1: +0.024 vs -0.031) ——单种子单折的 Dead 结论不可解释；(2) 已发布的评测配方可能内嵌价值约 0.02 mPQ 的测试侧调参（我们的 HoVer-NeXt-T 解码研究），大于排行榜的典型名次差距；(3) 生成的评测数据系统性地更易分割但类型一致性更差，因此反事实基准必须臂对 control 评分，并同时报告 strict mPQ 与 mPQ。

**Dead 作为跨域现象。** 三架构在 PUMA 上 Dead PQ  $\leq 0.006$ ——尽管 Dead 是 CONCH 最可文本识别的类，也是我们域内模型检出后能以 0.69 正确分类的类——说明域内的 Dead 线索（ $40\times$  下的深色固缩染色质）不迁移到黑色素瘤 H&E 中的凋亡小体。任何 Dead 定向的贡献都必须跨域验证，而不只在 PanNuke 折上。

## 8 状态与后续工作

所有预注册实验已完成：基线复现（课程要求 (a)、(b) 完成），错误分解与类  $\times$  组织分析完成 ((c))，支柱 A/B 以负判定关闭，支柱 C 以机理式评测结果关闭。终稿报告剩余：三架构的组织  $\times$  类热力图与错误分解图、精简的主表集合、可选的额外外部集 (MoNuSeg、NuInsSeg；仅 bPQ/AJI)、以及文字润色。可选的开放方向（未预注册）：从架构侧攻击 Dead 检测缺陷，以及布局干预反事实——探测仅外观 CF 无法触及的检测轴。

## 参考文献

- [1] J. Gamper et al., “PanNuke Dataset Name, Instance Segmentation and Classification in Hematoxylin & Eosin Stained Histology Images,” *Medical Image Analysis*, 2020.
- [2] S. Graham et al., “HoVer-Net: Simultaneous Segmentation and Classification of Nuclei in Multi-Tissue Histology Images,” *Medical Image Analysis*, 2019.
- [3] J. S. Horta Malo et al., “CellViT: Vision Transformers for Precise Cell Instance Segmentation,” *Medical Image Analysis*, 2024. arXiv:2306.15350.
- [4] J. S. Horta Malo et al., “CellViT++,” arXiv:2501.05269, 2025.
- [5] S. D. Bhattacharjee et al., “HoVer-NeXt: Exploring Reliable and Efficient Lifted ViT Baselines for Nuclei Segmentation,” *MIDL*, 2024.
- [6] Y. Zhou et al., “CPP-Net: A Unified Framework for Nuclei Instance Segmentation and Classification,” arXiv:2102.06867, 2021.
- [7] S. Graham et al., “PromptNucSeg: A Text-Driven Nuclei Instance Segmentation Method,” *ECCV*, 2024. arXiv:2311.15939.
- [8] R. Lu et al., “A Visual-Language Foundation Model for Computational Pathology (CONCH),” *Nature Medicine*, 2024. arXiv:2307.12914.
- [9] “Mind the Gap: Meta-Analysis of Foundation Models for Pathology Image Analysis,” arXiv:2502.02471, 2025.

- [10] M. Le et al., “PixCell: A Generative Model for Digital Pathology Slides,” arXiv:2506.05127, 2025.
- [11] “NucleiMix: Diffusion-Based Rare-Nuclei Synthesis,” arXiv:2410.16671, 2024.
- [12] “Counterfactual Stress Testing of Medical Imaging Models,” arXiv:2605.10894, 2026.




图 2: SYN-v2 合成样例 (真实 | 生成 | 标签): 配对上下文 + Reinhard 下外观通过审查, 但二值掩码条件使生成器无法表达类别定向外观 (没有生成对象可读作 Dead)。





图 3: 左: PanNuke-CF 各臂 (同一折 3 GT 标签在上下文/染色干预下重渲染)。右: PUMA 真值 (类别着色; 黑轮廓 = 凋亡 Dead), 提供跨域 Dead 标签的外部集。