

PanNuke 上的稀有细胞核是一个检测问题： 诊断、两个失败的数据侧修复，与反事实压力测试

中期报告（课程项目 bdd26）

金鑫豪 (Xinhao Jin)

2026 年 9 月 28 日

摘要

在 PanNuke 上，更换 backbone 只能带来 1-2 个 mPQ 点的收益，而 **Dead** (凋亡) 类的 PQ 在所有已发表模型中停滞在 0.13-0.18。本中期报告回答两个问题：为什么，以及病理视觉-语言模型与可控生成模型这两类“新范式”能否撬动稀有类缺陷或鲁棒性评测。我们首先在官方 3-fold 协议下复现两个基线 (HoVer-Net 0.456 mPQ、CellViT-UNI 0.500)，并加入第三个评估器 HoVer-NeXt-T (0.458)——其初始移植得分 0.358 被证明是解码伪影而非模型差距。其次，我们证明 Dead 缺陷集中于**检测**而非分类：38.5% 的 Dead 真值核没有任何重叠预测；在这些漏检核内部，前景头沉默（平均核概率 0.16），而类型头却给出 $P(\text{Dead}) \approx 0.26$ 。第三，在预注册的多种子协议下，四类干预全部无效或有害：病理 VLM (CONCH) 后处理重分类、免训练漏检找回、类别/尺寸加权的前景损失，以及数据侧的失败驱动 copy-paste (Dead PQ -0.031) 与标签自洽的上下文内扩散合成 (mPQ 持平)。第四，我们构建了 3×3 数据集的零样本跨域基准 (CoNIC、MoNuSAC、PUMA) 与 *PanNuke-CF*——固定 PanNuke 标签、对组织上下文与染色做干预后重渲染的反事实测试集。反事实压力测试**反转**了真实跨域排序 (6 个评估点 Spearman -0.89；架构均值 -1.00)：轴分解显示架构间的真实迁移差异几乎全部位于检测轴，而标签固定的渲染在构造上无法对检测施压；在它施压的分型轴上，反事实排序与真实迁移一致。结论：反事实渲染是有效的分型压力测试而非迁移代理；Dead 检测缺陷是架构性的——它对我们测试的所有损失级与数据级干预都免疫，并跟随模型跨域 (三架构在 PUMA 上 Dead PQ ≤ 0.006)。

1 引言

细胞核实例分割与分类是计算病理学的标准任务，PanNuke [1] 是其标准基准：19 种组织、205,000 个标注核，以组织平均全景质量 (mPQ) 评测。其排行榜有一个醒目的形状：五年的架构进步压缩在约 1-2 个 mPQ 点内 (HoVer-Net [2] 0.463 $\rightarrow$ CellViT-SAM-H [3] 0.498 $\rightarrow$ 当前最佳约 0.51)，而 **Dead** (凋亡小体) 类始终停在 PQ 0.13-0.18，粘连核的 merge/split 错误也持续存在。两类新范式承诺比 backbone 工程更大的收益：病理视觉-语言模型 [8] 作为类型分类的先验，与可控生成模型 [10] 作为“组织模拟器” (定向合成训练数据，或在干预下重渲染评测图像)。

本项目按三个预注册支柱组织，附明确的通过/失败规则——其逻辑是：负结果只有在验收标准事先固定时才有价值。**A**：语言锚定的类型头 (用 CONCH 文本空间攻击稀有类分类)；**B**：失败驱动的合成 (用生成数据攻击 Dead/小核检测)；**C**：评测 (用真实跨域迁移加反事实测试集攻击鲁棒性度量)。三个支柱现已全部关闭；本报告记录其发现。贡献如下：

1. **单一严格协议下的复现** (§3)：HoVer-Net、CellViT-UNI、HoVer-NeXt-T 以完全相同的方式在官方 3-fold 划分上训练与评测：last checkpoint、仅在验证折上调解码。顺带量化了一个已发布评测配方 (16 个随机颜色 TTA 视图 + 在测试折上调阈值) 能抬高多少分数 (§3.1)。

2. **Dead 缺陷的分解** (§4.5): 它是一个集中在小核与孤立核上的检测失败——前景头看不见, 类型头却部分“看见”——这正是一切类型侧干预失败的原因。
3. **预注册的负结果** (§4、§5): CONCH 重分类、免训练找回、损失重加权 (3 种子)、失败驱动 copy-paste、上下文内扩散合成全部无效或有害; 并给出了种子噪声标定, 说明多大的效应量才可信。
4. **3×3 架构 × 数据集零样本跨域基准** (§6.1), 其中 PUMA 是我们所能找到的唯一较大规模的外部凋亡 Dead 标签来源; CoNIC 与 MoNuSAC 的转换与核验管线一并给出。
5. **PanNuke-CF**: 标签固定的反事实渲染基准 (§6.2), 其有效性分析得到机理式判定: 外观反事实无法探测检测 (构造性限制), 因此在 mPQ 层面反转真实迁移排序, 但作为分型压力测试仍然有效。

所有结果来自同一代码库与同一评测器; 该评测器已对官方 PanNuke-metrics 做到逐位一致 (官方发布的 `class_stats.csv` 存在列交换 bug, 已在仓库中记录)。

2 相关工作

PanNuke 模型。 HoVer-Net [2] 提出的水平-垂直 watershed 解码至今仍被多数后续工作 (以变体形式) 沿用。CPP-Net [6]、HoVer-NeXt [5]、CellViT [3] 及其后续 (LKCell、CellVTA、CellViT++ [4])、PromptNucSeg [7] 填满了 0.46–0.51 的 mPQ 区间。其中只有部分工作发布了按折权重; 若官方权重在全量数据上训练 (如 HoVer-Net 官方权重), 则只能作管线 sanity check, 绝不能作为测试结果——本报告全程执行这一区分。

病理基础模型与 VLM。 冻结病理基础模型在稠密任务上并不自动胜过 ImageNet CNN [9]; 病理 VLM CONCH [8] 在稠密预测上与纯视觉模型持平, 但额外提供对齐的文本空间。纯提示接口在细胞核上失败严重 (SAM3 式提示在 PanNuke 类任务上 mIoU < 10%); 最接近的已有工作 (PromptNu、MONCH) 要么没有官方 PanNuke 配置, 要么只做语义分割。我们未找到“病理 VLM 文本空间 + 实例分割 + 官方 PanNuke mPQ”的先前工作。

生成式增强与压力测试。 已有报道合成数据对稀有类有帮助 (DiffMix、HistoSmith、NucleiMix [11]), 但据我们所知没有工作在官方 3-fold PanNuke 协议下以 mPQ 报告; 已有研究使用非标准划分与 Dice/AJI/F1。影像模型的反事实压力测试已在放射学中演示 [12]; 我们不知道实例分割的对应工作。PixCell [10] (连同其 Cell-ControlNet) 是当前最强的开源可控细胞核生成器, 是我们合成实验与反事实渲染器的共同底座。

3 实验设置

数据与协议。 PanNuke 第 1–3 折, 官方划分 (train/val/test = 1/2/3、2/1/3、3/2/1); 所有数字为 *last-checkpoint* 模型的 3-split 均值, 不做基于测试集的早停。外部数据集 (§6.1) 为零样本: 每个数据集固定到 PanNuke 5 类的类别映射, 缺失类按官方协议从 mPQ 中排除。

指标。 官方组织平均 mPQ/bPQ (对 PanNuke-metrics 的逐位一致复现)、strict mPQ (对图中不存在类的 FP 计罚而非忽略)、AJI/AJI⁺、检测 F_d 与分类 F_c (12px 质心匹配)、以及 IoU 0.5 的错误分解 (matched / merged / missed-no-overlap / missed-poor-shape / split, 按类拆分)。TTA (8 个二面体变换, HV 通道重映射) 单独报告。

表 1: 官方 3-fold 协议下的基线 (3-split 均值; last checkpoint; 无 TTA, TTA 在括号内)。“已发表” = 论文自报数字 (其各自配方)。

模型	mPQ	bPQ	Dead PQ
HoVer-Net (本文)	.4564 [.4666]	.6613 [.6714]	.127 [.128]
已发表	.463	.660	.139
CellViT-UNI (本文)	.4995 [.5047]	.6654 [.6706]	.176 [.177]
已发表 (CellViT++)	.492	.664	.154
HoVer-NeXt-T (本文)	.4579	.6367	.136
已发表	.477	.656	.154

噪声标定 (用于每个判定)。 同一 CellViT-UNI 配方的 3 个种子: 种子 std 在 mPQ 上为 0.0021, 但在 Dead PQ 上为 **0.0074**; Dead 的图像 bootstrap CI 半宽为 0.02–0.03。我们由此执行: 单种子 Dead 变化低于约 0.01–0.015 视为噪声; 每个干预的判定必须是 3 种子 (或多折) 结论, 附配对、组织分层图像 bootstrap 95% CI; 决策只在验证折上做。

3.1 基线

表 1: 两个经典基线均复现 (HoVer-Net 略低于原文, 与常见复现一致; CellViT-UNI 略高于原文)。HoVer-NeXt-T 需要移植, 初始只得 0.358 mPQ; 消融表明 *预测图本身没有问题*, 损失全部在解码。其发布的 0.477 配方平均 16 个随机空间 + 颜色 TTA 视图, 并在 *测试折* 上调每类阈值。我们改用它自身的验证解码 (平坦 fg/seed 阈值), 只在每个 split 的 *验证折* 上调参——与其它基线同一协议——得到 0.4579。二者之差 (0.458 vs 0.477) 度量了测试侧调参与随机颜色 TTA 的价值; 值得注意, 这个量级 (0.02 mPQ) 大于排行榜上多数名次差距。HoVer-NeXt-T 作为第三评估器的价值在于 *不同的错误画像*: 三者中 merge 率最低 (0.096–0.101, HoVer-Net 约 0.14), missed-background 更高。

4 支柱 A: Dead 缺陷是检测缺陷

4.1 CONCH 语义存在于上下文尺度 (可行性)

对真值核的零样本 CONCH 分类: 紧裁剪接近随机 (32px: 0.27), 全上下文 patch 加半径受限注意力池化达到平衡准确率 0.695 ($R=32$ px, 每 patch 一次前向); LLM 形态学描述比裸类名高 8–11 个点。Dead 是最可被文本识别的类 (召回 0.88), 却也是分割模型最差的类——但在自然分布下其零样本精度仅约 0.10, 只能作为互补信号。线性头的文本锚定初始化只在少样本制度 (每类 ≤ 25 核) 有帮助; 全量 PanNuke 标注下无关紧要。这把支柱 A 从分类重定向到检测。

4.2 管线内重分类: 无效

把 CONCH (零样本或线性探针) 融合进 CellViT-UNI 的类型决策, 所有旋钮在验证折上调 (表 2): 没有任何配置超过管线自身的 seg-vote 类型; 重校准对照与最佳融合持平。TTA 下, 验证调参为两种融合都选择了 $\alpha = 0$ 。

4.3 免训练找回: 无效

在原始 NP/HV/TP 图上扫描 96 个配置 (前景混合、Dead 先验增强、blob 阈值、孤立体找回; 3 splits, 验证集选择): 每个族与仅调阈值的对照差距在 ± 0.0004 test mPQ 之内。漏检的 Dead 核无法从该模型的输出中找回。

表 2: CellViT-UNI 上的后处理重分类, split 1 (测试折 3)。

方法	val mPQ	test mPQ	test Dead PQ
seg vote (管线)	.4835	.4951	.142
+ 类别偏置重校准	.4873	.4953	.135
× CONCH 零样本 ($\alpha=.1$)	.4835	.4938	.141
× CONCH 线性 ($\alpha=.3$)	.4836	.4920	.141
CONCH 线性单独	.3645	.3821	.145

表 3: CellViT-UNI 在折 3 上的错误分解 (IoU 0.5; 真值核占比)。

真值类	matched	merged	missed	miss(形状)	split	匹配后类型正确
Neoplastic	.811	.048	.092	.040	.009	.905
Inflammatory	.849	.046	.079	.023	.004	.817
Connective	.752	.038	.153	.044	.013	.794
Dead	.470	.089	.385	.048	.008	.690
Epithelial	.837	.042	.075	.036	.011	.930

4.4 损失侧消融：无效或是交换

split 1 上的像素加权前景 CE, 配 3 种子基线: Dead 像素权 $\times 11$ (M1) 无效; 完全均衡采样器 (C1) 无效; 小核权 $\times 6$ (M2) 在一个种子里看似有希望 (+0.0042 test mPQ, CI 不含 0), 但 3 种子上 mPQ -0.0010 $[-0.0043, +0.0022]$, 且 bPQ 显著下降 -0.0024 $[-0.0048, -0.0002]$, Dead 增益 $+0.0108$ $[-0.0021, +0.0238]$ 不显著——这是一次交换而非贡献, 也干净地演示了该基准上单种子 mPQ 效应低于约 0.004 就是种子运气。

4.5 诊断: Dead 性能在哪里丢失

表 3: 38.5% 的 Dead 核没有任何重叠预测 (其它类 8–15%), 而 Dead 匹配后类型正确率为 0.69——损失以检测为先。在漏检的 Dead 核内部, 前景头沉默 (平均 NP 概率 0.164; 17% 中有响应), 类型分支却给出 $P(\text{Dead}) \approx 0.26$ (其它类漏检核约 0.01): 网络“看见”了前景头丢弃的死亡物质。尺寸贡献很大 (Dead 中位面积 107 px, 其它类 368; 24% 的 Dead < 60 px, 其它类 6%), 但外观效应在尺寸分层后依然存在: 大 Dead (> 200 px) 的漏检率是其它大类核的 6 倍 (0.214 vs 0.035)。定性上 (图 1), 漏检 Dead 是核碎裂碎片、乏染色质的嗜酸性小体与模糊标注。结论: 要么改检测, 要么改数据——由此定义支柱 B。

5 支柱 B: 失败驱动的合成同样无法修复检测

5.1 失败布局长什么样

折外失败挖掘 (split-2 模型预测折 1; 折 3 测试上模式相同): 漏检 Dead 是孤立的——零接触邻居的 Dead 漏检率 0.39–0.42 (占全部 Dead 的约 90%), 漏检 Dead 与其它核接触的比例 $< 5\%$ 。merge 是同类簇现象 (73–82% 的 merged Dead 与另一 Dead 接触: 核碎裂碎片群)。直觉假设的跨类接触在数据中罕见且不是失败模式。因此原计划的“Dead 紧贴 Neoplastic”干预被替换为: (1) 向空基质插入孤立小核; (2) 密集同类簇。




图 1: Dead 真值核 (绿色) 与预测 (黄色), CellViT-UNI 折 3: 漏检 Dead 是没有前景响应的微小暗色碎片与乏染色质凋亡小体。

5.2 CP1: 失败驱动 copy-paste 是有害的

供体核 (50–400 px, Dead 权重 0.4) 以 8 px 间距粘入无核基质, 且在几何/光度增强 之前粘贴 (粘贴核与宿主 patch 同步增强; v1 的可学习捷径由视觉审查发现并修复, 同时修复的还有边界碎片与未标注核碰撞)。相对 3 种子基线的结果 (split 1, 测试折 3): $\Delta mPQ +0.0009 [-0.0024, +0.0043]$, 但 $\Delta Dead -0.0310 [-0.0576, -0.0100]$ (TTA 一致)。损伤在分型而非检测: 匹配 Dead 的类型正确率 $.690 \rightarrow .609$, 混淆双向增加。值得注意的是验证折在 Dead 上指向相反方向 (+0.0235): Dead PQ 在折间摆动约 0.05, 这是噪声规则的第三次独立确认。解释: 把真实外观移植进新上下文, 教会模型 “干净基质中的孤立小核” 是一个 Dead-ish 线索, 从而模糊了类型边界。

5.3 上下文内合成 (PixCell): 从外观差距到结构性标签阻断

PixCell-256 + Cell-ControlNet, 以折 1 真实掩码为条件: 放置是忠实的 (约 95% 的掩码对象在正确位置/尺寸渲染, 中位 IoU 0.68), 但 20× 生成器在 40× PanNuke 上有结构性外观差距 (平色块染色质、高频 -24%、大掩码欠渲染且尺寸偏置)。LoRA 适配 (两轮, r16 与 r8 加快照选择) 使每个图像空间指标都更差, 路线放弃; 改用对配对真实 patch 的 Reinhard LAB 迁移关闭颜色差距 (OD-L1 0.072 $\rightarrow$ 0.009)。锁定配方 (基座 + 配对上下文 + Reinhard) 下, 32 图冒烟的视觉审查通过 (颜色与配对真实相差约 3/255), 但审查暴露了一个结构性阻断: ControlNet 条件是二值掩码, 上下文 embedding 不含类别信息——生成器无法表达类别定向的外观——729 个保留对象中 0 个被教师判为 Dead ($P(Dead) \leq 0.005$)。强行使用供体类别标签会精确复现 CP1 的失败 (标签与外观矛盾)。SYN1 因此采用类别无关、教师自治的标签——它只能经由检测起作用: 1146 张合成图以

表 4: 零样本跨域 (3-split 均值, 无 TTA)。域内 mPQ: CellViT 0.4995、HoVer-Net 0.4564、HoVer-NeXt-T 0.4579。

模型	数据集	mPQ	bPQ	F_d
CellViT-UNI	CoNIC	.3351 $\pm$.0037	.5314	.7816
	MoNuSAC	.2495 $\pm$.0218	.5616	.7652
	PUMA	.4518 $\pm$.0031	.7177	.8831
HoVer-Net	CoNIC	.2610 $\pm$.0061	.5136	.7669
	MoNuSAC	.0370 $\pm$.0003	.2756	.3658
	PUMA	.3203 $\pm$.0139	.7136	.8714
HoVer-NeXt-T	CoNIC	.2786	.4811	.725
	MoNuSAC	.1123	.4025	.628
	PUMA	.3813	.6888	.848

50% 混合, 其余与基线配方完全一致。结果 (测试折 3): mPQ 0.4900 vs 基线 0.4951 (3 种子区间 0.4910–0.4951 的底部), Dead 0.1521 vs 0.1424 (约 +1 点, 处于种子噪声边缘; $PQ^+/DQ^+/SQ^+$ 全平: 这点 Dead 收益来自更好的类型配对而非更好的分割), Inflammatory -1.0 – 1.6 点。按预注册规则判定: 无效。

5.4 支柱 B 判定

在不重训生成器条件的条件下, Dead/小核检测缺陷无法被可用的数据侧杠杆修复: 真实外观移植 (CP1) 主动伤害 Dead 分型, 标签自洽的上下文内合成 (SYN1) 无效。连同支柱 A 的无效结果 (重分类、找回、损失重加权), 该缺陷看起来是架构性的。

6 支柱 C: 跨域与反事实评测

6.1 真实跨域零样本: 3×3

外部数据集 (已转换并通过拼接图审查): **CoNIC** (19,476 tiles; 剔除 112 张源自 PanNuke 的 patch; $20 \times \rightarrow 2 \times$ 上采样; 类 Inflamm/Epith/Conn)、**MoNuSAC** test (443 tiles; Inflamm/Epith)、**PUMA** 黑色素瘤 (3,278 tiles; PanNuke 5 类齐全, 含 1,991 个凋亡 $\rightarrow$ Dead 核——我们找到的唯一较大外部 Dead 来源; GT 由 HoVer-Net 初始化、病理学家校正, 绝对召回有上限, 但对所有模型公平共享)。

表 4: 所有模型都退化, 但方式不同。HoVer-Net 在 MoNuSAC 上几乎 **崩溃** (F_d 0.37; 各 split 0.26–0.78): 检测失败。PUMA 上没有模型检测崩溃 (F_d 0.85–0.88)——损失在分型 (HoVer-NeXt-T strict mPQ 0.31 vs mPQ 0.38), 且尽管有 1,991 个凋亡真值核, **三架构的 Dead PQ 均 ≤ 0.006** : Dead 失效模式跟随模型跨域。TTA 无法挽救迁移 (CoNIC +0.005, MoNuSAC -0.001)。真实域降 (域内减外部均值 mPQ) 的架构排序为 CellViT 0.152 < HoVer-NeXt-T 0.199 < HoVer-Net 0.246, 在每个数据集上一致。

6.2 PanNuke-CF: 标签固定的反事实渲染

500 张折 3 patch, *GT* 标签固定, 由 (冻结) 生成器在因子化外观干预下重渲染——上下文 {配对, 换组织} $\times$ Reinhard 目标 {自身, donor}——得到 control/stain/ctx/tissue 四臂, 外加未触碰的 **real** 图像与 3 个生成器种子的 control 重复 (噪声底)。生成器噪声比下述效应小一个数量级 (control 重复 mPQ std 0.002–0.006)。两个标定事实: 生成的 control 图像比真实更容易分割

表 5: PanNuke-CF, 架构在 2 个 split 上的均值 (mPQ; 括号为相对 control 均值的配对 Δ , 图像 bootstrap 95% CI 除 HoVer-NeXt-T stain 外均不含 0)。

架构	real	control	stain	ctx	tissue
CellViT-UNI	.495	.449	.426 [−.023]	.259 [−.190]	.258 [−.191]
HoVer-Net	.449	.439	.373 [−.066]	.300 [−.140]	.293 [−.146]
HoVer-NeXt-T	.456	.425	.417 [−.008]	.262 [−.163]	.261 [−.164]

表 6: 轴分解 (架构均值): 每个降幅拆为检测 (F_d) 与分型 (bPQ−mPQ 间隙增量)。架构间的真实迁移差异位于检测轴, 而 CF 压力在检测轴上架构齐平。

架构	真实 (域内 − 外部)			CF ctx (control − ctx)		
	mPQ	F_d	分型	mPQ	F_d	分型
CellViT-UNI	.154	.007	+0.088	.190	.102	+0.082
HoVer-Net	.246	.163	+0.069	.140	.084	+0.034
HoVer-NeXt-T	.199	.045	+0.085	.163	.090	+0.064

轴匹配 rank agreement (全部 6 点 / 架构均值):
mPQ: −0.89 ($p=.033$) / −1.00; 检测 F_d : −0.83 ($p=.058$) / −1.00; 分型: +0.71 / **+1.00**。

(bPQ 0.78 vs 0.67), 但携带类型不一致的外观 (strict mPQ 0.36 vs 0.45) ——因此 CF 比较永远是臂对 control, 绝不直接对 real; 空白 patch 必须剔除 (上下文 embedding 是内容通道)。

上下文交换是强压力源 (Epithelial PQ 崩塌 0.24–0.43, 而 F_d 只降 0.08–0.10: 它摧毁的是类型信息), 染色是弱压力源。验证问题是: 这些反事实降幅能否在评估器之间预测 真实跨域降幅。

6.3 有效性: 反事实压力反转真实排序

在 6 个评估点 (3 架构 $\times$ 2 splits) 上, CF 降幅 vs 真实域降: Spearman $\rho = -0.89$ (ctx, 精确置换 $p = 0.033$), tissue −0.89, stain +0.43 不显著。在架构均值上 (诚实检验; 同一架构的两个 split 近似重复) ctx 与 tissue 都给出 $\rho = -1.00$: 完全倒置——域内最受上下文交换伤害的模型 (CellViT) 是真实迁移中最鲁棒的, 反之亦然。

表 6 给出机理。架构间的真实迁移差异集中在检测轴 (CellViT 的 F_d 损失 0.007; HoVer-Net 0.163——其 MoNuSAC 崩溃), 分型间隙增量则彼此接近 (0.07–0.09)。但标签固定的渲染无法对检测施压: 生成器在固定位置重渲染形态完好的核, CF 的 F_d 降幅因此在架构间齐平 (0.08–0.10), 不携带排序信息。在 CF 能施压的地方——上下文/染色错配下的分型——其排序与真实分型迁移一致 (架构均值 $\rho = +1.00$; 全部 6 点 +0.71/+0.83)。诚实的警示: $n = 3$ 个架构 (架构均值 $|\rho| = 1$ 的精确 $p = 1/3$; 可辩护的证据是 3 架构 $\times$ 2 splits 的完全符号倒置加上轴机理), 且架构间真实分型差异 (区间 0.069–0.088) 远小于检测差异 (0.007–0.163)。

判定。 PanNuke-CF 是有效的分型压力测试——它与真实迁移一致地排序各架构的分型鲁棒性——但它不是迁移代理: 当作代理使用会反转排序, 因为其盲区 (检测) 恰是真实迁移差异所在。仅干预外观的反事实继承这一构造性限制; 探测检测鲁棒性需要对 布局 (密度、杂乱、伪影) 的干预, 而非外观。

7 讨论

为什么三个支柱一起走向负结果。 三个支柱共享一个隐含假设——Dead 性能受限于信息 (语言先验) 或数据 (合成样本), 而非检测架构。诊断给出了相反的证据: 漏检 Dead 核在 83% 的像素

级上没有前景响应，类型分支却已经“看见”它们；语言侧融合、后处理找回、损失重加权（3种子）、真实外观移植、标签自洽的上下文内合成都没有移动检测。该缺陷与 $40\times$ 下 NP 头的分辨率/架构一致——这是一个我们尚未在架构上检验的假设（如更高分辨率的前景监督），也是主要的开放方向。

评测方法论。 三条有证据的教训：(1) PanNuke 的种子噪声依赖类别 (mPQ 0.002 vs Dead 0.007)，且验证折的 Dead 信号可能与测试相反 (CP1: +0.024 vs -0.031) ——单种子单折的 Dead 结论不可解释；(2) 已发布的评测配方可能内嵌价值约 0.02 mPQ 的测试侧调参（我们的 HoVer-NeXt-T 解码研究），大于排行榜的典型名次差距；(3) 生成的评测数据系统性地 **更易分割但类型一致性更差**，因此反事实基准必须臂对 control 评分，并同时报告 strict mPQ 与 mPQ。

Dead 作为跨域现象。 三架构在 PUMA 上 Dead PQ ≤ 0.006 ——尽管 Dead 是 CONCH 最可文本识别的类，也是我们域内模型检出后能以 0.69 正确分类的类——说明域内的 Dead 线索（ $40\times$ 下的深色固缩染色质）不迁移到黑色素瘤 H&E 中的凋亡小体。任何 Dead 定向的贡献都必须跨域验证，而不只在 PanNuke 折上。

8 状态与后续工作

所有预注册实验已完成：基线复现（课程要求 (a)、(b) 完成），错误分解与类 $\times$ 组织分析完成 ((c))，支柱 A/B 以负判定关闭，支柱 C 以机理式评测结果关闭。终稿报告剩余：三架构的组织 $\times$ 类热力图与错误分解图、精简的主表集合、可选的额外外部集 (MoNuSeg、NuInsSeg；仅 bPQ/AJI)、以及文字润色。可选的开放方向（未预注册）：从架构侧攻击 Dead 检测缺陷，以及布局干预反事实——探测仅外观 CF 无法触及的检测轴。

参考文献

- [1] J. Gamper et al., “PanNuke Dataset Name, Instance Segmentation and Classification in Hematoxylin & Eosin Stained Histology Images,” *Medical Image Analysis*, 2020.
- [2] S. Graham et al., “HoVer-Net: Simultaneous Segmentation and Classification of Nuclei in Multi-Tissue Histology Images,” *Medical Image Analysis*, 2019.
- [3] J. S. Horta Malo et al., “CellViT: Vision Transformers for Precise Cell Instance Segmentation,” *Medical Image Analysis*, 2024. arXiv:2306.15350.
- [4] J. S. Horta Malo et al., “CellViT++,” arXiv:2501.05269, 2025.
- [5] S. D. Bhattacharjee et al., “HoVer-NeXt: Exploring Reliable and Efficient Lifted ViT Baselines for Nuclei Segmentation,” *MIDL*, 2024.
- [6] Y. Zhou et al., “CPP-Net: A Unified Framework for Nuclei Instance Segmentation and Classification,” arXiv:2102.06867, 2021.
- [7] S. Graham et al., “PromptNucSeg: A Text-Driven Nuclei Instance Segmentation Method,” *ECCV*, 2024. arXiv:2311.15939.
- [8] R. Lu et al., “A Visual-Language Foundation Model for Computational Pathology (CONCH),” *Nature Medicine*, 2024. arXiv:2307.12914.
- [9] “Mind the Gap: Meta-Analysis of Foundation Models for Pathology Image Analysis,” arXiv:2502.02471, 2025.

- [10] M. Le et al., “PixCell: A Generative Model for Digital Pathology Slides,” arXiv:2506.05127, 2025.
- [11] “NucleiMix: Diffusion-Based Rare-Nuclei Synthesis,” arXiv:2410.16671, 2024.
- [12] “Counterfactual Stress Testing of Medical Imaging Models,” arXiv:2605.10894, 2026.




图 2: SYN-v2 合成样例 (真实 | 生成 | 标签): 配对上下文 + Reinhard 下外观通过审查, 但二值掩码条件使生成器无法表达类别定向外观 (没有生成对象可读作 Dead)。





图 3: 左: PanNuke-CF 各臂 (同一折 3 GT 标签在上下文/染色干预下重渲染)。右: PUMA 真值 (类别着色; 黑轮廓 = 凋亡 Dead), 提供跨域 Dead 标签的外部集。