

PanNuke 稀有细胞核的瓶颈在检测： 诊断、两项失败的数据侧修复与反事实压力测试

阶段报告一（课程项目 bdd26）

2026 年 9 月 28 日

2026 年 10 月 2 日：结论范围更正

本文保留 9 月 28 日的实验结果作为历史记录。以下说明优先于原正文中较宽泛的解释。负结果只针对已经测试的损失、复制粘贴与生成配置，不能推出所有数据方法都无效；多种子证据只适用于实际包含重复训练的实验，并非每项列出的干预。固定标签本身不妨碍施加检测压力，失败的是当前反事实生成器对真实跨域排序的代理作用。相关性比较只有三个独立架构家族，不是六个；架构均值的精确置换检验为 $p = 0.333$ ，不能把六点评估解释为强独立架构证据。

代码中的 `missed_bg` 指最大 IoU 小于 0.1，不一定完全没有重叠。 mPQ^+ 仍与类别有关， F_c 同时受到检测和类型错误影响。发布的验证集最优权重与我们自训模型的最后检查点，不是完全相同的选点协议。后续审计及 P0-P3 实验（v2，包含合并前发现的共享边界累加与官方 GT 通道修正）详见仓库 docs 目录的 `P0_P3_RESULTS_2026-10-02.md`；检测是所研究基线的重要瓶颈，不代表类型预测对后续改进无关紧要。

摘要

在 PanNuke 上, 更换 backbone 只能带来 1-2 个 mPQ 点的收益, 而 **Dead** (凋亡) 类的 PQ 在所有已发表模型中停滞在 0.13-0.19。本阶段报告回答两个问题: Dead 为何停滞, 以及病理视觉-语言模型与可控生成模型这两类“新范式”能否改善稀有类缺陷或改进鲁棒性评测。我们首先在官方 3-fold 协议下复现两个基线 (HoVer-Net 0.456 mPQ、CellViT-UNI 0.500), 并加入第三个评估器 HoVer-NeXt-T (0.458) ——其初始移植得分 0.358 被证明源于解码伪影, 而非模型差距。其次, 我们证明 Dead 缺陷集中于**检测**而非分类: 38.5% 的 Dead 真值核没有任何重叠预测; 在这些漏检核内部, 前景头沉默 (平均核概率 0.16), 而类型头却给出 $P(\text{Dead}) \approx 0.26$ 。第三, 在预注册的多种子协议下, 五项干预全部无效或有害: 模型侧的病理 VLM (CONCH) 后处理重分类、免训练漏检找回与类别/尺寸加权的前景损失, 以及数据侧的失败驱动 copy-paste (Dead PQ -0.031) 与标签自洽的上下文内扩散合成 (mPQ 持平)。第四, 我们构建了三架构 $\times$ 三数据集的零样本跨域基准 (CoNIC、MoNuSAC、PUMA) 与 *PanNuke-CF* ——固定 PanNuke 标签、对组织上下文与染色做干预后重渲染的反事实测试集。反事实压力测试**反转**了真实跨域排序 (6 个评估点 Spearman -0.89; 架构均值 -1.00): 轴分解显示架构间的真实迁移差异几乎全部位于检测轴, 而标签固定的渲染在构造上便无法触及检测; 在它施压的分型轴上, 反事实排序与真实迁移一致。结论: 反事实渲染是有效的分型压力测试而非迁移代理; Dead 检测缺陷为我们评测的所有架构家族所共有 (ViT-L/16、全分辨率 ResNet-50 与 ConvNeXt 三种解码器的尺寸-漏检曲线几乎重合) ——我们测试的所有损失级与数据级干预都对它无效, 且该缺陷跨域依然存在 (三架构在 PUMA 上的平均 Dead PQ 仅 0.002-0.033, 域内为 0.13-0.19)。

1 引言

细胞核实例分割与分类是计算病理学的标准任务, PanNuke [1] 是其代表性基准: 19 种组织、205,000 个标注核, 以组织平均 mPQ (mean panoptic quality) 评测。其排行榜长期停滞不前: 五年的架构进步总共只跨越约 5 个 mPQ 点 (HoVer-Net [2] 0.463 $\rightarrow$ CellViT-SAM-H [3] 0.498 $\rightarrow$ 当前最佳约 0.51; 最近一代模型彼此相差不过约 2 个点, 且 §3.1 将显示已发布的评测配方还可能使报告值虚高约 0.02), 而 **Dead** (凋亡小体) 类始终停在 PQ 0.13-0.19, 粘连核的 merge/split 错误也持续存在。两类新范式有望带来比 backbone 工程更大的收益: 一是病理视觉-语言模型 [8], 可作为类型分类的先验; 二是可控生成模型 [10], 可充当“组织模拟器”——定向合成训练数据, 或在干预下重渲染评测图像。

本项目围绕三个预注册的支柱展开, 每个支柱都事先写明通过/失败标准——负结果只有在验收标准事先固定时才有价值。**A**: 语言锚定的类型头——用 CONCH 文本空间攻克稀有类的分类问题; **B**: 失败驱动的合成——用生成数据攻克 Dead 与小核的检测问题; **C**: 评测——用真实跨域迁移与反事实测试集检验现有的鲁棒性度量。三个支柱现均已收官, 本报告记录各项发现。贡献如下:

1. **单一严格协议下的复现** (§3): HoVer-Net、CellViT-UNI 由我们自行训练并按同一协议评测 (一律取 last checkpoint、解码超参仅在验证折上调节); HoVer-NeXt-T 使用官方发布的分析 (per-fold) 权重 (其验证折选出的 checkpoint; 折划分已核对, 与我们的完全一致), 配以同样仅在验证折上调好的解码。并在此过程中量化了一个已发布评测配方 (16 个随机空间 + 颜色 TTA 视图 + 在测试折上调阈值) 能把分数抬高多少 (§3.1)。
2. **Dead 缺陷的分解** (§4.5): 它是一个集中在小核与孤立核上的检测失败——前景头看不见, 类型头却部分“看见”——这正是所有类型侧干预都失败的原因。
3. **预注册的负结果** (§4、§5): CONCH 重分类、免训练找回、损失重加权 (3 种子)、失败驱动 copy-paste、上下文内扩散合成全部无效或有害; 并给出了种子噪声标定, 说明多大的效应量才可信。
4. **3 $\times$ 3 架构 $\times$ 数据集零样本跨域基准** (§6.1), 其中 PUMA 是我们所能找到的唯一较大规模的外部凋亡 Dead 标签来源; CoNIC 与 MoNuSAC 的转换与核验管线一并给出。

5. **PanNuke-CF**: 标签固定的反事实渲染基准 (§6.2), 并在机理层面判定其有效性: 外观反事实在构造上无法检验检测能力, 因此在 mPQ 层面反转真实迁移排序, 但作为分型压力测试仍然有效。

所有结果来自同一代码库与同一评测器; 该评测器与官方 PanNuke-metrics 逐位一致 (官方发布的 `class_stats.csv` 存在列交换 bug, 已在仓库中记录)。

2 相关工作

PanNuke 模型。 HoVer-Net [2] 提出的水平-垂直 watershed 解码至今仍被多数后续工作 (以变体形式) 沿用。CPP-Net [6]、HoVer-NeXt [5]、CellViT [3] 及其后续 (LKCell、CellVTA、CellViT++ [4])、PromptNucSeg [7] 均落在 0.46–0.51 的 mPQ 区间内。其中只有部分工作发布了分折 (per-fold) 权重; 若官方权重是在全量数据上训练的 (如 HoVer-Net 官方权重), 便只能用于管线 sanity check, 绝不能当作测试结果——本报告全程遵守这一区分。

病理基础模型与 VLM。 冻结的病理基础模型在稠密任务上并不必然优于 ImageNet CNN [9]; 病理 VLM CONCH [8] 在稠密预测上与纯视觉模型持平, 但额外提供对齐的文本空间。纯提示接口在细胞核任务上表现极差 (SAM3 式提示在 PanNuke 类任务上 mIoU < 10%); 最接近的已有工作 (PromptNu、MONCH) 要么没有官方 PanNuke 配置, 要么只做语义分割。据我们所知, “病理 VLM 文本空间 + 实例分割 + 官方 PanNuke mPQ” 这一组合尚无先前工作。

生成式增强与压力测试。 已有报道显示, 合成数据对稀有类有帮助 (DiffMix、HistoSmith、NucleiMix [11]), 但据我们所知没有工作在官方 3-fold PanNuke 协议下以 mPQ 报告——已有研究均使用非标准划分与 Dice/AJI/F1。影像模型的反事实压力测试已在放射学中得到演示 [12]; 实例分割中尚无对应工作。PixCell [10] (连同其 Cell-ControlNet) 是当前最强的开源可控细胞核生成器, 也是我们合成实验与反事实渲染器的共同基础。

3 实验设置

数据与协议。 PanNuke 第 1–3 折, 官方划分 ($\text{train/val/test} = 1/2/3, 2/1/3, 3/2/1$); 所有数字为 3-split 均值, 不做基于测试集的早停: 我们自行训练的 HoVer-Net/CellViT-UNI 取 last checkpoint, HoVer-NeXt-T 用官方发布的分折 (验证折选出) checkpoint。外部数据集 (§6.1) 为零样本: 每个数据集都映射到 PanNuke 5 类, 缺失类按官方协议从 mPQ 中排除。

指标。 官方组织平均 mPQ/bPQ (对 PanNuke-metrics 的逐位一致复现)、strict mPQ (对图中不存在的类别计罚其 FP, 而非忽略)、AJI/AJI⁺、检测 F_d 与分类 F_c (12 px 质心匹配)、以及 IoU 0.5 的错误分解 (matched / merged / missed-no-overlap / missed-poor-shape / split, 按类拆分)。TTA (8 个二面体变换, HV 通道重映射) 单独报告。

噪声标定 (用于每个判定)。 用同一 CellViT-UNI 配方训练 3 个种子: std 在 mPQ 上为 0.0021, 但在 Dead PQ 上为 **0.0074**; Dead 的图像 bootstrap CI 半宽为 0.02–0.03。我们据此执行以下规则: 单种子 Dead 变化低于约 0.01–0.015 视为噪声; 每个干预的判定必须是 3 种子 (或多折) 结论, 附配对、组织分层图像 bootstrap 95% CI; 所有决策只在验证折上做出。

表 1: 官方 3-fold 协议下的基线 (3-split 均值; 无 TTA, TTA 在括号内)。HoVer-Net/CellViT-UNI 为我们自行训练、取 last checkpoint; HoVer-NeXt-T 用官方发布的分析权重。“已发表” = 论文自报数字 (其各自配方)。

模型	mPQ	bPQ	Dead PQ
HoVer-Net (本文)	.4564 [.4666]	.6613 [.6714]	.127 [.128]
已发表	.463	.660	.139
CellViT-UNI (本文)	.4995 [.5047]	.6654 [.6706]	.176 [.177]
已发表 (CellViT++)	.492	.664	.154
HoVer-NeXt-T (本文)	.4579	.6367	.136
已发表	.477	.656	.154

3.1 基线

表 1 显示, 两个经典基线均成功复现 (HoVer-Net 略低于原文, 与常见复现情况一致; CellViT-UNI 略高于原文)。HoVer-NeXt-T 需要把官方发布的分析权重移植进我们的管线, 初始得分仅 0.358 mPQ; 消融表明预测图本身没有问题, 性能损失完全出在解码环节。其发布的 0.477 配方平均 16 个随机空间 + 颜色 TTA 视图, 并在测试折上调每类阈值。我们改用它自身的验证解码 (平坦 fg/seed 阈值), 只在每个 split 的验证折上调参 (与其它基线同一协议), 得到 0.4579。二者之差 (0.458 vs 0.477) 反映了测试侧调参与随机颜色 TTA 一共能带来多少提升; 这个量级 (0.02 mPQ) 大于排行榜上多数名次差距。HoVer-NeXt-T 作为第三评估器的价值在于它与二者不同的错误模式: 其平坦解码把相互接触的核并成一体比例约为分水岭解码的两倍 (merged GT 率 0.096–0.101, CellViT-UNI 为 0.044、HoVer-Net 为 0.049), 漏检 (missed-background) 比例高于 CellViT-UNI (0.122–0.131 vs 0.102–0.109)。

4 支柱 A: Dead 缺陷是检测缺陷

4.1 CONCH 的类别语义只在上下文尺度上显现 (可行性)

我们在真值核上直接测试零样本 CONCH 分类: 紧裁剪下接近随机水平 (32 px 裁剪为 0.27); 改用全上下文 patch 加半径受限注意力池化后, 平衡准确率达到 0.695 ($R=32$ px, 每 patch 一次前向); 用 LLM 形态学描述替代纯类名, 再提高 8–11 个点。在五类之中, Dead 是 CONCH 文本识别效果最好的一类 (召回 0.88), 而分割模型恰恰在 Dead 上表现最差。不过在自然分布下, CONCH 对 Dead 的零样本精度只有约 0.10, 因此只能作为互补信号。线性头的文本锚定初始化只在少样本情形 (每类 ≤ 25 核) 下有帮助, 在全量 PanNuke 标注下则不起作用。这把支柱 A 的重心从分类转移到了检测。

4.2 管线内重分类: 无效

我们将 CONCH (零样本或线性探针) 融合进 CellViT-UNI 的类型决策, 所有可调参数均在验证折上确定 (表 2): 没有任何配置超过管线自身的 seg-vote 类型决策; 重校准对照与最佳融合持平。TTA 下, 验证调参为两种融合都选择了 $\alpha = 0$ 。

4.3 免训练找回: 无效

在原始 NP/HV/TP 图上扫描 96 个配置, 覆盖前景混合、Dead 先验增强、blob 阈值、孤立体找回四族 (3 个 split, 配置在验证集上挑选): 每个族与官方默认配置相比, 差距都在 ± 0.0004 test mPQ 之内——仅调阈值的对照与任何找回变体效果相当。漏检的 Dead 核无法从该模型的输出中找回。

表 2: CellViT-UNI 上的后处理重分类, split 1 (测试折 3)。

方法	val mPQ	test mPQ	test Dead PQ
seg vote (管线)	.4835	.4951	.142
+ 类别偏置重校准	.4873	.4953	.135
× CONCH 零样本 ($\alpha=.1$)	.4835	.4938	.141
× CONCH 线性 ($\alpha=.3$)	.4836	.4920	.141
CONCH 线性单独	.3645	.3821	.145

表 3: CellViT-UNI 在折 3 上的错误分解 (IoU 0.5; 真值核占比)。

真值类	matched	merged	missed	miss(形状)	split	匹配后类型正确
Neoplastic	.811	.048	.092	.040	.009	.905
Inflammatory	.849	.046	.079	.023	.004	.817
Connective	.752	.038	.153	.044	.013	.794
Dead	.470	.089	.385	.048	.008	.690
Epithelial	.837	.042	.075	.036	.011	.930

4.4 损失侧消融：无效或是交换

split 1 上的像素加权前景 CE, 配 3 种子基线: Dead 像素权 $\times 11$ (M1) 无效; 完全均衡采样器 (C1) 无效; 小核权 $\times 6$ (M2) 在一个种子里看似有希望 (+0.0042 test mPQ, CI 不含 0), 但 3 种子上 mPQ -0.0010 $[-0.0043, +0.0022]$, 且 bPQ 显著下降 -0.0024 $[-0.0048, -0.0002]$, Dead 增益 $+0.0108$ $[-0.0021, +0.0238]$ 不显著——这是一次交换而非贡献; 它也清楚地说明: 在该基准上, 低于约 0.004 的单种子 mPQ 效应只能算种子运气。

4.5 诊断：Dead 性能在哪里丢失

表 3 显示, 38.5% 的 Dead 核没有任何重叠预测 (其它类为 8–15%), 而 Dead 匹配后的类型正确率为 0.69——性能损失首先出在检测。在漏检的 Dead 核内部, 前景头沉默 (平均 NP 概率 0.164, 仅在 17% 的核中有响应), 类型分支却给出 $P(\text{Dead}) \approx 0.26$ (其它类漏检核约 0.01): 网络其实“看见”了这些凋亡物质, 只是前景头没有响应。尺寸是一个重要因素 (Dead 中位面积 107 px, 其它类 368; 24% 的 Dead < 60 px, 其它类 6%), 但外观效应在尺寸分层后依然存在: 大面积 Dead (> 200 px) 的漏检率是其它类大核的 6 倍 (0.214 vs 0.035)。定性来看 (图 2), 漏检的 Dead 多为核碎裂碎片与乏染色质的嗜酸性小体, 也有一部分是标注本身模糊的核。结论: 要么改检测, 要么改数据——支柱 B 由此而来。

事后分解 (三评估器, 测试折 3+1; `scripts/analyze_artifacts.py`) 从两方面细化了这一诊断。其一, Dead 之外的“漏检小核”大多是贴片边界碎片: < 60 px 的真值核中 89% 接触 256 px 图块边界; 只看内部 (不贴边) 核, Neo/Inf/Epi/Con 的漏检率为 .037/.027/.028/.095, 而 Dead 为 .31, 且 ≥ 256 px 的 Dead 仍有 .17。其二, 官方逐类 PQ 只在含有该类的图上逐图平均: Dead 只由折 3 的 97 张、折 1 的 65 张图决定, 而折 3 中有 34 张 Uterus 的 Dead 图, 其 Dead PQ 在所有架构上都只有 .01–.05 (腺腔内淡染脱落细胞团; 其内部 Dead 核的 69% 被三架构一致漏检)。剔除 Uterus 图后, CellViT-UNI 三个 split 的 Dead PQ 为 .195/.227/.231 (官方 .142/.162/.224): 折间 Dead 差距来自测试折的图像组成, 而非模型行为。




图 1: CellViT-UNI 在折 3 上的错误分解 (IoU 0.5; 占该类真值核比例), 即表 3 的图形版: Dead 一行由漏检主导 (38.5% 的 Dead 核没有任何重叠预测, 其它类为 8–15%), 而非类型判错。

5 支柱 B: 失败驱动的合成同样无法修复检测

5.1 失败布局长什么样

我们在折外数据上挖掘失败布局 (用 split-2 模型预测折 1; 折 3 测试上模式相同), 发现漏检的 Dead 核是孤立的: 完全不与任何邻居接触的 Dead 核, 漏检率为 0.39–0.42 (占全部 Dead 的约 90%), 而漏检 Dead 与其它核接触的比例 <5%。merge 则是同类成簇的现象 (73–82% 的 merged Dead 与另一 Dead 相接触, 即核碎裂碎片群)。起初假设的跨类接触在数据中很罕见, 并非失败模式。因此我们放弃了原计划的 “Dead 紧贴 Neoplastic” 干预, 改为: (1) 向空基质插入孤立小核; (2) 密集同类簇。

5.2 CP1: 失败驱动 copy-paste 是有害的

供体核 (50–400 px, Dead 权重 0.4) 以 8 px 间距粘入无核基质, 且在几何/光度增强 之前粘贴 (粘贴核与宿主 patch 同步增强; 视觉审查发现了 v1 中的可学习捷径并将其修复, 同时修复的还有边界碎片与未标注核碰撞)。相对 3 种子基线的结果 (split 1, 测试折 3): $\Delta mPQ +0.0009$ $[-0.0024, +0.0043]$, 但 $\Delta Dead -0.0310$ $[-0.0576, -0.0100]$ (TTA 一致)。损害集中在分型而非检测: 匹配 Dead 的类型正确率 .690 $\rightarrow$.609, 混淆双向增加。但验证折上 Dead 的变化方向恰好相反 (+0.0235): Dead PQ 在折间摆动约 0.05, 这是噪声规则的第三次独立确认。一种解释是: 把真实外观移植进新上下文, 等于教会模型把 “干净基质中的孤立小核” 当作偏向 Dead 的线索, 从而模糊了类型边界。

5.3 上下文内合成 (PixCell): 从外观差距到结构性障碍

PixCell-256 + Cell-ControlNet, 以折 1 真实掩码为条件: 核的放置是忠实的 (约 95% 的掩码对象在正确位置/尺寸渲染, 中位 IoU 0.68), 但 20 $\times$ 生成器在 40 $\times$ PanNuke 上有结构性外观差距 (平色块染色质、高频 -24%、大掩码欠渲染且尺寸偏置)。LoRA 适配 (两轮, r16 与 r8 加快照选择) 反而使所有图像空间指标都变差, 遂放弃该路线; 改用对配对真实 patch 的 Reinhard LAB 迁移来消除颜色差距 (OD-L1 0.072 $\rightarrow$ 0.009)。在锁定配方 (基座 + 配对上下文 + Reinhard) 下,




图 2: Dead 真值核 (绿色) 与预测 (黄色), 青色为图中其它真值; CellViT-UNI 折 3, 每组 4 例。上排 “Dead missed”: 绿色轮廓没有任何黄框对应——完全漏检; 中排 “Dead matched”: 检出; 下排 “other classes missed”: 其它类漏检对照 (远少于 Dead)。漏检的 Dead 是没有前景响应的微小暗色碎片与乏染色质凋亡小体。

32 张图的冒烟测试通过了视觉审查 (颜色与配对真实相差约 3/255), 但审查暴露了一个结构性障碍: ControlNet 条件是二值掩码, 上下文 embedding 不含类别信息, 生成器因此无法表达类别特定的外观——729 个保留对象中没有一个被判为 Dead ($P(\text{Dead}) \leq 0.005$)。若强行使用供体类别标签, 只会原样复现 CP1 的失败 (标签与外观相互矛盾)。因此 SYN1 采用类别无关、教师自洽的标签, 任何效果都只能经由检测环节产生: 1146 张合成图以 50% 混合, 其余与基线配方完全一致。结果 (测试折 3): mPQ 0.4900 vs 基线 0.4951 (3 种子区间 0.4910–0.4951 的底部), Dead 0.1521 vs 0.1424 (约 +1 点, 处于种子噪声边缘; $PQ^+/DQ^+/SQ^+$ 全部持平, 说明这点 Dead 收益来自更好的类型配对而非更好的分割), Inflammatory -1.0 – 1.6 点。按预注册规则判定: 无效。

5.4 支柱 B 判定

在不重训生成器条件的前提下, Dead/小核检测缺陷无法被现有的数据侧手段修复: 真实外观移植 (CP1) 反而损害 Dead 分型, 标签自洽的上下文内合成 (SYN1) 无效。连同支柱 A 的三项无效结果 (重分类、找回、损失重加权), 所有证据都指向同一结论: 该缺陷为我们测试的全部三种稠密解码器架构所共有 (§4.5); 检测优先家族能否逃脱仍属未知 (§8)。

表 4: 零样本跨域 (3-split 均值, 无 TTA)。域内 mPQ: CellViT 0.4995、HoVer-Net 0.4564、HoVer-NeXt-T 0.4579。

模型	数据集	mPQ	bPQ	F_d
CellViT-UNI	CoNIC	.3351 $\pm$.0037	.5314	.7816
	MoNuSAC	.2495 $\pm$.0218	.5616	.7652
	PUMA	.4518 $\pm$.0031	.7177	.8831
HoVer-Net	CoNIC	.2610 $\pm$.0061	.5136	.7669
	MoNuSAC	.0370 $\pm$.0003	.2756	.3658
	PUMA	.3203 $\pm$.0139	.7136	.8714
HoVer-NeXt-T	CoNIC	.2786	.4811	.725
	MoNuSAC	.1123	.4025	.628
	PUMA	.3813	.6888	.848

6 支柱 C: 跨域与反事实评测

6.1 真实跨域零样本评测: 3 架构 $\times$ 3 数据集

外部数据集 (已转换并通过拼接图审查): **CoNIC** (19,476 tiles; 剔除 112 张源自 PanNuke 的 patch; $20\times \rightarrow 2\times$ 上采样; 类 Inflam/Epith/Conn)、**MoNuSAC** test (443 tiles; Inflam/Epith)、**PUMA** 黑色素瘤 (3,278 tiles; PanNuke 5 类齐全, 含 1,991 个凋亡 $\rightarrow$ Dead 核——我们找到的唯一较大外部 Dead 来源; GT 由 HoVer-Net 初始化、病理学家校正, 绝对召回有上限, 但这一上限对所有模型一视同仁)。

表 4 显示, 所有模型都出现退化, 但方式各不相同。HoVer-Net 在 MoNuSAC 上几乎崩溃 (F_d 0.37; 各 split 0.26–0.50), 是典型的检测失败。在 PUMA 上, 没有模型出现检测崩溃 (F_d 0.85–0.88), 退化发生在分型 (HoVer-NeXt-T strict mPQ 0.31 vs mPQ 0.38); 而且尽管 PUMA 有 1,991 个凋亡真值核, 三架构的平均 Dead PQ 分别跌至 **0.002 (CellViT-UNI)**、**0.005 (HoVer-NeXt-T)** 与 **0.033 (HoVer-Net)** (域内依次为 0.176、0.136、0.127) ——Dead 的失效模式随模型一同跨域。TTA 也无助于迁移 (CoNIC +0.005, MoNuSAC -0.001)。真实跨域降幅 (域内 mPQ 减外部均值) 给出的架构排序为 CellViT 0.154 < HoVer-NeXt-T 0.199 < HoVer-Net 0.246, 且在每个数据集上都一致。

6.2 PanNuke-CF: 标签固定的反事实渲染

PanNuke-CF 由 500 张折 3 patch 组成: *GT* 标签固定, 由冻结的生成器在因子化外观干预下重渲染——上下文 {配对, 换组织} $\times$ Reinhard 目标 {自身, donor}——得到 control/stain/ctx/tissue 四臂, 外加未经改动的 **real** 原图与 3 个生成器种子的 control 重复 (作为噪声底)。生成器噪声比下述效应小一个数量级 (control 重复 mPQ std 0.002–0.006)。两个用于标定的观察: 生成的 control 图像比真实图更容易分割 (bPQ 0.78 vs 0.67), 但其外观与类型标签不一致 (strict mPQ 0.36 vs 0.45) ——因此 CF 的比较一律在干预臂与 control 之间进行, 绝不直接对比 real; 空白 patch 必须剔除 (上下文 embedding 本身就是内容通道)。

上下文交换是强压力源 (Epithelial PQ 跌至 0.23–0.43, 而 F_d 只降 0.08–0.10——被破坏的是类型信息), 染色则是弱压力源。我们要检验的问题是: 一个评估器在这些反事实臂上的降幅, 能否预测它真实的跨域降幅。

表 5: PanNuke-CF, 架构在 2 个 split 上的均值 (mPQ; 括号为相对 control 均值的配对 Δ , 图像 bootstrap 95% CI 除 HoVer-NeXt-T stain 外均不含 0)。

架构	real	control	stain	ctx	tissue
CellViT-UNI	.495	.449	.426 [−.023]	.259 [−.190]	.258 [−.191]
HoVer-Net	.449	.440	.373 [−.066]	.300 [−.140]	.293 [−.146]
HoVer-NeXt-T	.456	.425	.417 [−.008]	.262 [−.163]	.260 [−.164]

表 6: 轴分解 (架构均值): 每个降幅拆为检测 (F_d) 与分型 (bPQ−mPQ 间隙增量)。架构间的真实迁移差异位于检测轴, 而 CF 压力在检测轴上的影响对各架构几乎持平。

架构	真实 (域内 − 外部)			CF ctx (control − ctx)		
	mPQ	F_d	分型	mPQ	F_d	分型
CellViT-UNI	.154	.007	+0.088	.190	.102	+0.082
HoVer-Net	.246	.163	+0.069	.140	.084	+0.034
HoVer-NeXt-T	.199	.045	+0.085	.163	.090	+0.064

轴匹配 rank agreement (全部 6 点 / 架构均值):
mPQ: −0.89 ($p=.033$) / −1.00; 检测 F_d : −0.83 ($p=.058$) / −1.00; 分型: +0.71 / **+1.00**。

6.3 有效性: 反事实压力反转真实排序

在 6 个评估点 (3 架构 $\times$ 2 splits) 上, 将 CF 降幅与真实跨域降幅做相关: Spearman $\rho = -0.89$ (ctx, 精确置换 $p = 0.033$), tissue −0.89, stain +0.43 不显著。在架构均值上 (这是更公平也更严格的检验——同一架构的两个 split 近乎重复), ctx 与 tissue 都给出 $\rho = -1.00$: 完全倒置——域内受上下文交换损害最重的模型 (CellViT) 是真实迁移中最鲁棒的, 反之亦然。

表 6 给出了机理。架构间的真实迁移差异集中在检测轴 (CellViT 的 F_d 损失 0.007; HoVer-Net 0.163——其 MoNuSAC 崩溃), 分型间隙增量则彼此接近 (0.07–0.09)。但标签固定的渲染无法对检测施压: 生成器在固定位置重渲染形态完好的核, CF 的 F_d 降幅因此在架构间齐平 (0.08–0.10), 不携带排序信息。在 CF 能施压的地方——上下文/染色错配下的分型——其排序与真实分型迁移一致 (架构均值 $\rho = +1.00$; 全部 6 点 +0.71/+0.83)。必须指出的局限: $n = 3$ 个架构 (架构均值 $|\rho| = 1$ 对应的精确 $p = 1/3$; 更有力的证据是 3 架构 $\times$ 2 splits 的完全符号倒置加上轴分解机理), 且架构间真实分型差异 (区间 0.069–0.088) 远小于检测差异 (0.007–0.163)。

判定。 PanNuke-CF 是有效的分型压力测试: 它对各架构分型鲁棒性的排序与真实迁移一致。但它不是迁移代理——若当作代理使用, 排序会被反转, 因为它的盲区 (检测) 恰恰是真实迁移差异所在。仅干预外观的反事实天然带有这一构造性限制; 要探测检测鲁棒性, 需要对布局 (密度、杂乱、伪影) 的干预, 而非外观。

7 讨论

为什么三个支柱都以负结果收场。 三个支柱共享一个隐含假设——Dead 性能受限于信息 (语言先验) 或数据 (合成样本), 而非检测架构。诊断结果恰恰相反: 前景头在 83% 的漏检 Dead 核上不触发 (仅在 17% 的核中有响应), 类型分支却已经“看见”它们; 语言侧融合、后处理找回、损失重加权 (3 种子)、真实外观移植、标签自洽的上下文内合成都未能撼动检测。事后对比表明该缺陷并非 ViT token 分辨率所特有——全分辨率 ResNet-50 与 ConvNeXt 解码器的尺寸-漏检曲线与 ViT-L/16 几乎重合, <60 px 真值核的 62% 被三者一致漏检——真正尚未检验的是检测优先家族 (点/质心提示器、逐类质心热图): 其论文自报的 Dead F1 (.46–.59; 严格解码下我们的三种

为.23–.36) 从未在验证折调参的解码下复现, 更未转化为 Dead PQ。对这些已发布按折权重的严格重评, 加上直接的 $2\times$ 输入分辨率消融, 是主要的开放方向。

评测方法论。 五条教训, 每一条都有证据支撑: (1) PanNuke 的种子噪声依赖类别 (mPQ 0.002 vs Dead 0.007), 且验证折的 Dead 信号可能与测试相反 (CP1: $+0.024$ vs -0.031) ——单种子、单折的 Dead 结论不可信; (2) 已发布的评测配方可能内嵌相当于约 0.02 mPQ 的测试侧调参收益 (我们的 HoVer-NeXt-T 解码研究), 比排行榜上的典型名次差距还大; (3) 生成的评测数据系统性地更易分割但类型一致性更差, 因此反事实基准必须以干预臂对 control 的方式评分, 并同时报告 strict mPQ 与 mPQ; (4) 官方逐类 PQ 是图子集指标——Dead 只在含 Dead 的图上平均 (折 3/1 分别为 97/65 张), 其中折 3 的 34 张 Uterus 图在所有模型上都只有 .01–.05, Dead PQ 必须同时报告剔除 Uterus 的版本; (5) $<60\text{px}$ 真值核的 89% 贴图块边界、贴边对象占全部假阴性的 57%, 小核结论必须按是否贴边分层。

Dead 作为跨域现象。 尽管 Dead 是 CONCH 文本上最可识别的类, 也是域内模型检出后能以 0.69 正确分类的类, 三架构在 PUMA 上的 Dead PQ 却跌至 0.002–0.033 (域内 0.13–0.19) ——这说明域内的 Dead 线索 ($40\times$ 下的深色固缩染色质) 迁移不到黑色素瘤 H&E 中的凋亡小体。任何针对 Dead 的改进都必须经过跨域验证, 而不能只在 PanNuke 折上验证。

8 状态与后续工作

所有预注册实验已完成: 基线复现 (课程要求 (a)(b)) 与错误分解、类 $\times$ 组织分析 (课程要求 (c)) 均已完成; 支柱 A/B 以负结果收官, 支柱 C 以一个机理性的评测结果收官。最终报告还需要: 三架构的组织 $\times$ 类热力图与错误分解图、一套精简的主表、可选的额外外部集 (MoNuSeg、NuInsSeg; 仅 bPQ/AJI), 以及文字润色。阶段二方向 (2026-09-28 确定, 未预先注册): (A) 用本协议严格重评已发布的检测优先按折权重 (PromptNucSeg、LKCell、CellVTA、KongNet), 并采用上述对伪影更稳健的 Dead 报告口径; (B) 以 $2\times$ 输入分辨率/检测优先路线作为方法主攻; (C) 更大的无泄漏训练数据 (STHELAR、手工实例集、外部 Dead 标签池化) 与分子 (虚拟 caspase-3) 试点。

参考文献

- [1] J. Gamper, N. Alemi Koohbanani, K. Benet, A. Khuram, N. Rajpoot, “PanNuke: An Open Pan-Cancer Histology Dataset for Nuclei Instance Segmentation and Classification,” *ECDP*, LNCS 11435, pp. 11–19, 2019; and J. Gamper et al., “PanNuke Dataset Extension, Insights and Baselines,” arXiv:2003.10778, 2020.
- [2] S. Graham, Q. D. Vu, S. E. A. Raza, A. Azam, Y.-W. Tsang, J. Kwak, N. Rajpoot, “HoVer-Net: Simultaneous Segmentation and Classification of Nuclei in Multi-Tissue Histology Images,” *Medical Image Analysis*, 58:101563, 2019.
- [3] F. Hörst, M. Rempe, L. Heine, J. Kleesiek, “CellViT: Vision Transformers for Precise Cell Segmentation and Classification,” *Medical Image Analysis*, 94:103143, 2024.
- [4] F. Hörst, M. Rempe, H. Becker, L. Heine, J. Keyl, J. Kleesiek, “CellViT++: Energy-Efficient and Adaptive Cell Segmentation and Classification Using Foundation Models,” *Computer Methods and Programs in Biomedicine*, 277:109206, 2026.
- [5] E. Baumann, B. Dislich, J. L. Rumberger, I. D. Nagtegaal, M. Rodríguez Martínez, I. Zlobec, “HoVer-NeXt: A Fast Nuclei Segmentation and Classification Pipeline for Next Generation Histopathology,” *MIDL*, PMLR 250:61–86, 2024.

- [6] S. Chen, C. Ding, M. Liu, J. Cheng, D. Tao, “CPP-Net: A Unified Framework for Nuclei Instance Segmentation and Classification,” *IEEE Transactions on Image Processing*, 32:980–994, 2023.
- [7] Z. Shui, Y. Zhang, K. Yao, C. Zhu, S. Zheng, J. Li, H. Li, Y. Sun, R. Guo, L. Yang, “Unleashing the Power of Prompt-Driven Nucleus Instance Segmentation (PromptNucSeg),” *ECCV*, LNCS 15085, pp. 288–304, 2024.
- [8] M. Y. Lu et al., “A Visual-Language Foundation Model for Computational Pathology (CONCH),” *Nature Medicine*, 30:863–874, 2024.
- [9] V. Vadori, A. Peruffo, J.-M. Graïc, L. Finos, E. Grisan, “Mind the Gap: Evaluating Patch Embeddings from General-Purpose and Histopathology Foundation Models for Cell Segmentation and Classification,” arXiv:2502.02471, 2025.
- [10] S. Yellapragada et al., “PixCell: A Generative Foundation Model for Digital Histopathology Images,” arXiv:2506.05127, 2025.
- [11] J. Wang, J. T. Kwak, “NucleiMix: Realistic Data Augmentation for Nuclei Instance Segmentation,” arXiv:2410.16671, 2024.
- [12] M. Stammel, F. De Sousa Ribeiro, R. Mehta, M. Roschewitz, B. Glocker, “Counterfactual Stress Testing for Image Classification Models,” MICCAI workshop (FAIMI), arXiv:2605.10894, 2026.




图 3: SYN-v2 合成样例 (真实 | 生成 | 标签): 配对上下文 + Reinhard 下外观能通过审查, 但二值掩码条件使生成器无法表达类别定向的外观 (没有生成对象可读作 Dead)。




图 4: 各架构的 Dead PQ: 域内 (PanNuke, 3-split 均值) 与 PUMA 零样本跨域对比。该类随模型跨域几乎归零 (0.002–0.033, 域内为 0.127–0.176)。




图 5: 左: PanNuke-CF 各臂 (同一折 3 GT 标签在上下文/染色干预下重渲染)。右: PUMA 真值 (类别着色; 黑轮廓 = 凋亡 Dead), 提供跨域 Dead 标签的外部集。




图 6: 轴分解 (架构均值; 表 6): 真实迁移的架构差异集中在检测轴 (左图 F_d 降幅), 而 CF 上下文交换压力对检测的影响在架构间齐平、只对分型轴携带排序信息 (右图)。