

AI 看病理切片，为什么“看不见”将死的细胞？

——阶段报告一导读（课程项目 bdd26）

2026 年 9 月 28 日

背景：让 AI 帮医生看切片

医生诊断肿瘤，经常需要在显微镜下观察染色的组织切片，逐个找出细胞核并判断其类型。这项工作费时费力，因此研究者训练 AI 来完成：输入一张 40 倍放大的数字切片图像，AI 需要勾出每个细胞核的轮廓，并判断它属于哪一类。

为了衡量 AI 的优劣，学界有一份公开的“标准考卷”——PanNuke 数据集：约 20 万个人工标注的细胞核，来自 19 种人体组织，分成五大类（肿瘤细胞、炎症细胞、结缔组织细胞、非肿瘤的上皮细胞，以及一类特殊的“凋亡核”——细胞死亡后留下的皱缩、碎裂、深染的残迹）。凋亡核值得单独关注：有效的抗癌治疗往往伴随大量细胞死亡，凋亡核的多少对判断肿瘤状态和疗效有参考价值。

该基准按 0 到 1 打分，分数同时要求“找得准”（轮廓对得上）与“认得对”（类型不判错）。

发现一：更强的模型提升有限，凋亡核是各类模型的共同短板

近五年新模型层出不穷，但整个领域在这份基准上的最好成绩也只从约 0.46 提高到 0.51——而后文会看到，仅评测配方的宽松之处就可能贡献约 2 个百分点，实际的进步比排行榜显示的更小。更突出的是凋亡核：近五年所有已发表模型在这一类别上的得分都停留在 0.13–0.19，而其它类型的细胞核一般在 0.4 以上。

发现二：问题不是“认错”，而是根本“看不见”

我们对复现模型的错误做了逐项分解（通行判定标准：预测轮廓与人工标注重叠过半才算检出）：38.5% 的凋亡核在模型预测中完全不存在——并非被误判为其它类型，而是根本没有被检出；作为对比，其它类型的完全漏检率只有 8–15%（图 1）。

进一步检查漏检区域上模型两个部件的输出：负责“找细胞”的部件几乎没有响应（平均概率仅 0.16，只在 17% 的核上有反应），而负责“辨类型”的部件却给出约 26% 的凋亡概率（其它类型仅约 1%）。也就是说，问题出在“眼睛”（检测），不在“脑子”（分类）。此外，检出的凋亡核中仍有约三成类型判错、约一成被并入相邻核的轮廓——即使不计漏检，得分也难以提高。

发现三：五种补救办法，在事先约定的标准下全部无效

1. 用病理“图文大模型”（见过大量病理图片和医学文字描述的 AI）重新判型——无效。这一条与下一条是最先尝试的：当时以为问题出在“认错类型”上，正是它们的失败促使我们转而统计漏检；




图 1: 五类细胞核的错误分解 (CellViT-UNI, 折 3)。蓝色“检出”指预测轮廓与人工标注重叠过半; 橙色“完全漏检”指模型预测中没有这个核。凋亡核 (Dead) 一行有 38% 完全漏检, 是其它类的 3-5 倍。

2. 在模型输出的概率图上调整判定门槛、挖掘被抑制的小响应, 试图召回漏检的核——无效;
3. 训练时提高凋亡核与“小核”的损失权重 (凋亡核的尺寸往往只有普通核的约三分之一) ——无效;
4. 把真实的凋亡核粘贴进训练图的无核区域——不仅无效, 反而使凋亡核得分更差: 模型把“无核区域出现的小核”当成了凋亡的标志, 扰乱了类型边界;
5. 用图像生成 AI 参照标注“凭空绘制”新的训练图——无效。这条路先暴露了一个更根本的问题: 生成器只接收“在这个位置画一个核”的指令, 并不知道哪个核应当是凋亡核, 结果画出的孤立小核外观都接近普通淋巴核——七百多个生成的核中, 能被认定为凋亡核的数量是零。若强行给这些“外观不像凋亡”的核打上凋亡标签, 就会重蹈第 4 种方法的覆辙 (标签与外观不符)。退而求其次, 按生成图的实际外观标注后再训练, 整体得分仍在噪声范围内, 凋亡核的变化也在噪声边缘——合成图能补充的只是“更多小核”, 弥补不了真正缺失的“在真实切片中识别出凋亡核”的能力。

这些阴性结果仍有价值。每种方法都在 3 个随机种子上重复训练, 并事先写明成功判定标准, 小于噪声的差异一律不视为有效 (同一模型仅更换随机种子重训, 整体得分即会波动约 ± 0.2 个百分点, 凋亡核甚至会波动约 ± 0.7 个百分点)。小核本来就难检出——各类皆然; 但凋亡核即使尺寸不小也常被漏掉 (大凋亡核的漏检率是其它大核的 6 倍), 说明还存在“外观不像核”的问题: 很多凋亡核只是淡染的碎屑, 没有深染的核。这些证据共同指向一个结论: 这一缺陷为我们测试的全部三种“稠密解码器”架构所共有, 换数据、换训练技巧都无法弥补; 另一类“先找点、再抠轮廓”的检测优先架构尚未在同等严格的条件下检验过。

两个后续核查进一步校准了上述数字。其一, 各类型普遍存在的“小核漏检”大多是图块边界切开的核碎片: 256 像素图块内小于 60 像素的真值核有 89% 贴着图块边界; 真正位于图块内部的核, 除凋亡核 (漏检率 31%) 外, 其它类型的漏检率仅 3%-10%。其二, 凋亡核的官方得分只由极少数图片决定: 测试折 3 中仅 97 张图含有凋亡核, 其中 34 张来自子宫组织且各模型得分接近零




图 2: 模型检测核的示例 (CellViT-UNI, 折 3; 每组 4 个视野): 绿色为人工标注的目标核, 黄色为模型预测的核, 青色为图中其它标注。上排 “Dead missed”: 凋亡核的绿色轮廓没有任何黄框对应——模型完全未检出 (407 个); 中排 “Dead matched”: 被正常检出的凋亡核 (绿黄重合); 下排 “other classes missed”: 其它类型漏检的对照——漏检率仅为凋亡核的约 1/3 到 1/5。

(其凋亡核多为腺腔内淡染的脱落细胞团); 剔除这些图后, 模型在三个测试折上的凋亡核得分为 0.195/0.227/0.231 (官方口径 0.142/0.162/0.224)。因此, 不同测试折之间的凋亡核分数差异主要反映图片组成, 而非模型能力。

此外, 当把模型拿到一套公开的黑色素瘤 (一种皮肤癌) 数据上测试时, 其它类型的细胞仍能正常检出, 唯独凋亡核的得分几乎归零 (图 3) ——这一短板会随模型迁移。(需要说明: 凋亡核的人工标注本身存在少量模糊之处, 该类别本身的难度也高于其它类型。)

发现四：一种新式评测会把模型的真实排名几乎颠倒

我们还尝试了一种流行的新思路: 用生成式 AI 把基准图像重新渲染一遍——每个细胞的位置和标准答案都不变, 只改变画面外观 (例如背景换成其它组织、染色换成其它实验室的方案), 用以模拟 “模型在新医院、新病种数据上的表现”。结果发现, 这种 “只换外观、不换内容” 的评测会把排名几乎完全颠倒: 在真实跨病种测试 (即上述黑色素瘤等外部数据) 中最稳健的模型, 在这种评测中反而显得最脆弱。

原因有两层。第一, 模型之间的真实差距主要在 “找细胞” 的能力上, 而这种评测中 “细胞位置不变”, 恰恰测不到 “找细胞”; 第二, 它实际测量的是 “背景变化后还能否识别类型” ——而这几种模型的两项能力恰好此消彼长, 按后者排名, 恰好将前者的名次颠倒。结论: 这种评测只适用




图 3: 三种模型的凋亡核 (Dead) 得分: 域内测试 (PanNuke) 与跨域测试 (黑色素瘤数据 PUMA)。跨域时所有模型的凋亡核得分都接近 0。

于考察“认类型”，不能当作跨病种能力的替代。

本文是《阶段报告一》的导读；完整的数字、表格与文献见同目录下的正式报告（中文版 `stage_report_1_zh.pdf`，英文版 `stage_report_1.pdf`）。




图 4: 同一张基准图像在“换背景/换染色”干预下重新生成的结果: 红色轮廓是固定不变的标准答案, 细胞位置不变, 仅画面外观改变。