

AI 看病理切片，为什么“看不见”将死的细胞？

——阶段报告一导读（课程项目 bdd26）

2026 年 9 月 28 日

2026 年 10 月 2 日：结论范围更正

本文保留 9 月 28 日的实验结果作为历史记录。以下说明优先于原正文中较宽泛的解释。负结果只针对已经测试的损失、复制粘贴与生成配置，不能推出所有数据方法都无效；多种子证据只适用于实际包含重复训练的实验，并非每项列出的干预。固定标签本身不妨碍施加检测压力，失败的是当前反事实生成器对真实跨域排序的代理作用。相关性比较只有三个独立架构家族，不是六个；架构均值的精确置换检验为 $p = 0.333$ ，不能把六点评估解释为强独立架构证据。

代码中的 `missed_bg` 指最大 IoU 小于 0.1，不一定完全没有重叠。 mPQ^+ 仍与类别有关， F_c 同时受到检测和类型错误影响。发布的验证集最优权重与我们自训模型的最后检查点，不是完全相同的选点协议。后续审计及 P0-P3 实验（v2，包含合并前发现的共享边界累加与官方 GT 通道修正）详见仓库 docs 目录的 `P0_P3_RESULTS_2026-10-02.md`；检测是所研究基线的重要瓶颈，不代表类型预测对后续改进无关紧要。

背景：让 AI 帮医生看切片

医生诊断肿瘤，经常需要在显微镜下观察染色的组织切片，逐个找出细胞核并判断其类型。这项工作费时费力，因此研究者训练 AI 来完成：输入一张 40 倍放大的数字切片图像，AI 需要勾出每个细胞核的轮廓，并判断它属于哪一类。

为了衡量 AI 的优劣，学界有一份公开的“标准考卷”——PanNuke 数据集：约 20 万个人工标注的细胞核，来自 19 种人体组织，分成五大类（肿瘤细胞、炎症细胞、结缔组织细胞、非肿瘤的上皮细胞，以及一类特殊的“凋亡核”——细胞死亡后留下的皱缩、碎裂、深染的残迹）。凋亡核值得单独关注：有效的抗癌治疗往往伴随大量细胞死亡，凋亡核的多少对判断肿瘤状态和疗效有参考价值。

该基准按 0 到 1 打分，分数同时要求“找得准”（轮廓对得上）与“认得对”（类型不判错）。

发现一：更强的模型提升有限，凋亡核是各类模型的共同短板

近五年新模型层出不穷，但整个领域在这份基准上的最好成绩也只从约 0.46 提高到 0.51——而后文会看到，仅评测配方的宽松之处就可能贡献约 2 个百分点，实际的进步比排行榜显示的更小。更突出的是凋亡核：近五年所有已发表模型在这一类别上的得分都停留在 0.13–0.19，而其它类型的细胞核一般在 0.4 以上。

发现二：问题不是“认错”，而是根本“看不见”

我们对复现模型的错误做了逐项分解（通行判定标准：预测轮廓与人工标注重叠过半才算检出）：38.5% 的凋亡核在模型预测中完全不存在——并非被误判为其它类型，而是根本没有被检出；作为对比，其它类型的完全漏检率只有 8–15%（图 1）。




图 1: 五类细胞核的错误分解 (CellViT-UNI, 折 3)。蓝色“检出”指预测轮廓与人工标注重叠过半；橙色“完全漏检”指模型预测中没有这个核。凋亡核 (Dead) 一行有 38% 完全漏检，是其它类的 3–5 倍。

进一步检查漏检区域上模型两个部件的输出：负责“找细胞”的部件几乎没有响应（平均概率仅 0.16，只在 17% 的核上有反应），而负责“辨类型”的部件却给出约 26% 的凋亡概率（其它类型仅约 1%）。也就是说，问题出在“眼睛”（检测），不在“脑子”（分类）。此外，检出的凋亡核中仍有约三成类型判错、约一成被并入相邻核的轮廓——即使不计漏检，得分也难以提高。




图 2: 模型检测核的示例 (CellViT-UNI, 折 3; 每组 4 个视野): 绿色为人工标注的目标核, 黄色为模型预测的核, 青色为图中其它标注。上排 “Dead missed”: 凋亡核的绿色轮廓没有任何黄框对应——模型完全未检出 (407 个); 中排 “Dead matched”: 被正常检出的凋亡核 (绿黄重合); 下排 “other classes missed”: 其它类型漏检的对照——漏检率仅为凋亡核的约 1/3 到 1/5。

发现三：五种补救办法，在事先约定的标准下全部无效

1. 用病理“图文大模型”（见过大量病理图片和医学文字描述的 AI）重新判型——无效。这一条与下一条是最先尝试的：当时以为问题出在“认错类型”上，正是它们的失败促使我们转而统计漏检；
2. 在模型输出的概率图上调整判定门槛、挖掘被抑制的小响应，试图召回漏检的核——无效；
3. 训练时提高凋亡核与“小核”的损失权重（凋亡核的尺寸往往只有普通核的约三分之一）——无效；
4. 把真实的凋亡核粘贴进训练图的无核区域——不仅无效，反而使凋亡核得分更差：模型把“无核区域出现的小核”当成了凋亡的标志，扰乱了类型边界；

5. 用图像生成 AI 参照标注“凭空绘制”新的训练图——无效。这条路先暴露了一个更根本的问题：生成器只接收“在这个位置画一个核”的指令，并不知道哪个核应当是凋亡核，结果画出的孤立小核外观都接近普通淋巴核——七百多个生成的核中，能被认定为凋亡核的数量是零。若强行给这些“外观不像凋亡”的核打上凋亡标签，就会重蹈第 4 种方法的覆辙（标签与外观不符）。退而求其次，按生成图的实际外观标注后再训练，整体得分仍在噪声范围内，凋亡核的变化也在噪声边缘——合成图能补充的只是“更多小核”，弥补不了真正缺失的“在真实切片中识别出凋亡核”的能力。

这些阴性结果仍有价值。每种方法都在 3 个随机种子上重复训练，并事先写明成功判定标准，小于噪声的差异一律不视为有效（同一模型仅更换随机种子重训，整体得分即会波动约 ± 0.2 个百分点，凋亡核甚至会波动约 ± 0.7 个百分点）。小核本来就难检出——各类皆然；但凋亡核即使尺寸不小也常被漏掉（大凋亡核的漏检率是其它大核的 6 倍），说明还存在“外观不像核”的问题：很多凋亡核只是淡染的碎屑，没有深染的核。这些证据共同指向一个结论：这一缺陷为我们测试的全部三种“稠密解码器”架构所共有，换数据、换训练技巧都无法弥补；另一类“先找点、再抠轮廓”的检测优先架构尚未在同等严格的条件下检验过。

两个后续核查进一步校准了上述数字。其一，各类型普遍存在的“小核漏检”大多是图块边界切开的核碎片：256 像素图块内小于 60 像素的真值核有 89% 贴着图块边界；真正位于图块内部的核，除凋亡核（漏检率 31%）外，其它类型的漏检率仅 3%–10%。其二，凋亡核的官方得分只由极少数图片决定：测试折 3 中仅 97 张图含有凋亡核，其中 34 张来自子宫组织且各模型得分接近零（其凋亡核多为腺腔内淡染的脱落细胞团）；剔除这些图后，模型在三个测试折上的凋亡核得分为 0.195/0.227/0.231（官方口径 0.142/0.162/0.224）。因此，不同测试折之间的凋亡核分数差异主要反映图片组成，而非模型能力。

此外，当把模型拿到一套公开的黑色素瘤（一种皮肤癌）数据上测试时，其它类型的细胞仍能正常检出，唯独凋亡核的得分几乎归零（图 3）——这一短板会随模型迁移。（需要说明：凋亡核的人工标注本身存在少量模糊之处，该类别本身的难度也高于其它类型。）




图 3: 三种模型的凋亡核 (Dead) 得分：域内测试 (PanNuke) 与跨域测试 (黑色素瘤数据 PUMA)。跨域时所有模型的凋亡核得分都接近 0。

发现四：一种新式评测会把模型的真实排名几乎颠倒

我们还尝试了一种流行的新思路：用生成式 AI 把基准图像重新渲染一遍——每个细胞的位置和标准答案都不变，只改变画面外观（例如背景换成其它组织、染色换成其它实验室的方案），用以模拟“模型在新医院、新病种数据上的表现”。结果发现，这种“只换外观、不换内容”的评测会把排名几乎完全颠倒：在真实跨病种测试（即上述黑色素瘤等外部数据）中最稳健的模型，在这种评测中反而显得最脆弱。

原因有两层。第一，模型之间的真实差距主要在“找细胞”的能力上，而这种评测中“细胞位置不变”，恰恰测不到“找细胞”；第二，它实际测量的是“背景变化后还能否识别类型”——而这几种模型的两项能力恰好此消彼长，按后者排名，恰好将前者的名次颠倒。结论：这种评测只适用于考察“认类型”，不能当作跨病种能力的替代。

本文是《阶段报告一》的导读；完整的数字、表格与文献见同目录下的正式报告（中文版 `stage_report_1_zh.pdf`，英文版 `stage_report_1.pdf`）。




图 4: 同一张基准图像在“换背景/换染色”干预下重新生成的结果: 红色轮廓是固定不变的标准答案, 细胞位置不变, 仅画面外观改变。