

AI 看病理切片，为什么“看不见”将死的细胞？

——阶段报告一导读（课程项目 bdd26）

2026 年 9 月 28 日

一句话总结：我们研究了 AI 在显微镜图像里找细胞核、认细胞类型的能力，为一个公认的长期短板找到了贯穿所有实验的解释——不是“认错”，而是“看不见”；试了五种补救方法，在事先约定的判定标准下都无效；还发现一种新式“考试”方法会把模型的真实排名几乎完全考反。

背景：让 AI 帮医生看切片

医生诊断肿瘤，经常要在显微镜下看染色的组织切片，逐个找出细胞核并判断它是哪一种细胞。这件事费时费力，于是研究者训练 AI 来做：给它一张 40 倍放大的数字切片照片，它要把每个细胞核的轮廓勾出来，并说出它属于哪一类。

为了比较 AI 的好坏，学界有一份公开的“标准考卷”——PanNuke 数据集：约 20 万个人工标注的细胞核，来自 19 种人体组织，分成五大类（肿瘤细胞、炎症细胞、结缔组织细胞、非肿瘤的上皮细胞，以及一类特殊的“凋亡核”——细胞死亡后留下的皱缩、碎裂、深染的残迹）。凋亡核值得单独关注：有效的抗癌治疗往往伴随大量细胞死亡，凋亡核的多少对判断肿瘤状态和疗效有参考价值。

考卷按 0 到 1 打分。这个分数同时要求“找得准”（轮廓对得上）和“认得对”（类型不判错），两项都好才能得高分。

发现一：换更强的模型几乎不涨分，但有一类细胞谁都认不好

近五年新模型层出不穷，整个领域在这份考卷上的最好成绩也只从约 0.46 提高到 0.51——而后文会看到，光评测配方里的“水分”就可能值 2 个百分点，真正的进步比排行榜显示的还要小。更扎眼的是凋亡核：近五年所有已发表模型在这一类上的得分都卡在 0.13–0.18，而其它类型的细胞核一般在 0.4 以上。

发现二：问题不是“认错”，而是根本“看不见”

我们把复现模型的错误逐个拆开（用通行判定标准：预测轮廓与人工标注重叠过半才算检出）：38.5% 的凋亡核，模型给出的答案里根本没有它——不是把它认成了别的类型，而是压根没把它当成细胞；作为对比，其它类型完全漏检的只有 8–15%（图 1）。

更有意思的是，我们直接到漏检位置的图像区域去读模型两个部件的输出：负责“找细胞”的部件几乎全静默（平均概率只有 0.16，仅在 17% 的核里有反应），而负责“辨类型”的部件却给出约 26% 的凋亡概率（其它类型只有约 1%）。一句话，问题出在“眼睛”（检测），不在“脑子”（分类）。顺带一提，检出来的凋亡核里也有约三成类型判错、约一成被并进旁边核的轮廓——所以就算不算漏检，分数也上不去。




图 1: 五类细胞核的错误分解 (CellViT-UNI, 折 3)。蓝色“检出”指预测轮廓与人工标注重叠过半; 橙色“完全漏检”指模型答案里根本没有这个核。凋亡核 (Dead) 一行有 38% 完全漏检, 是其它类的 3-5 倍。

发现三：五种补救办法，在事先约定的标准下全部无效

1. 请病理“图文大模型”（见过大量病理图片和医学文字描述的 AI）帮忙重新判型——无效。这一条与下一条是最先试的：当时以为问题出在“认错类型”上，正是它们的失败促使我们去数漏检；
2. 在模型输出的概率图上调整判定门槛、翻找被埋没的小块，把漏掉的核“捞回来”——无效；
3. 训练时给凋亡核和“小核”加大权重（凋亡核的个头往往只有普通核的约三分之一）——无效；
4. 把真实的凋亡核“复制粘贴”进训练图的空白处——不仅无效，反而让凋亡核分得更差：模型把“空白处冒出的小核”当成了凋亡的标志，反而搞乱了类型边界；
5. 用图像生成 AI 照着标注“凭空画”新的训练图——无效。这条路先暴露了一个更根本的问题：生成器只接收“在这个位置画一个核”的指令，并不真正知道哪个核该是凋亡核，结果它画出来的孤立小核全都长得像普通淋巴核——七百多个生成的核里，能被认出是凋亡核的数量是零。若强行给这些“不像凋亡”的核打上凋亡标签，就又落回第 4 种方法的坑（标签与外观不符）。退而求其次、按生成图的实际长相来标注再训练，整体分数仍停在噪声范围内，凋亡核的变化也在噪声边缘——因为合成图能补的只是“多见些小核”，补不了真正缺的“在真实切片里看见凋亡核”的能力。

这些失败不是白做。每种方法都在 3 个随机种子上重复训练、事先写明“怎样才算成功”，小于噪声的差异一律不算数（同一模型换个随机种子重训，整体分自己就会波动约 ± 0.2 个百分点，凋亡核甚至会波动约 ± 0.7 个百分点）。小核本来就难检出——各类皆然；但凋亡核即使个头不小也常被漏掉（大个头凋亡核的漏检率是其它大核的 6 倍），说明还有“长得不像核”的外观问题：很多凋亡核只是淡染的碎屑，没有深色的核。这些证据共同指向一个结论：缺陷很可能出在模型的底层架构上，换数据、换训练技巧都救不了。




图 2: 模型找核的示例 (CellViT-UNI, 折 3; 每组 4 个视野): 绿色是人工标注的目标核, 黄色是模型画出的核, 青色是图中其它标注。上排 “Dead missed”: 凋亡核的绿色轮廓没有任何黄框对应——模型完全没看见它们 (407 个); 中排 “Dead matched”: 被正常检出的凋亡核 (绿黄重合); 下排 “other classes missed”: 其它类型漏检的对照——漏检率只有凋亡核的约 1/3 到 1/5。

而且, 当我们把模型拿到一套公开的黑色素瘤 (一种皮肤癌) 数据上考试, 其它类型的细胞仍能正常检出, 唯独凋亡核的成绩几乎归零 (图 3)——这个短板会跟着模型走。(也要说明: 凋亡核的人工标注本身就有少量模糊之处, 这一类天然难上加难。)

发现四: 一种新式 “考试” 会把模型的真实水平考反

我们还尝试了一种流行的新思路: 用生成式 AI 把考卷图片重新 “画” 一遍——每个细胞的位置和标准答案都不变, 只改变画面外观 (比如背景换成别的组织、染色换成别家的)。本意是模拟 “模型到了新医院、新病种的数据上还靠不靠谱”。结果发现, 这种 “换皮不换芯” 的考试会把排名考反 (几乎正好颠倒): 在真实跨病种测试 (就是上面那套黑色素瘤等外部数据) 中最稳的模型, 在这种考试里反而显得最脆弱。

原因有两层。第一, 模型之间的真实差距主要在 “找细胞” 的能力上, 而这种考试里 “细胞位置不变”, 恰恰考不了 “找细胞”; 第二, 它实际考的是 “换了个背景还认不认得出类型”——而这几种模型的两项能力恰好此消彼长, 于是按后者排名, 正好把前者的名次倒了过来。结论: 这种考试只能用来考 “认类型”, 不能当作跨病种能力的替身。




图 3: 三种模型的凋亡核 (Dead) 得分: 域内考试 (PanNuke) vs. 跨域考试 (黑色素瘤数据 PUMA)。跨域时所有模型的凋亡核得分都跌到接近 0。

这份工作留下了什么

- **一个明确的诊断:** 凋亡核识别是检测问题。下一步最值得试的是让“找细胞”的部件在更高分辨率上工作 (例如用更高分辨率的特征图来判断前景) ——这是正式报告指出的开放方向, 尚未验证。
- **一份避坑指南:** 评估 AI 时, 别被单次实验的涨分骗到——先标定噪声有多大 (见上); 看公开排行榜时留心评测配方的“水分”: 有的已发布配方会在测试集上调参数——相当于考前对过答案——加上特殊技巧能白捡约 2 个百分点, 比排行榜上多数名次差距还大; 用生成数据做考试之前, 先想清楚它到底考的是什么。
- **可复现:** 整套代码、数据管线与实验记录都保存在项目仓库里, 每个结论都能逐步复现。

本文是《阶段报告一》的导读; 完整的数字、表格与文献见同目录下的正式报告 (中文版 `stage_report_1_zh.pdf`, 英文版 `stage_report_1.pdf`)。




图 4: 同一张考卷图在“换背景/换染色”干预下重新生成的样子: 红色轮廓是固定不变的标准答案, 细胞位置不变, 画风变了。