

把图像放大一倍，AI 就能看见将死的细胞了吗？

——阶段报告二导读（课程项目 bdd26）

2026 年 10 月 1 日

背景：上一份报告留下了两个猜想

上一阶段的结论（见阶段报告一导读）：AI 在病理切片上找细胞核，最难的一类是**凋亡核**——细胞死亡后留下的皱缩、碎裂、深染的残迹。过去五年发表的模型，在这一类上的得分都停在 0.13–0.19，其它类别一般在 0.4 以上。把错误逐项拆开后我们确认：问题不是“认错”，而是“看不见”——约 38% 的凋亡核完全没有被检出；换数据集、换训练技巧，都无济于事。

当时留下两条没来得及检验的出路。这一阶段做的事，就是把它们一条条验完：

1. **换一种架构**。常见的模型是“先给每个像素打分、再把相邻的像素围成核”（下称“描边派”）。另一派“找点派”先预测每个核的中心点、再围着这些点拼出轮廓——而论文里最亮眼的凋亡核成绩，恰恰出自找点派（一个叫 KongNet 的模型）。
2. **把图像放大**。凋亡核个头小（面积中位数只有普通核的约三分之一），256 像素的工作分辨率下每个核只占十几个像素——也许模型不是不会认，是根本看不清。

按事先约定的严格标准（数据按官方标准分成三份；调参数只许用验证那份；测试那份只评一次；每个结论都用多个随机种子重复），两条猜想的答案现在都有了。

发现一：换“找点派”架构，不仅没更好，反而差了 11 分

KongNet 的作者公开了三份分别训练的模型权重，但没说哪份对应数据的哪个划分。我们先解决了这个问题：把每份权重在数据的三个部分上各测一遍，看它在哪部分“记得最牢”——模型在训练过的数据上成绩会明显偏高，据此就能对号入座，全程不碰测试数据。

之后按严格标准复评：KongNet 的整体得分只有 0.346，比我们测过的“描边派”里最弱的还低 11 分；文献里最亮眼的凋亡核成绩（逐核配对打分的 F_c ，0.59），在我们的口径下只剩 0.34。

失败的方式很能说明问题：**挨在一起的同类核被“粘”成一坨**。互相接触的核，它合并的比例是描边派模型的三四倍——而凋亡核恰恰经常以“碎块群”的形态出现（核碎裂，karyorrhexis）。也就是说，凋亡核的困难一半在“找不到”，另一半在“找到了却分不开”，而找点派的组装方式把“分不开”变得更糟。结论：这不是架构流派能解决的问题。

发现二：另一个更强的模型，也兑不出凋亡核的收益

我们又复评了 LKCell-L——在我们能拿到公开权重的模型里，它整体成绩最好（论文 0.508）。两个发现：

- 它的各项指标都比论文低约 1.5 分，**一项不多、一项不少**。这种“整体平移”说明差异来自评测流程（选哪个存档点、怎么调后处理），不是我们测错了。

- 在同等条件下，它勾轮廓确实更准（不分类别的分割得分更高），但**认类型反而更差**，凋亡核得分比我们自己的基线低 2.2 分。它找凋亡核的能力其实更强——找到的核却过不了“类型配对”这一关，最后还是兑不成凋亡核得分。

两个模型说的是同一件事：**模型整体的强弱，和解决凋亡核，是两回事。**

发现三：把分辨率放大一倍，凋亡核确实好了——但代价明码标价

这是本阶段的主结果，前后一共五步。

第一步：放大。 把工作分辨率从 256 像素倍增到 512，其它一切（模型、训练配方、数据）都不动。结果：事先登记的凋亡核指标**全部**变好——图内部（不贴图边）的凋亡核漏检率从 35% 降到 25%，连最难的子宫脱落细胞团都从 0.041 升到 0.055。但整体分数全面下降 1.8–2.6 分（指标不同，降幅不同）。按事先定下的“凋亡核改善且整体不退步”标准判：失败。

第二步：代价出在哪儿？ 三个证据锁定了位置。其一，下降与凋亡核的改善不在**同一批图**上——凋亡核变好的图整体分数基本没动，丢分的图恰恰是不含凋亡核的。其二，把核按大小分层（图 1）：面积 200 像素以下的小核**全部**变好（凋亡核也不例外），核越大掉得越多——受损的是大核，与类别无关。其三，被正确匹配的核，轮廓质量完全没变。大核不是被认差了，是**被切碎**了：一个核最多被切成 7 块“马赛克”，而外轮廓还贴着标准答案（图 2）。




图 1：分辨率倍增后各尺寸核的检出率变化：小核全赢，大核全输，单调过渡——问题的坐标轴是核的大小，不是核的类别。

第三步：真凶是两个写死的数字。 “把 512 的预测图缩回 256 时丢了信息”是最直观的嫌疑，但被“匹配核轮廓质量不变”排除了。顺着线索查到模型背后的经典后处理代码：分水岭（把图像当地形、沿“山脊”切开相邻核的老算法）这一步里，有两个**按像素写死**的常数——面积小于 10 平




图 2: 上排对比 (增益): 绿色是人工标注, 黄色是模型预测——256 分辨率下没有任何预测 (上行), 512 下被正常检出 (下行)。下排对比 (损伤): 256 下作为完整单体检出的大核 (上行), 512 下碎成一堆小块 (下行), 但外围轮廓仍然贴着标注。

方像素的目标一律丢弃; 边缘检测的窗口宽度固定为 21 像素。分辨率放大一倍后, 换算回真实的物理尺寸, 这两个门槛等于悄悄放松了好几倍——面积门槛缩到四分之一、窗口宽度缩到一半。于是, 本该被滤掉的细碎噪声活了下来, 混进预测列表; 大核内部纹理上又冒出多余的切割信号, 把整核切碎。几乎整个领域都在用这套从 HoVer-Net 继承下来的后处理代码, 而这个坑此前没有文献指出过。

第四步: 修复, 以及一个“杠杆”。 修复方案在动手前就登记好: 把两个常数按放大倍数补回去 (面积门槛乘 4、窗口宽度乘 2)。改两行代码, 代价收回 50–87% (依指标不同), 凋亡核增益分毫未损、还略增。接着再加一个只在验证数据上选好的小杠杆——把切碎的同类相邻块合并回去、丢掉贴着图边界的细条——加上它之后, 全部 9 次重复实验 (3 个数据划分 $\times$ 3 个随机种子) 的整体分数都严格变好。

第五步: 诚实的终局。 最后一次大考是 3×3 的划分 $\times$ 种子网格 (图 3), 判定标准事先写好。结果一分为二:

- **代价是稳健的:** 整体分数下降在每一次重复中方向一致, 幅度约是随机波动 (换随机种子重训带来的差异) 的 5 倍——这是真效应。
- **凋亡核增益是脆弱的:** 折算下来只有随机波动的 0.4–0.7 倍, 五次同种子配对比较里输了一场, 有一个数据划分的种子均值甚至由正转负。

所以最终答案是: 放大一倍确实让 AI “看见” 了更多将死的细胞 (漏检率降 7 个百分点, 这一项在所有重复中方向一致), 但它不是免费的——要拿约 0.8 分的整体分数来换。这是一次明码标价的交换, 值不值, 取决于下游更在乎哪一头; 而“凋亡核类得分提高 0.5 分”这种头条数字, 在这项基准的噪声水平下不足为凭——哪个数字可信、哪个不可信, 我们在报告里都说清楚了。




图 3: 种子网格: 3 个数据划分 $\times$ 3 个随机种子。右图整体分数——橙点 (512 分辨率) 每次都低于蓝点 (基线), 代价确凿; 左图凋亡核分数——橙蓝交错, 有一个划分上橙色均值反而更低, 增益脆弱。

本文是《阶段报告二》的导读。完整的数字、表格与文献见同目录下的正式报告:
 中文版 [stage_report_2_zh.pdf](#), 英文版 [stage_report_2.pdf](#);
 上一阶段的背景见 [../stage_report_1/summary_plain_zh.pdf](#)。