

把图像放大一倍，AI 就能看见将死的细胞吗？

——阶段报告二导读（课程项目 bdd26）

2026 年 10 月 1 日

背景：上一份报告留下了两个猜想

上一阶段的结论（见阶段报告一导读）：AI 在病理切片上识别细胞核，最困难的一类是**凋亡核**——细胞死亡后留下的皱缩、碎裂、深染的残迹。过去五年发表的模型，在这一类上的得分始终停留在 0.13–0.19，其它类别一般在 0.4 以上。对错误逐项拆解后，我们确认：问题不在于“认错”，而在于“看不见”——约 38% 的凋亡核完全没有被检出；更换数据集、更换训练技巧，均无济于事。

当时留下两条未经检验的出路，本阶段的工作就是把它们逐一检验完毕：

1. **换一种架构**。常见模型的做法是“先为每个像素打分，再把相邻像素围成核”（下称“描边派”）。另一派“找点派”先预测每个核的中心点，再围绕这些点组装轮廓——文献中最亮眼的凋亡核成绩，恰恰出自找点派（一个名为 KongNet 的模型）。
2. **把图像放大**。凋亡核体积小（面积中位数约为普通核的三分之一），在 256 像素的工作分辨率下，每个核只占十几个像素——模型也许并非不会识别，而是根本看不清。

按照事先约定的严格标准（数据按官方方案分为三份；参数只在验证部分上调整；测试部分只评估一次；每个结论都以多个随机种子重复验证），两条猜想的答案均已得出。

发现一：换用“找点派”架构，不仅没有更好，反而低了 11 分

KongNet 的作者公开了三份分别训练的模型权重，但未说明各份对应数据的哪个划分。我们先解决了这个问题：将每份权重在数据的三个部分上各测一遍，观察它在哪个部分“记得最牢”——模型在训练过的数据上成绩会明显偏高，据此即可对号入座，全程不使用测试数据。

随后按严格标准复评：KongNet 的整体得分只有 0.346，比我们测过的“描边派”中最弱者还低 11 分；文献中最亮眼的凋亡核成绩（逐核配对打分的 F_c , 0.59），在我们的口径下只剩 0.34。

失败的方式很能说明问题：**相互接触的同类核被“粘”为一体**。它合并相互接触核的比例，是描边派模型的三至四倍——而凋亡核恰恰常以“碎块群”的形态出现（核碎裂，karyorrhexis）。换言之，凋亡核的困难一半在“找不到”，另一半在“找到了却分不开”，而找点派的组装方式加剧了“分不开”的问题。结论：这不是更换架构流派所能解决的问题。

发现二：另一个更强的模型，同样未能兑现凋亡核的收益

我们还复评了 LKCell-L——在我们能取得公开权重的模型中，它的整体成绩最好（论文成绩 0.508）。两个发现：

- 它的各项指标一律比论文低约 1.5 分。这种“整体平移”说明差异来自评测流程（选择哪个存档点、如何调整后处理），而不是我们测错了。

- 在同等条件下，它分割轮廓确实更准（不分类别的分割得分更高），但类型识别反而更差，凋亡核得分比我们自己的基线低 2.2 分。它寻找凋亡核的能力其实更强——找到的核却过不了“类型配对”这一关，最终仍无法兑现为凋亡核得分。

两个模型指向同一个结论：模型整体的强弱，与能否解决凋亡核，是两回事。

发现三：把分辨率提高一倍，凋亡核确实改善——但代价明码标价

这是本阶段的主要结果，前后共五步。

第一步：放大。 把工作分辨率从 256 像素倍增到 512，其余一切（模型、训练配方、数据）保持不变。结果：事先登记的凋亡核指标全部改善——图内部（不贴图边）的凋亡核漏检率从 35% 降至 25%，连最困难的子宫脱落细胞团也从 0.041 升至 0.055。但整体分数全面下降 1.8-2.6 分（指标不同，降幅不同）。按事先定下的“凋亡核改善且整体不退步”标准判定：失败。

第二步：代价出在哪里？ 三个证据锁定了位置。其一，下降与凋亡核的改善不在同一批图像上——凋亡核改善的图像，整体分数基本未变，丢分的图像恰恰不含凋亡核。其二，把核按大小分层（图 1）：面积 200 像素以下的小核全部改善（凋亡核也不例外），核越大下降越多——受损的是大核，与类别无关。其三，被正确匹配的核，轮廓质量完全没有变化。大核不是被识别得更差，而是被切碎了：一个核最多被切成 7 块“马赛克”，而外轮廓仍贴合标准答案（图 2）。




图 1: 分辨率倍增后各尺寸核的检出率变化：小核全部获益，大核全部受损，中间单调过渡——问题的坐标轴是核的大小，而非核的类别。

第三步：真凶是两个写死的数字。 “把 512 的预测图缩回 256 时丢失了信息”是最直观的嫌疑，但被“匹配核轮廓质量不变”排除。顺着线索追查到模型背后的经典后处理代码：分水岭（一种把图像视为地形、沿“山脊”切开相邻核的传统算法）这一步中，有两个以像素为单位写死的常数




图 2: 上排对比 (增益): 绿色为人工标注, 黄色为模型预测——256 分辨率下没有任何预测 (上行), 512 下被正常检出 (下行)。下排对比 (损伤): 256 分辨率下作为完整单体检出的大核 (上行), 512 下碎成多个小块 (下行), 但外围轮廓仍贴合标注。

——面积小于 10 平方像素的目标一律丢弃; 边缘检测的窗口宽度固定为 21 像素。分辨率提高一倍后, 换算回真实的物理尺寸, 这两个门槛相当于悄然放松——面积门槛缩至四分之一, 窗口宽度缩至一半。于是, 本应被滤除的细碎噪声混入了预测列表; 大核内部纹理上又出现多余的切割信号, 将整核切碎。几乎整个领域都在使用这套沿袭自 HoVer-Net 的后处理代码, 而这一隐患此前未见文献指出。

第四步: 修复, 以及一个“杠杆”。 修复方案在实施前已预先登记: 把两个常数按放大倍数补回 (面积门槛乘 4、窗口宽度乘 2)。只改两行代码, 代价即可收回 50–87% (依指标不同), 凋亡核增益分毫未损, 还略有增加。随后再加入一个只在验证数据上选定的“杠杆”——把切碎的同类相邻块合并回去、丢弃贴着图像边界的细条——加上它之后, 全部 9 次重复实验 (3 个数据划分 $\times$ 3 个随机种子) 的整体分数均严格改善。

第五步: 诚实的终局。 最后的检验是 3×3 的划分 $\times$ 种子网格 (图 3), 判定标准事先写定。结果一分为二:

- **代价是稳健的:** 整体分数的下降在每一次重复中方向一致, 幅度约为随机波动 (更换随机种子重训带来的差异) 的 5 倍——这是真实效应。
- **凋亡核增益是脆弱的:** 折算下来只有随机波动的 0.4–0.7 倍, 五次同种子配对比较中失利一场, 还有一个数据划分的种子均值由正转负。

因此, 最终的答案是: 分辨率提高一倍, 确实让 AI “看见” 了更多将死的细胞 (漏检率下降 7 个百分点, 这一项在所有重复中方向一致), 但它并非免费——代价约为 0.8 分的整体分数。这是一次明码标价的交换, 是否值得, 取决于下游更看重哪一端; 至于“凋亡核类得分提高 0.5 分”这样的头条数字, 在这项基准的噪声水平下不足为凭——哪些数字可信、哪些不可信, 报告中均已说明。




图 3: 种子网格: 3 个数据划分 $\times$ 3 个随机种子。右图为整体分数——橙点 (512 分辨率) 均低于蓝点 (基线), 代价确凿; 左图为凋亡核分数——橙蓝交错, 其中一个划分上橙色均值反而更低, 增益脆弱。

本文是《阶段报告二》的导读。完整的数字、表格与文献见同目录下的正式报告:
 中文版 [stage_report_2_zh.pdf](#), 英文版 [stage_report_2.pdf](#);
 上一阶段的背景见 [../stage_report_1/summary_plain_zh.pdf](#)。