

跨尺度 Dead 增益的机制检验与 Dead 专家分支的预注册关闭

PanNuke 细胞核实例分割：阶段报告四

课程项目 bdd26

2026 年 10 月 8 日

实验范围：2026 年 10 月 6 日至 8 日

摘要

上一阶段的 EF-P2 在保留原尺度预测的前提下补入两倍尺度候选，以极小的整体指标代价稳定提升了 Dead 类的分割质量，但没有回答三个更根本的问题：两倍尺度的 Dead 增益从何而来，Dead 短板能否靠训练侧的专家分支解决，以及两套模型的完整推理代价是多少。本阶段围绕这三个问题开展机制实验。首先，四臂对照实验（E2a）把 HV 目标的固定面积门槛从尺度效应中分离出来：x1 降低门槛只能复现两倍尺度 Dead 增益的 9.59%，不足以替代尺度本身；在把门槛折算到原生像素面积口径配平后，x2 相对 x1 仍承担全部 bPQ 代价，并保留大部分 Dead 增益。其次，为检验“Dead 与常见类在共享解码器上存在容量级梯度冲突”这一前提，Dead 专家分支（DSB）在训练前设置了四道预注册闸门：A、C、D 三项放行，而 B 项梯度冲突探针在修正取样方式后的重跑显示，64 个 Dead 阳性批次上解码器复合梯度余弦均值为 +0.749、最小值 +0.594、无一批为负，梯度强同向而非冲突；据此该研究线按预注册的止损规则关闭，未启动任何 GPU 训练。最后，推理成本实测表明两模型系统耗时为单模型 x1 的 6.09 倍；按预注册规则，EF-P2 的定位由候选部署方案调整为机制证据与教师候选模型。本阶段另完成一次全仓库一致性审计，更正了若干历史转录误差，并重建了两个丢失的实验产物。全部实验未读取测试折，亦未产生新的三划分测试成绩。

关键词：细胞核实例分割；PanNuke；机制归因；预注册闸门；梯度冲突；推理成本

1 研究背景与本阶段问题

阶段报告三给出了一个边界清晰的正面结果：EF-P2 在九组划分-种子配对上将 Dead PQ 平均提高 0.00699，同时将 bPQ 的平均损失控制在约 -0.000009 [1]。但它同时留下了三个悬而未决的问题。第一，Dead 增益的来源不清楚——两倍工作尺度同时改变了采样密度、特征尺度、解码常数和训练监督的构成，收益无法归因。第二，Dead 短板的训练侧解法尚未被排除——此前的负结果集中在像素加权、平衡采样与免训练找回，模型内部为稀有类设置专家分支的方案尚未检验。第三，两套模型的部署代价从未测量，EF-P2 的实用定位悬而未决。

10 月 6 日的复盘将这三个问题确立为正式议题，并给出最小实验集 E0-E5 与三条候选路线[2]。复盘中的代码排查带来一项直接决定本阶段首组实验的发现：HV 目标构造沿用了官方实现的 30 工作像素面积门槛，实例小于该门槛时其整个 HV 目标被置零；而在两倍尺度下，同样的门槛只相当于约 7.5 个原生像素。也就是说，x1 与 x2 的小实例几何监督在训练开始前就不相同，任何把 x2 收益直接归因于“分辨率”的解释，都必须首先排除这一混杂因素。

本阶段完成的工作依次为：

1. 开展 E2a 四臂对照实验，将工作尺度与 HV 门槛两因素交叉，隔离监督门槛对 Dead 增益的贡献；

2. 执行 DSB 四道预注册闸门，在投入 GPU 训练前检验 Dead 专家分支的全部前提假设，并在闸门失败时按预注册规则关闭该研究线；
3. 完成 E0 推理成本实测，按预注册规则确定 EF-P2 的部署定位；
4. 进行全仓库一致性审计，核对文档、代码与实验产物，更正历史误差并重建丢失产物。

本阶段所有训练与探针只使用训练折和验证折，没有读取任何测试折，也不产生新的三划分测试成绩。E2a 为单划分、双种子的验证集机制实验；DSB 全部闸门在同一组冻结检查点上执行；E0 只计时、不评测。三者结论的适用范围分别在相应各节说明。

2 实验设置与通用口径

模型与训练配方沿用阶段报告三：CellViT[9] 以 UNI[8] 为编码器，训练 130 轮，批大小 16，前 25 轮冻结编码器，初始学习率 3×10^{-4} 、逐轮乘 0.85 衰减，推理不使用测试时增强。E2a 与 DSB 闸门在 split 1（训练 fold 1、验证 fold 2）上执行；验证折 fold 2 含 2,523 张图、19 种组织、59,872 个真实细胞核实例（ground-truth instances），其中 Dead 884 个，分布在 70 张图，图像内部 741 个、接触图像边界 143 个。两个随机种子训练出的模型共享同一批对象，不构成两批独立样本。

指标口径与阶段报告三一致：mPQ 为官方图像-组织聚合的多类全景质量，bPQ 忽略类别，Dead PQ 只在含 Dead 真值的图像上计算；strict 口径把“无该类真值却预测出该类”的图像也计入惩罚，与官方口径并报。梯度余弦、毫秒每图等本阶段新增的量在各节单独定义。表中 Δ 均为前者减后者的带符号差值，如 +0.00982 即百分制下 0.982 分。

3 HV 目标支持门槛：一个先于训练的混杂

复盘阶段在 CPU 上直接调用仓库的 `hv_targets` 构造函数，对同一 64×64 标签中的完整矩形核做精确两倍最近邻放大，统计非零 HV 像素数（表 1）。16 与 25 像素的核在 x1 下 HV 目标整体为零，在 x2 下则具有完整的方向距离场；30 像素的核恰在 x1 门槛边缘。被门槛排除的实例仍保留核像素与类型（NP/TP）监督，并非被完全忽略，但分水岭解码所依赖的 HV 几何目标被置为零，并在损失中被显式监督至零，而非作为忽略区域排除在损失之外。

表 1: CPU 探针：同一标签在不同工作尺度下的非零 HV 像素数。目标构造对 x1/x2 使用同一 30 工作像素门槛。

原始实例面积（像素）	x1 非零 HV 像素	x2 非零 HV 像素
16	0	63
25	0	99
30	29	119
36	35	143

这一发现有两层含义。其一，跨尺度互补的机制解释必须先控制该门槛：如果 x1 单纯降低门槛就能复现大部分 Dead 增益，两套模型的必要性将大幅下降。其二，它是官方实现的既有行为而非程序缺陷（bug），修改它属于实验干预，必须以对照实验的方式实施。E2a 由此确定四臂设计：保留 (x1, 30) 与 (x2, 30)，新增 (x1, 8) 与 (x2, 120)，后两臂把门槛折算到原生像素面积口径后分别约为 8 像素与 30 像素，使两对尺度比较在配平的支持水平上进行。设计、预算与对比在启动前冻结于预注册计划 [3]。

4 E2a: HV 门槛与工作尺度的四臂对照

4.1 完成状态

四臂 $\times$ 种子 {19, 1} 共 8 次训练全部完成：每个日志均含 130 个 epoch 且无重复记录，最终检查点齐备，训练源码冻结于提交 c6e7e92。每臂另做一次哈希绑定的审计重推（最终检查点、无 TTA、同一解码常数）， 8×6 个端点上审计与原始评估的差值全部精确为零，排除了在两次评估之间择优汇报的可能。八个训练日志记录的训练循环时间合计 41.76 小时，在共享 A100 上运行，仅作为完成性记录，并非受控的吞吐基准。HV 分支完整 CPU 测试 210 项通过、3 项 CUDA 依赖跳过。

4.2 臂均值与预注册对比

表 2: E2a 验证折 (fold 2) 双种子均值。四臂配置仅工作尺度与 HV 门槛不同。

臂	mPQ	bPQ	Dead PQ	strict Dead PQ
x1_hv30	0.48211	0.65197	0.16214	0.12630
x1_hv8	0.48079	0.65067	0.16358	0.13017
x2_hv30	0.48131	0.64470	0.17717	0.12340
x2_hv120	0.47980	0.64448	0.16735	0.11899

表 3: 四项预注册对比（前者减后者）。方括号为 2,000 次按组织分层的配对图像 bootstrap 95% 区间（种子 20261006），只反映给定两个训练模型的图像抽样不确定性。

对比	Δ Dead PQ	Δ bPQ
x1_hv8 - x1_hv30	+0.00144 [-0.01027, +0.01360]	-0.00130 [-0.00295, +0.00039]
x2_hv30 - x2_hv120	+0.00982 [-0.00165, +0.02397]	+0.00022 [-0.00111, +0.00168]
x2_hv120 - x1_hv30	+0.00521 [-0.01298, +0.02609]	-0.00749 [-0.01033, -0.00439]
x2_hv30 - x1_hv8	+0.01359 [-0.01021, +0.04251]	-0.00597 [-0.00896, -0.00289]

E2a 预注册对比（双种子均值，图像 bootstrap 区间）




图 1: 四项预注册对比的 Dead PQ 与 bPQ 差值及图像 bootstrap 区间。Dead 的四个区间全部跨零；bPQ 的两个尺度对比区间整体低于零。图中数值为双种子均值。

四项对比给出四个可分开陈述的判断 [4]:

1. **x1 降门槛不能替代 x2**。Dead 差值在两个种子间方向相反 ($-0.00138 / +0.00426$)，bPQ 在两个种子上均下降。x1_hv8 的 strict Dead 均值虽较高，仍无法弥补官方口径下的不稳定性与整体代价。
2. **x2 内门槛效应是候选信号，不是稳健改进**。hv30 相对 hv120 的官方 Dead 在两个种子上均提高 ($+0.01083 / +0.00880$)，均值 $+0.00982$ ，但 bootstrap 区间跨零，strict Dead 在 seed 1 下降。
3. **配平支持水平后，尺度效应仍伴随 bPQ 代价**。两组 x2-x1 对比的 bPQ 区间均完全位于零以下，且两个种子方向一致；官方 Dead 均值为正的同时，strict Dead 在全部四个 x2-x1 种子对上为负。官方与 strict 两种口径必须一并报告。
4. **因果机制尚未定位**。固定面积门槛只排除了一个特定混杂；尺度同时改变采样、特征与目标离散化，训练进度安排（编码器解冻时学习率已衰减至 5.16×10^{-6} ）等混杂仍未隔离。

对象级统计进一步刻画了门槛效应的性质。以验证折固定的 741 个内部 Dead 为分母，x1_hv30 的匹配率为 61.27%，x2_hv120 为 70.99%——在原生像素面积口径配平后，内部 Dead 匹配率仍由尺度提高近 10 个百分点。而在 x2 内部，把门槛从 120 降到 30 仅使平均内部匹配数从 526.0 增至 526.5（两个种子合计仅多 1 个）： $+0.00982$ 的官方 Dead 增益并非来自内部完整核的额外找回，更可能源于掩码形状与误报结构的变化，本轮未做进一步分解。接触图像边界的 Dead 匹配率同样由尺度解释（40.21%→48.25%），门槛在 x2 内对其几乎没有影响。

4.3 研究决策与闸门 A 的规则计算

E2a 的直接决策是：默认 hv_min_size=30 不变；x2_hv30 保留为冻结的机制参照；不把本轮任何数字当作三划分收益发布。对后续 DSB 研究线，预注册的闸门 A 以点估计代入规则：x1 降门槛复现的 Dead 增益占比 $r/R = 0.00144/0.01503 = 9.59\%$ ，未达到 50% 的换基线条件，也未达到 90% 的全解释降级条件，且 x1_hv8 伴随 -0.00130 的 bPQ 代价。因此 DSB 基线维持 x1_hv30，架构线不降级。该比值只是冻结规则的代入值，不构成对门槛贡献的因果估计。

5 DSB: Dead 专家分支的四道预注册闸门

5.1 设计与闸门逻辑

DSB 的假设链是：如果 Dead 与常见类在共享解码器上存在**容量级**梯度冲突 (H1)，那么把 Dead 检测解耦为模型内专家分支（同构 NP+HV 双头、仅 Dead 阳性图计算专家损失、EF 式去重并入）有望在不损害聚合指标的前提下恢复内部 Dead 召回 (H2)。设计要点为：编码器与既有 NP/HV/TP 三支保持平衡，仅新增专家分支；不使用过采样（平衡采样在 C1 已有负结果），不使用 pos_weight（97% 的批次为纯负样本，会污染 BatchNorm 统计），改用损失掩蔽。文献核查未发现“类解耦专家 + 细胞核实例分割 + PanNuke 官方三折 + 等参对照”的正面工作，最近的类比是图像分类领域的 GS-MoE 与半监督腺体分割的 Semi-MoE[10, 11]。完整设计、预算与止损规则冻结于预注册规格 [5]。

按规格 §6，任何 GPU 训练开始前须依次通过四道闸门，全部通过方可进入开发轮；任一失败则关闭整条研究线、只保留机制证据。CPU 侧实现（模型、目标、损失、TTA、命令行、合并选择、蒙太奇与四个闸门脚本）按测试驱动开发逐任务完成并提交；该分支在闸门流程结束后合入 master，保留为已通过测试的工具代码，从未用于任何训练。

表 4: 四道闸门的内容与预冻结继续条件（规格 §6 摘要）。

闸门	检验内容	预冻结继续条件
A	E2a 门槛规则	x1 降门槛复现 $\geq 50\%$ 尺度 Dead 增益则更换基线； $\geq 90\%$ 且无性能代价则架构线降级
B	梯度冲突探针	Dead 组与常见类组梯度余弦为负的批次比例 $\geq 30\%$ ，或逐层显著为负
C	L0 决策解耦上界	免训练的按类阈值/解码菜单若得 $\Delta\text{Dead} \geq +0.005$ 且 bPQ 代价 ≤ 0.001 ，则架构级解耦不必要，本线关闭
D	Dead oracle 上界	内部漏检 Dead 以 IoU 0.7 oracle 加入后 $\Delta\text{Dead} \geq +0.01$

5.2 闸门 A、C、D 的结果

闸门 A (proceed, 基线 x1_hv30)。规则计算见上节： $9.59\% < 50\%$ ，未触发更换基线； $< 90\%$ ，未触发降级。输入数字经独立复核，与 E2a 冻结快照逐位一致。

闸门 C (proceed)。在验证折 fold 2 上扫描 Dead 专属解码阈值 $\tau_{\text{dead}} \in \{0.5, 0.4, 0.35, 0.3\}$ (0.5 即基线)：Dead PQ 由 0.16386 最高升至 0.16601 ($\tau = 0.4$)， ΔDead 峰值 $+0.00214$ ， $\Delta\text{bPQ} + 1.1 \times 10^{-5}$ 。峰值远低于 $+0.005$ 的关闭线，说明免训练的决策级解耦无法带来足够的 Dead 召回提升，架构级解耦的前提仍然成立。基线 Dead PQ 与官方评估逐位一致；该菜单的重解码路径使 mPQ/bPQ 基线与官方评估存在 10^{-7} 量级差异，本报告只引用其 Dead 数字。

闸门 D (pass)。把 fold 2 全部 267 个未匹配的内部 Dead 真值以 IoU 0.7 的收缩掩码 oracle 加入基线预测：Dead PQ 由 0.16386 升至 0.31992， $\Delta\text{Dead} + 0.15606$ ，bPQ $+0.00145$ ，mPQ $+0.00231$ ；精确掩码变体 $\Delta\text{Dead} + 0.24533$ 。该上界远高于 $+0.01$ 的通过阈值：只要能找回漏检的内部 Dead，收益量级即可达到现有水平的十倍以上。这与“Dead 短板首先是检测召回问题”的诊断一致。

5.3 闸门 B: 首跑判 VOID 与修正重跑后的失败

闸门 B 在冻结的 split1 检查点上测量 Dead 像素组与常见类像素组损失的梯度余弦：两组掩码不相交，同一批数据一次前向、分别反传，对共享解码器参数取复合余弦；冲突定义为余弦为负的批次比例 $\geq 30\%$ 或逐层显著为负。

首次运行（10 月 8 日 00:58）被判 VOID 而非失败：预冻结计划指定“顺序取前 256 张 fold 1 图像”，而这 256 张全部为 Breast 组织、恰含 1 张 Dead 阳性图；64 批中有 63 批的 Dead 损失结构性地为零，却被当作非冲突批次计入分母，致使冲突比例在尚未测量任何梯度几何之前就被限制在 $1/64$ 。唯一有效批的解码器复合余弦为 $+0.269$ 。探针机制本身经核查无误（掩码不相交、一次前向、retain_graph；参数集与解码器等价），缺陷出在预冻结的取样设计与零损失批次的分母计入方式。规格 §10 的止损规则未被触发；修正案（Dead 分层种子取样覆盖全部 65 张 Dead 阳性图、分母只计 Dead 活跃批、 $n_{\text{active}} < 16$ 判 VOID、补齐逐层单侧 t 检验与 Holm 校正）先行登记于台账并新增四个测试用例，经确认后重跑，全程约数分钟 GPU 时间。

表 5: 闸门 B 修正重跑: 65 张 Dead 阳性图全覆盖, 64/64 批 Dead 活跃, 每批 4 图。解码器复合为跳接、NP、HV、TP 四组共享参数的合成余弦。

参数组	逐批余弦均值	负批次	冲突比例
编码器	+0.406	0/64	0.000
跳接适配层	+0.608	0/64	0.000
NP 分支	+0.917	0/64	0.000
HV 分支	+0.760	0/64	0.000
TP 分支	+0.196	7/64	0.109
解码器复合	+0.749	0/64	0.000




图 2: 闸门 B 修正重跑的逐批梯度余弦分布。圆点为 64 个 Dead 阳性批次的取值, 菱形为均值。全部点位于零线右侧; 仅 TP 分支出现 7 个负批次。

重跑结果明确: 解码器复合余弦均值 +0.749, 逐批最小 +0.594、中位数 +0.760、最大 +0.861, **64 批中 0 批为负** (冲突比例 $0 \ll 0.30$; 若真实冲突率 $\geq 30\%$, 64 批全非负的概率约 10^{-10})。六个参数组的均值全部为正, 逐层单侧 t 检验统计量均为正 (解码器复合 $t = +89.6$), 无任何 Holm 显著负组。首次运行中唯一有效批的 +0.269 也并非偶然。闸门 B 判定失败。

该测量在训练收敛后的同一配置检查点上进行 (回退检查点取自另一种子), 早期训练动态不在覆盖范围内; 两组损失等权, 余弦只约束方向、不含幅度。方向性结论是明确的: 在训练完成的模型上, 改善 Dead 像素与改善常见类像素把共享参数往大体相同的方向推。H1 不成立, 专家解耦的收益前提不复存在。

5.4 按预注册止损关闭

规格 §10 预注册: 任一闸门失败即关闭整条研究线, 不升级算力。闸门 B 失败后, DSB 的冒烟轮、开发轮与确认轮全部取消, 蒙太奇盲审不再需要, 已准备的开发轮队列脚本未启用。四道闸门合起来留下的是一组机制证据: Dead 短板是检测召回问题——像素重加权与平衡采样此前已证伪, 决策阈值解耦仅能带来 +0.002, 专家架构解耦的梯度冲突前提不成立, 而检测级 oracle 上界高达 +0.156。解法不在这四个方向上; 后续要么引入新的检测监督或数据 (路线 C 的跨模态条件), 要么接受 EF-P2 式的两阶段候选补入并如实报告其成本 (路线 B)。

6 E0：两模型系统的推理成本

E2a 与 DSB 检验的是训练价值，E0 度量的是部署成本。计时协议固定：共享 A100-SXM4-80GB，批大小 32，解码 16 进程；在保持 `predict_fold` 流程未作修改的前提下，以 256 张图分块统计实际运行耗时 (wall-clock)，数据为 fold 2 的 2,523 张图（计时对象 `split2_seed1` 的训练折；成本与检查点质量无关，未读测试折，未评任何端点）。CPU 融合按冻结的 `split2_seed19` EF-P2 部署调用逐图重放，重放的添加数与冻结选择精确一致 (1,542 个)，证明计时路径就是部署路径。

表 6: E0 分臂计时。各臂取各次重复中吞吐最高者；比值以 x1 为分母。融合为 CPU 单线程。

环节	ms/图	图/秒	峰值显存 (GiB)	相对 x1
x1	15.50	64.4	4.76	1.00
x2-du2 (GPU)	52.88	18.9	12.91	3.41
x1-TTA (GPU)	72.33	13.8	4.93	4.67
融合 (CPU)	25.97	—	—	1.68
两模型系统合计	94.35	—	—	6.09




图 3: E0 各环节的每图耗时与相对 x1 的倍数。两模型系统为 x1、x2-du2 与 CPU 融合之和。

两模型系统合计 94.35 ms/图，为单模型 x1 的 **6.09 倍**；作为参照，x1 自身的 TTA 亦达 4.67 倍。绝对耗时随同机负载波动：四次启动窗口的负载从 19 到 46 不等，x1 均值在 10.7–15.5 ms 间变化，但**臂间比值**在各窗口稳定 (x2/x1 3.1–3.4，两模型/x1 6.1–6.3；TTA 因 CPU 占比最高而最敏感，3.3–4.7)。两点口径说明：其一，冻结产物中的精度标签为 fp32，实际前向走的是 `predict_fold` 的 bf16 autocast 路径，四臂一致，比值不受影响（脚本标签已在事后修正）；其二，融合计时的最终数字基于一次性物化的数组测得，已排除 npz 逐实例重复解压带来的偶发开销（首测每图 1–27 秒），并与命令日志绑定存档。

按 E0 预注册规则——无性能–成本优势则 EF-P2 只作机制证据或教师候选——EF-P2 的正式定位就此调整：Dead 收益成立，但任何部署表述都必须如实说明约 6 倍的推理成本；该成本约为 x1-TTA 的 1.3 倍，而 TTA 不能带来新的 Dead 检出。M/S 杠杆未单独计时（CPU 重标注，与融合同量级）；模型加载、评测与多进程融合并行化未计入。

7 全仓库一致性审计

10月8日晚,由三个独立运行的只读审计代理(LLM自动核查)加人工复算完成了一次全仓库一致性核查:文档对代码、文档数字对实验产物、代码对记录运行三个方向,加全量测试。核心结论是**主要结果全部复现**:四道闸门的判定值与台账逐位一致,E0的6.09倍由cost.json重推,阶段报告一至三与HV对照、P0-P3的全部表格数字精确复现,评测协议规则(官方评测器、最终检查点、三划分均值、不引用全数据发布权重作测试成绩)均得到遵守。审计后全量测试**271项通过**。

更正与补建包括:CellViT-UNI三划分bPQ均值由舍入值平均改为精确平均,0.6654更正为**0.6653**(本文与阶段报告三的衔接以此为准);恢复类负结果的表述修正为“逐折最大回落 -0.0012 ”;KongNet训练折F1间距更正为 ≥ 0.12 (最小0.124);跨域降幅CellViT 0.152 $\rightarrow$ 0.154等十余处转录级修正;两个在两台机器上均已丢失的产物(fold3失败实例清单、split2_seed2的du2/du2lev测试评测)分别从留存的确定性预测重建,重建值与历史记录逐位吻合(du2 0.48682/0.65836/0.15259,杠杆增量 $+0.00157/+0.00238/+0.00071$,九格网格判定全部不变),并以记录SHA-256的校验文件(sidecar)绑定来源。工程上新增fold_guard机制:四类开发/探针脚本此后拒绝读取所属划分的测试折、拒绝不可验证的划分号,开发评估菜单冻结时绑定输入哈希并拒绝覆盖。CONCH支柱A的探针输出此前未在任何机器留存缓存,是目前唯一无法复核的条目,已在文档中如实标注。

本轮审计的各项更正均先依据产物重新计算、再行修改;涉及历史文档的就地更正不改变任何实验判定。

8 讨论与后续工作

8.1 本阶段的局限

1. **E2a 为单划分、双种子实验**。全部对比在split1的验证折上进行,bootstrap区间只覆盖图像抽样;Dead的四个对比区间均跨零,x2内的门槛效应属于候选信号,有待三划分与更多种子确认。
2. **闸门B只覆盖训练收敛后的检查点**。早期训练动态与损失幅度不在测量范围内;止损所依据的规格先于测量冻结。
3. **DSB的H2未经检验**。整条研究线在进入训练前的闸门阶段即告终止,结论限于“解耦前提不成立”,不涉及专家分支本身的有效性。
4. **E0为单机共享GPU的实际耗时(wall-clock)测量**。绝对毫秒不可直接迁移,比值在观测窗口内稳定;模型加载、评测与并行融合未计入。
5. **本阶段没有新的三划分测试成绩**。各结论或为验证折机制发现,或为既有结果的更正与定位调整;测试折多轮复用的限制与阶段报告三相同。

8.2 后续方向

复盘给出的三条路线中,本阶段已完成其中机制与成本两部分的检验(E2a与E0均以闸门化方式进行)。下一步优先级不变[2]:先做E1验证候选盲审(x1接受、x2独有接受/拒绝、随机背景四组,专家裁决“当前视野无法判定”),把EF-P2新增候选的“未匹配”成分拆成debris、形状偏差与疑似漏标;若盲审支持,再做路线B的训练内交叉拟合效用学习(以 $P(\text{match}) \cdot E[\text{IoU} \mid \text{match}] > q/2$ 为代理判据),并与冻结EF-P2、低维回归以及相同算力预算下的TTA/集成相对照。路线A的裁剪一致性机制实验与路线C的跨模态监督维持条件启动。DSB保留的闸门工具(分层蒙太奇、梯度探针、oracle上界)可在这些路线中复用。

9 结论

本阶段未追求新的测试分数，而是把阶段报告三留下的三个问题分别推进到明确的答案。第一，HV 目标支持门槛是真实存在的混杂因素，但贡献只占小部分：x1 降低门槛仅复现两倍尺度 Dead 增益的 9.59%，配平支持水平后 x2 仍承担全部 bPQ 代价并保留大部分 Dead 增益，strict Dead 在全部四个种子对上为负——尺度效应的主体在别处。第二，Dead 专家分支的前提假设被证伪：在训练完成的检查点上，Dead 与常见类的梯度高度同向（64 批复合余弦均值 +0.749、零负批），连同此前已证伪的重加权、增益仅 +0.002 的阈值解耦与高达 +0.156 的检测级 oracle 上界，Dead 短板的解法指向新的检测监督或数据，而非在现有监督上重新分配容量；该研究线按预注册止损关闭，未花费确认轮算力。第三，两模型系统的实测耗时为单模型（x1）推理的 6.09 倍，EF-P2 定位调整为机制证据与教师候选模型。全仓库审计确认主要结果均可复现，历史数字的转录误差已就地更正。机制结论、成本边界与更正后的历史记录，构成本项目当前的进度基线。

A 文件、数字与复现入口

A.1 数值核验

本报告所有表格数字由 `scripts/report4_numbers.py` 从冻结产物直接输出；`scripts/verify_report4.py` 从最原始一层（8 份审计评测 `summary.json`、五个闸门 JSON、`cost.json`、审计涉及的测试汇总）独立重算全部主表数字并逐位核对，输出可移植快照 `verified_numbers.json`（本目录已含，共核 96 个端点单元）。bootstrap 区间取自 E2a 冻结快照并记录来源 SHA-256，不重新抽样。闸门 B 的逐批余弦与每层 t 值由序列化列表独立重算，结果一致；闸门 A 比值与 E0 比率由原始数字重推，结果一致。研究日志 [6] 仅用于追溯过程，不作为数值依据。

2026 年 10 月 8 日在固定依赖环境下全量回归测试 271 项通过、64 条警告（Python 3.10、torch 2.5.1+cu124、numpy 1.23.5；未安装或升级依赖）。本次制图脚本沿用阶段报告三的中文字体与 Type 42 嵌入约定，图表数值与 `figs/` 内 CSV 一致。

A.2 产物与复现命令

表 7: 主要实验产物，均相对仓库根目录；`runs/` 下为本地产物，不随 Git 分发。

路径	本报告用途
<code>runs/hv_threshold_controls_20261006/</code>	E2a 八个训练臂：配置、日志、原始与审计重推评估。
<code>runs/analysis/hv_threshold_controls_20261006/</code>	E2a 冻结数字快照与 bootstrap。
<code>runs/analysis/dsb_gates_20261007/</code>	四闸门 JSON 与台账； <code>gate_b_v2.json</code> 为闸门 B 权威版本，VOID 首跑工件保留。
<code>runs/analysis/inference_cost_20261008/</code>	E0 计时、命令与尝试日志。
<code>runs/analysis/report4_numbers.txt</code>	本报告逐表数字快照。

在固定依赖环境、仓库根目录执行：

```
python scripts/report4_numbers.py
python scripts/verify_report4.py
python scripts/make_report_figures4.py
python -m pytest -q
```

核验脚本在产物缺失或数值不一致时以错误状态退出，不修改实验产物。重跑历史评测须使用相应的源码快照，或在明确登记为新的复核后执行，不得绕过来源检查。

参考文献

- [1] bdd26 项目. 阶段报告三: 跨尺度候选筛选与面积过滤 [R]. 2026-10-06.
docs/report/stage_report_3/.
- [2] bdd26 项目. 研究复盘与下一阶段路线 (2026-10-06) [R].
docs/RESEARCH_NEXT_2026-10-06.md.
- [3] bdd26 项目. HV 门槛四臂对照预注册计划 [R]. 2026-10-06.
docs/superpowers/plans/2026-10-06-hv-threshold-controls.md.
- [4] bdd26 项目. HV 目标门槛对照: 结果与机制分析 [R]. 2026-10-07.
docs/HV_CONTROLS_RESULTS_2026-10-07.md.
- [5] bdd26 项目. Dead 检测专家分支 (DSB) 设计规格与实现计划 [R]. 2026-10-07.
docs/superpowers/specs/2026-10-07-dead-specialist-branch-design.md;
docs/superpowers/plans/2026-10-07-dead-specialist-branch.md.
- [6] bdd26 项目. 实验日志: 2026-10-06 至 10-08 条目 [R]. docs/findings.md.
- [7] GAMPER J, ALEMI KOOHBANANI N, BENES K, et al. PanNuke Dataset Extension, Insights and Baselines[EB/OL]. 2020[2026-10-06]. <https://arxiv.org/abs/2003.10778>.
- [8] CHEN R J, DING T, LU M Y, et al. Towards a general-purpose foundation model for computational pathology[J]. Nature Medicine, 2024, 30(3): 850–862. DOI: 10.1038/s41591-024-02857-3.
- [9] HÖRST F, REMPE M, HEINE L, et al. CellViT: Vision Transformers for precise cell segmentation and classification[J]. Medical Image Analysis, 2024, 94: 103143. DOI: 10.1016/j.media.2024.103143.
- [10] GS-MoE: generalist–specialist 分支恢复低患病率类 (项目规格核查所用简记) [EB/OL]. arXiv:2609.18688, 2026[2026-10-07]. <https://arxiv.org/abs/2609.18688>.
- [11] Semi-MoE: 任务级专家的半监督分割 (项目规格核查所用简记) [EB/OL]. arXiv:2509.13834, 2025[2026-10-07]. <https://arxiv.org/abs/2509.13834>.