

多检出的 Dead 核从何而来，代价又有多大？

阶段报告四导读

课程项目 bdd26

2026 年 10 月 8 日；10 月 10 日文字修订

先说结论

上一阶段，我们保留原尺度模型的结果，再从两倍尺度模型中筛选一些新候选补进去。这套方案称为 EF-P2，能小幅提高 Dead 类的分割指标，但还不能据此认为它更适合实际使用。这里的 Dead 包括凋亡和坏死细胞核，不只指凋亡核。本阶段回答了三个后续问题：

- **只改训练中的面积门槛，还替代不了放大图像。**在原尺度上降低门槛，所得 Dead 指标增益仅为原两倍尺度增益的 **9.59%**。这是两项增益的比值，不是说我们已经解释了恰好 9.59% 的因果机制。
- **没有启动 Dead 专家分支训练。**训练前检查没有发现方案所要求的梯度冲突证据，因此按事先写好的规则停止。这不等于专家分支已经被证明无效。
- **两模型系统约需单模型 6.1 倍的推理时间。**现有收益不足以证明这项成本值得付出。EF-P2 保留用于研究跨尺度互补，也可作为后续教师模型的候选，但还不是有部署优势的方法。

为什么先检查一个面积门槛？

原图为 256×256 。把它放大到 512×512 ，再按相应尺度训练，确实能多找回一些原先漏检的 Dead 核，但整体分割质量有所下降。放大也同时改变了输入采样、模型特征和训练目标，不能简单解释成“分辨率更高，所以看得更清楚”。

其中有一处可以直接检查：模型的 HV 训练目标，为核内像素提供到核中心的水平、垂直方向距离，帮助模型把相邻的核分开。官方实现设有 30 个工作像素的面积门槛；核小于这个面积时，HV 目标全部置零。它仍参与前景和类别训练，但几何输出会被要求学成零，而不是被忽略。

同样的 30 像素门槛，在两倍尺度下只相当于原图 7.5 个像素。因此，一个原图面积为 16 像素的小核，在原尺度下的 HV 目标全零，放大后却有完整的距离信息。**两种尺度给小核的几何监督，原本就不一样。**这不是已确认的程序错误，而是需要通过对照实验检验的设置。

四组对照说明了什么？

我们比较四组配置：原尺度配门槛 30 或 8，两倍尺度配门槛 30 或 120。按原图面积换算，原尺度 30 与两倍尺度 120 相同；原尺度 8 与两倍尺度 30 则近似相同。每组训练两个随机种子，共 8 次训练，均在验证折上评估。

主要结果有三点：

- 原尺度把门槛从 30 降到 8，Dead 指标在两个种子间一正一负，整体指标还略有下降，未显示出稳定收益。
- 两倍尺度把门槛从 120 降到 30，官方 Dead 指标在两个种子上均提高，平均 +0.0098；但置信区间包含零，还不能排除抽样波动。
- 把门槛按原图面积配平后，两倍尺度的官方 Dead 指标均值仍较高，忽略类别的分割指标 bPQ 仍较低。更严格的 strict Dead 指标在全部四组种子配对中均下降。它会额外惩罚在没有 Dead 真值的图中报出 Dead 的情况，因此不能只看官方指标的上升。

逐个核的统计也很重要。在两倍尺度下，降低门槛前后，匹配到的内部 Dead 核平均为 526.0 和 526.5，两个种子合计只多 1 个。这说明 +0.0098 不能主要用“多找回了一批内部完整核”解释；掩码形状和误报分布可能也有影响，但本轮还没有把它们分别检验清楚。

为什么停止 Dead 专家分支？

这个方案打算在原模型中另加一组只负责 Dead 检测的分支。出发点是：如果学习常见类和学习 Dead 时，模型参数需要朝相反方向调整，独立分支也许能缓解冲突。我们没有直接训练，而是先登记四项检查，全部满足条件才继续：

闸门	检查内容	结果
A	降门槛能否替代尺度增益	继续：9.59%，低于 50% 的换基线条件
C	仅调类别阈值是否已足够	继续：峰值 +0.002，低于 +0.005
D	找回漏检核还有多大空间	继续：理想化试验可增加 0.156
B	Dead 与常见类梯度是否冲突	未满足继续条件

“继续”不是说方法已有效，只表示这项检查没有阻止后续实验。其中，D 使用已知真值补回漏检核，称为 oracle 试验。它估计的是理想条件下的提升空间，不是模型实际取得的成绩。

B 的第一次测量无效。原计划顺序取前 256 张训练图，恰好全部来自乳腺组织，只有 1 张含 Dead。于是 64 批中有 63 批的 Dead 损失为零，却仍被计入分母，冲突比例再高也达不到继续条件。我们将它记为无效测量（VOID），没有把它当作反对假设的证据。修正方案先登记、补测试、经确认后再执行：分层抽取全部 65 张 Dead 阳性图，分母只计损失有效的批次。

重跑后，64 个有效批次的解码器复合梯度余弦平均为 +0.749、最小为 +0.594，没有负值。余弦为正，表示两组更新方向大体一致；为负才表示相互冲突。因此，在这个训练完成的检查点和这组代理损失下，没有出现方案所要求的冲突证据。

按照事先规则，DSB 停止，没有训练专家分支。需要区分的是：“当前测量不支持这项设计的前提”，不等于“整个训练过程从无冲突”，更不等于“所有专家分支都没用”。此前的重加权、平衡采样和阈值方案也只能说明各自被测设置的结果，不能把所有同类方法一并排除。

多一套模型，慢了多少？

原计时汇总中，原尺度模型约需每图 15.5 毫秒，两倍尺度模型约 52.9 毫秒，两套预测的 CPU 融合另需约 26 毫秒，合计约 94.4 毫秒，即单模型的 6.09 倍。10 月 9 日发现，旧算法将大小不同的图像块等权平均；用同一份记录改按图像数加权，并重选吞吐最高的一次重复后，比值修正为 **6.08447**，仍约为 **6.1 倍**。这不是新测量，旧表和旧图保留便于追溯。

作为参照，单模型测试时增强（TTA）约需普通推理的 4.66 倍时间（旧估计为 4.67 倍）。计时前向实际使用 bf16 自动混合精度，旧记录中的 fp32 标签有误。共享 GPU 的负载会影响绝对耗时：系统负载在 19–46 之间时，原尺度模型为每图 10.7–15.5 毫秒；两模型相对原尺度的比值在所测窗口内约为 6.1–6.3。M/S 后处理、模型加载等没有全部纳入，不能把它当成完整部署延迟。

因此，现阶段更稳妥的结论是：EF-P2 有助于研究两种尺度为何互补，也可能为以后训练更便宜的模型提供参考；但其教师作用尚未验证，现有小幅收益也不足以证明约六倍的成本值得付出。

哪些结果已经核对，哪些还没有？

10 月 8 日的审计核对了文档、代码和实验产物，并更正转录错误。例如，CellViT-UNI 三划分 bPQ 的旧值 0.6654 来自先舍入再平均，按原始汇总计算应为 **0.6653**。两个丢失产物也从保留的测试预测重建，数值与历史记录一致，并用哈希校验记录来源。当日全量测试 271 项通过；10 月 9 日增加防护修复后为 277 项通过。

不过，“主要数字核对通过”不等于“全部历史实验已经重跑”。部分 CONCH 探针没有留存缓存；P0–P3 的旧种子清单与后续同名目录存在来源冲突，完整检查因此停止，没有绕过。还有一个范围区别：**E2a、DSB、E0 的新实验没有使用测试折，但审计确实核对了历史测试产物**。本阶段没有新增三划分测试成绩。

下一步先看清候选里究竟有什么

EF-P2 新增候选中，一部分没有匹配到标注。它们可能是碎屑、轮廓不够准确的核，也可能是真实但漏标的核，不能仅凭“不匹配”确定原因。

截至本报告对应的实验阶段，下一步优先做 E1 独立盲审：从验证数据中抽取原尺度接受的候选、两倍尺度独有且被接受的候选、独有但被拒绝的候选，以及随机背景，让独立评审逐个判断，并允许回答“当前视野无法确定”。如果能找到可以可靠识别的有效候选，再研究如何学习筛选；如果主要是碎屑或边界问题，就先处理对应机制。盲审不是为了证明漏标一定存在，也不能用来反复修改已看过的测试结果。

新的训练路线仍需另行确认，本次没有启动。完整数字与复现说明见本目录的中文正式报告。