分型缺口能否补上，候选标签是否可信：上限诊断、共识审计与效用学习

PanNuke 细胞核实例分割：阶段报告五

课程项目 bdd26

2026 年 10 月 13 日

实验范围：2026 年 10 月 9 日至 12 日

摘要

阶段报告四结束后，项目留下两个悬而未决的问题：官方 mPQ 与不含类别的 bPQ 之间的分型缺口还有多少可学习的空间；两倍尺度补入的候选中，未匹配到标注的那部分究竟是什么，标签本身是否可靠。本阶段用五项实验回答这两个问题。分类上限诊断显示，保持实例轮廓不变、仅把已匹配对象改成真值类别，三划分平均 mPQ 从 0.4995 升至 0.6632；其中真值属于 Inflammatory/Connective 的修正贡献约七成。随后的预注册探针 T0–T3 检验简单读出能否兑现这一空间：最优配置仅 +0.0002（置信区间跨零），未加权线性头的 Dead PQ 下降 0.0053 触发护栏，判定门未通过，冻结特征的事后重分型路线就此收档。独立盲审因人类专家资源不可得而转为无专家方案：13 席跨折检测器对冻结候选的支持度远超合成空对照（支持度 ≥3 的比例 0.75% 对 66–73%），支持度对真值匹配率单调；两轮模型预审互相一致性差（kappa −0.09 至 +0.35），不可用。在此基础上，E1-T 分型共识审计显示，基模型分错的已匹配实例上，12 席评审团的多数类与基类一致的比例为 72.5% [0.706, 0.742]，与真值类一致仅 18.2%，两区间分离，而基模型分对实例上的本征翻票率只有 1.9%——按预注册解读键，Inflammatory/Connective 标签边界模糊的检测器共鸣证据成立。E3 候选质量学习把上述支持度纳入特征：效用本身可预测（交叉验证 AUC 0.721/0.737），但沿用冻结选择规则时，全部学得行被 strict Dead 门槛拒绝，三门皆未通过，按预注册规则停线。本阶段五项实验均未读取测试折，没有新的训练；全量测试 335 项通过，终版工件经评审后重跑并与首版逐位一致。

关键词：细胞核实例分割；PanNuke；标签噪声；检测器共识；预注册检验；候选筛选

1 研究背景与本阶段问题

阶段报告四厘清了两倍尺度的机制与成本 [1]：HV 面积门槛只解释小部分尺度增益，Dead 专家分支因梯度冲突前提不成立而按预注册规则停止，两模型系统约需单模型 6.1 倍推理时间。EF-P2 保留为机制证据和教师候选。在此之后，研究的重心从“再找一个检测改进”转向两个更基础的问题。

第一是**分型缺口**。基线 CellViT-UNI 的官方三划分 mPQ 为 0.4995，不区分类别的 bPQ 为 0.6653。两者之差意味着相当一部分已检出的核被分错了类别。此前 CONCH 实例重分类的负结果 [3] 说明外部图文特征帮不上忙，但当前模型自身特征里还有没有可利用的分型信息，一直没有正面检验过。

第二是**候选与标签**。EF-P2 从两倍尺度模型补入的候选中，53–61% 没有匹配到任何真值实例（验证折 55.9%，测试折历史口径 57–61%）。它们可能是碎屑、轮廓偏差，也可能是真实存在但被标注遗漏的核。10 月 9 日的建议稿 [2] 据此规划了并行两条线：固定几何的分型初筛（T 实验）与独立候选盲审（E1）。

本阶段的实际走向比计划多了一层转折。T 实验按预注册失败后，E1 又因人类专家资源不可得而改为无专家方案，随后派生出两项新实验（E1-T 分型共识、E3 候选质量学习），二者均在启动前预注册 [4]。全文按时间顺序报告这五项工作：第 2 节分类上限诊断，第 3 节 T0–T3，第 4 节 E1 材料包与无专家修订（E1-C/E1-M），第 5 节 E1-T，第 6 节 E3，第 7 节复核记录。

数据边界的约定与前一阶段相同。T、E1-C、E1-M、E1-T、E3 五项实验只使用训练折与验证折，未读取任何测试折；除 E1-C 为评审团补入的两席 HoVer-Net 验证折推理外，没有新的 GPU 推理，也没有任何训练。第 2 节的上限诊断是唯一的例外：它读取了已冻结、已经评测过的三划分测试预测，属于审计型访问，只读不调参，下文单独说明。

2 分类上限诊断：理想改类能到多少

这个诊断回答一个朴素的问题：如果每个已检出的核都被赋予正确类别，指标能到多少？做法是读取冻结的基线测试预测（无 TTA、最终检查点），保持实例数量与轮廓完全不变，只把 IoU>0.5 的已匹配对象改成其真值类别，再用与官方评测一致的评测器重算 mPQ[3]。这类使用真值的理想化干预称为 oracle，它给出的是“类别完全正确时的几何现状”，不是模型可达成绩。

表 1: 分类上限诊断（三划分平均，实例几何不变，仅改已匹配对象的类别）。第三行只修正真值属于 Inflammatory 或 Connective 的已匹配对象，不论其原预测为何。

干预	三划分平均 mPQ	相对原始
原始类别	0.49951	—
全部已匹配对象按真值改类别	0.66322	+0.16371
真值为 Inf/Conn 的已匹配对象按真值改类别	0.61412	+0.11461

三划分逐项为 $+0.169/+0.167/+0.155$，方向一致。split 1 的逐类变化（原始 $\rightarrow$ 全类别 oracle）为：Neoplastic $0.570 \rightarrow 0.666$，Inflammatory $0.440 \rightarrow 0.720$，Connective $0.418 \rightarrow 0.595$，Dead $0.142 \rightarrow 0.411$，Epithelial $0.575 \rightarrow 0.659$。Inflammatory 与 Connective 的抬升幅度最大；Dead 的绝对空间也很大，但它同时受漏检约束（漏检的核没有改类的机会）。

第三行约占第二行增益的 70%。这个比例需要小心表述：脚本只按**真值类别**筛选修正对象，包含了这两类被错分成任何类别的情况，修正也会减少其他类别的误报计数；mPQ 是非线性指标，70% 不是可相加的类别贡献分解 [3]。同样，oracle mPQ 0.6632 与 bPQ 0.6653 数值接近只是巧合，两者的匹配与汇总口径不同。

这次诊断访问了历史测试产物且未预注册，只能用于提出假设。它提出的假设很直接：分型缺口值得检验，而 Inf/Conn 边界是第一嫌疑。随后三节的实验都在验证折上检验这条线。

3 T0–T3：固定几何的分型探针

3.1 设计与判定门

T 实验 [4] 的假设是：不改动核的数量和轮廓时，实例级特征里可能仍有像素多数票没有用上的类别信息。开发限定 split 1：fold 1（63,218 个真值实例）训练读出头，fold 2（59,593 个预测实例）验证，fold 3 不读。四个配置在启动前冻结：

表 2: T0–T3 配置与验证折结果（mPQ，相对 T0 之差）。T1 的方括号为配对图像 bootstrap 95% 区间。

配置	内容	mPQ	Δ vs T0
T0	像素多数票（现行解码）	0.483486	—
T1	实例内类别概率均值	0.483182	−0.0003 [−0.0010, +0.0003]
T2	冻结 TP 特征实例池化 + 线性头	0.483707	+0.0002 [−0.0027, +0.0019]
T3	T2 + 24px 上下文环（等维求和）	0.481796	−0.0017

T0 精确复现官方 fold 2 评测；T2 报两个线性头种子（0.483606/0.483807）的均值，两种子同向。判定门共六条，要求同时满足：ΔmPQ ≥ +0.003、区间下界大于零、strict mPQ 不降、Dead PQ 下降不超过 0.002、超过 T1、种子方向一致。

3.2 判定：门未通过

六条中只有三条通过。+0.0002 远低于 0.003 的最低增量，区间下界 −0.0027 小于零；更关键的是第四条护栏：未加权线性头的 Dead PQ 相对 T0 下降 0.0053，超出 0.002 的容许幅度——简单读出非但在整体上无收益，还进一步亏欠最稀有的类别。sklearn 确定性交叉检查方向一致（0.4817，更差）。按预注册规则：不加大分类器，不加配置，先定位失败原因。

失败位置可以从三个准确率看出来。线性头在**真值区域**上的诊断准确率为 85.3%；它在验证折**匹配预测实例**上的分型准确率为 85.8%；而现行多数票在同样的人群上是 85.7%。三个数字几乎相同：线性头从冻结特征里读出的，正是 TP 分支已经在用的信息，没有增量；GT 特征导出耗时 790 ms/图（未优化单线程），也不存在部署价值。T1 的 −0.0003 同时说明聚合规则本身已近饱和。

与 CONCH 负结果合并，结论是：两个彼此独立的特征来源（外部病理 VLM、模型内部冻结特征）都无法通过事后实例级读出改善分型。bPQ 与 mPQ 之间的分型缺口，不能靠“换个读出头”来兑现。这为两种解释留下空间——标签本身模糊，或收益必须来自联合训练——分别由第 5 节的 E1-T 和后置的联合训练假设接手。

4 E1 的转折：从人类盲审到检测器共识

4.1 材料包与原协议

E1 原计划由两名合格评审对候选做两阶段盲审。材料包已按预注册生成 [4]：200 个窗口，四类来源各 50 个——x1 已检出的对象（S1）、EF-P2 接受的补入候选（S2）、被拒绝的候选（S3）、随机背景（S4），按组织与触边状态分层抽样并记录入样概率；第一阶段只给图像与十字标记，第二阶段才展示候选与真值轮廓；分析脚本在任何人给出答案之前提交入库。2026 年 10 月 11 日，用户确认人类专家评审在可预见未来没有资源。E1 的人类评审路径就此**未执行收案**：材料包保持不变，义务记录在案，未来若获评审仍可执行原协议。

经用户批准，E1 转入无专家方案（spec §7 修订）：以跨折检测器共识（E1-C）替代生物学判断，以非专家模型预审（E1-M）检验“模型评审”这条便宜路径是否可用。两者都只提供**检测器层面的证据**，不作生物学断言。

4.2 E1-C：候选的跨检测器共识

评审团 13 席：split 1 与 split 3 的三种子 × {x1, x2} 共 11 席 CellViT，加 HoVer-Net 两席（split 1/split 3，fold 2 推理，验证折 sanity mPQ 0.4509）。全部成员的训练折属于 {1, 3}，fold 2 从未参与任何成员的训练。候选为 split1_seed1 的冻结合格池 4,084 个（接受 1,515、拒绝 2,569），支持度定义为与候选 IoU≥0.3 的成员数。

共识证据需要一个对照来定标。合成空对照 [4] 在真值实例膨胀 8 像素之外随机放置同面积圆盘（面积重采样自零重叠候选分布，$n = 2{,}000$）：平均支持度 0.07，≥3 的比例 0.75%，≤1 的比例 99.1%。也就是说，随机位置几乎不会凑出多检测器一致。这个对照控制的只是随机基线，不控制检测器家族共享的核状误报模式。

表 3: E1-C 按支持度的真值匹配率（IoU>0.5）。支持度为 13 席中与候选 IoU≥0.3 的成员数。

候选组	数量	平均支持度	支持 0–2 匹配率	支持 ≥5 匹配率
S2（EF-P2 接受）	1,515	5.47	9.6%	55.3%
S3（EF-P2 拒绝）	2,569	5.04	8.5%	45.0%
合成空对照	2,000	0.07	≥3 比例 0.75%	

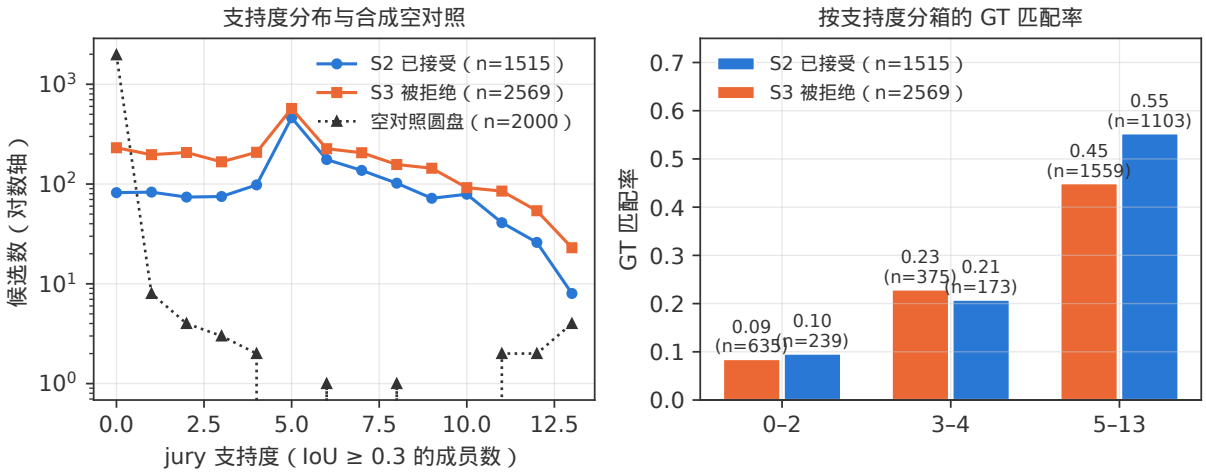


图 1: E1-C 支持度分布与按支持度分箱的真值匹配率。左：候选的支持度集中在 5–7 席，合成空对照几乎全在 0–1 席（对数轴）。右：真值匹配率随支持度单调上升。

两个来源的候选（无论 EF 规则接受与否）支持度都集中在 5–7 席，与空对照形成两个数量级的反差；真值匹配率随支持度单调上升。按与真值的关系分层后，画面更清楚：

- **与真值零重叠**的候选（S2 518 个、S3 1,146 个）平均支持度 4.8/4.4，其中获得 ≥3 席**且跨训练折、跨架构**支持的分别有 380 个（73.4%）与 751 个（65.5%）。跨折训练、跨架构的检测器只能从已标注的核泛化；它们在真值未覆盖的位置一致检出了核状对象，构成**标签可疑的检测器共鸣证据**。可能的解释包括标注单位差异、退化或凋亡对象被跳过、检测器家族共享误报模式，本实验不区分。
- **有重叠但未达匹配线**（$0 < \text{IoU} \leq 0.5$）的候选（S2 328 个、S3 582 个）支持度同样高。这与轮廓或实例单位不一致的机制相容：对象被看见了，但边界画法与标注不同。
- **碎屑相容**（支持 ≤1）的未匹配候选占 S2 的 10.0%、S3 的 15.5%。EF 的面积过滤与该子群方向一致，但区分能力有限。

工程含义直接写进了 10 月 11 日的下一步：支持度是候选质量的强预测子（单调、双源一致、有空对照定标），“低维特征 + 评审团支持度”的候选质量学习获得了证据基础。这就是第 6 节 E3 的由来。限制也如实记录：单一 (split1_seed1) 候选池；CellViT 占 11/13 席，跨架构证据主要靠两席 HoVer-Net；空对照是合成圆盘，不是核状形状。

4.3 E1-M：模型预审不可用

材料包的 200 个窗口顺带检验了“用视觉模型当评审”是否可行。两轮独立盲评分别走图像分析通道（passA）与另一模型的原生视觉通道（passB），标注者均为非专家模型。结果：passA 对 S1——几乎全为真实核的 x1 检出对象——只判 40.9% 为真，存在系统性“非核”偏置，理由高度模板化；passB 排序大体合理（S1 91.5% > S2 50.6%/S3 57.3% > S4 40.8%）但不确定率高达 34–70%。两轮之间原始一致率 0.18–0.38，kappa −0.09 至 +0.35：**模型评审连互相一致都做不到**。E1-M 仅完成其流程验证目的，事后印证了 spec 把模型评审排除出正式结论的决定。

5 E1-T：分型共识与标签边界

5.1 设计与预注册解读键

T 实验失败后留下的第一个待检验解释是“Inf/Conn 标签模糊”。E1-T[4] 用与 E1-C 相同的认识论检验它：在基模型（split1_seed1，x1，identity 解码）**分错类别**的已匹配实例上，未参与该预测的检测器是否系统性地支持基模型的类别而非真值类别?

评审团为 E1-C 的 13 席去掉基模型本身，剩 12 席（CellViT 10 + HoVer-Net 2，训练折 {1, 3}）。全部计算是缓存重放，CPU 完成，只读 fold 2。实例配对与官方评测一致（贪心 IoU≥ 0.5）；成员对某真值实例的类型票取其最大 IoU 实例（IoU≥ 0.3 才计票）的像素多数票类别。多数类的定义与基模型和真值都无关：总票 ≥ 3、严格胜出、且最高类收到两个训练折的票，否则记“无多数”。分组：G1 = 基分错（6,858 个），G0 = 基分对（40,558 个）；另有未匹配真值 12,456 个与歧义 0 个，合计 59,872，与 fold 2 真值实例总数核对一致。

预注册解读键写明：若 G1 的 Inf/Conn 对上“多数类 = 基类”的比例高于“多数类 = 真值类”，且聚类 bootstrap 区间分离，并高于 G0 的本征翻票率，则“Inf/Conn 标签边界模糊（检测器共鸣证据）”成立；反之以模型局限收档。Dead 的模式无论方向都单列，不并入结论。

5.2 结果：评审团站在基模型一边

表 4: E1-T 主结果。方括号为图像聚类 bootstrap 95% 区间（2,000 次，种子 20261011）。

统计量	比例	95% 区间
G1：多数类 = 基类	**72.5%**（4,970/6,858）	[0.706, 0.742]
G1：多数类 = 真值类	18.2%（1,246/6,858）	[0.167, 0.197]
G1：多数类为其他类	3.6%（247）	—
G1：无多数	5.8%（395）	[0.052, 0.064]
G0：多数类 ≠ 真值类（本征翻票率）	**1.9%**（767/40,558）	[0.017, 0.021]

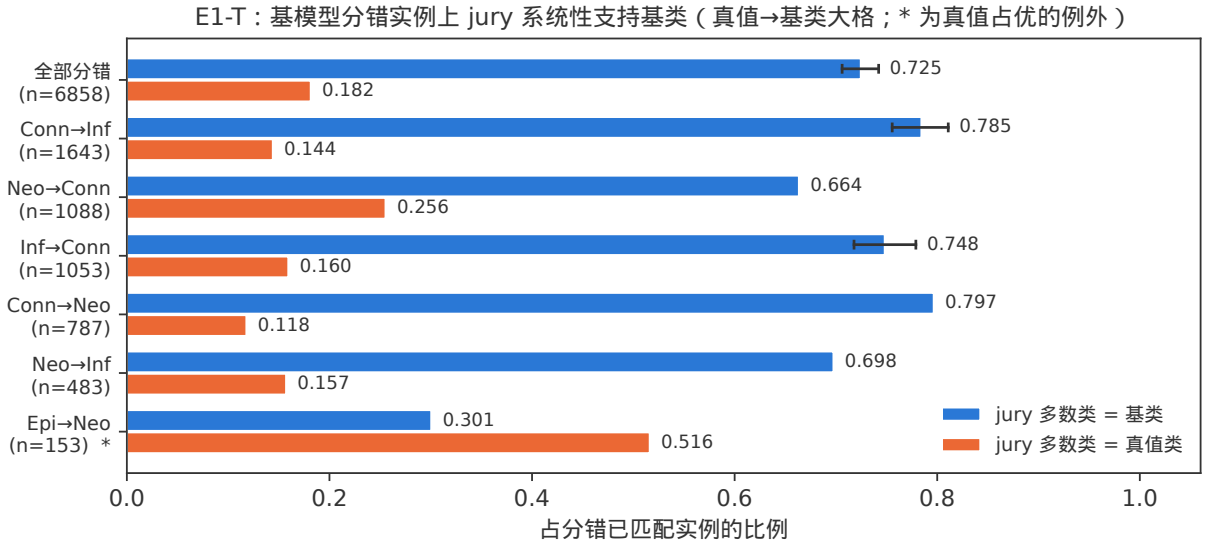


图 2: E1-T 主要（真值 → 基类）格上评审团多数类的归属。前三行带 bootstrap 区间（横线）。Epi→Neo（星标）是唯一真值占优的大格。

G1 内评审团多数类与基类一致的比例是 72.5%，与真值类一致只有 18.2%，两区间分离；作为对照，基模型分对的实例上评审团本征翻票率仅 1.9%。G0 的作用在于约束“纯回声”解释：如果评审团只是复制基模型的输出，G0 翻票率应接近零且 G1 应接近 100%，两者都不是。

按（真值 → 基类）分解，Inf/Conn 双向是最大的格子：GT=Inf、基 =Conn 的 1,053 例中 74.8% [0.718, 0.779] 支持基类；GT=Conn、基 =Inf 的 1,643 例中 78.5% [0.756, 0.811]。Neoplastic 指向 Inf/Conn 的两个大格（69.8%/66.4%）同向。唯一的例外是 GT=Epi、基 =Neo（153 例）：真值占优（51.6% 对 30.1%），单列不并入结论。Dead 相关格合计 404 例，多数类 = 基类的区间为 [0.573, 0.703]、= 真值类 [0.173, 0.282]，方向与 Inf/Conn 相同但幅度低、格内不均，按预注册只作描述。

三套敏感性检验同向：配对门槛提高到 IoU 0.5 时 72.0%；总票门槛提高到 5 时 72.3%；只用两席 HoVer-Net 组成子评审团时，基类 36.0% 仍高于真值类 20.2%（无多数 36.2%，G0 翻票 6.7%）——跨架构子集上信号变弱但没有反转。

5.3 结论与边界

按预注册解读键，**Inf/Conn 标签边界模糊的检测器共鸣证据成立**。它与 T0–T3、CONCH 负结果相互扣合：事后读出拿不到增量，不是因为特征里没有信息，而是读出的上限本身受标签噪声约束——在评审团一致支持基类的地方，监督信号把“正确答案”教成了基类的答案。据此，bPQ−mPQ 分型缺口中存在**不可由当前标签监督消除的成分**；联合训练的假设保持后置，不因本结果启动训练。

边界必须写清楚。这是检测器共鸣证据，不是生物学断言：评审团成员与基模型共享 CellViT 配方（10/12 席），其泛化模式与基模型相关；HoVer-Net 子评审团提供了唯一的跨架构对照，信号减弱但同向。单一划分（split 1 验证折）、单一基模型；“标签模糊”是对统计模式的解释，不是对 PanNuke 标注流程的指控。它与 E1-C 的存在性共鸣一起，构成分型轴与存在性轴两条标签质量证据链，但两类证据都止步于“标签可疑”，不量化噪声率。

6 E3：候选质量学习的开发轮

6.1 设计与五臂重放

E1-C 显示支持度单调预测候选的真值匹配。E3[4] 据此检验更强的命题：学习到的质量分数能否替代手工 EF 规则。训练数据是 fold 1 的 13,332 条折外候选（split 2 三种子生成，fold 1 是其验证折，折外成立），标签为冻结的 matched 列；应用侧是 split1_seed1 的 4,084 个冻结候选，在 fold 2 上重放五个手臂：A0 identity、A1 冻结 EF-P2（现任，a30d）、A2 纯面积区间、A3 低维特征学习质量（12 维：面积、延展率、圆度、距离、置信度、边缘余量、触边标记、类别 one-hot）、A4 加评审团支持度。模型为逻辑回归，超参由 fold 1 内部分组交叉验证选择。fold 3 零读取；fold 2 的匹配标签只允许出现在端点评测。

每臂内部的选择规则逐字沿用 EF 轮：在 mPQ、bPQ $\geq$ identity-0.002, strict Dead $\geq$ identity，内部 Dead 匹配数超过 identity 的候选行中，取验证 mPQ 最高者。A1 重放对冻结 EF-P2 选择做硬断言（差值 $\leq 10^{-12}$），其中 a30 变体曾逐位复现 EF 轮的 mPQ 0.48346，管线正确性由此锚定。

主门要求相对 A1：ΔDead $\geq +0.002$ 且 ΔbPQ ≥ -0.0005 且 Δstrict Dead ≥ -0.002；次门要求同等 Dead 增益下误报添加至少减少 25%。任一门通过则进入确认轮；两门皆否则停线，不加菜单、不换模型。

6.2 判定：三门皆未通过

表 5: E3 关键行的 fold 2 端点。学得行取 A2–A4 菜单中 strict Dead 最高者与描述性最优者两行；门值为各臂选中行相对 A1 之差。

行	mPQ	bPQ	Dead PQ	strict Dead	添加数	未匹配占比
A0 identity	0.48221	0.65093	0.16104	0.12957	0	—
A1 冻结 EF-P2	0.48346	0.65218	0.16714	0.13448	1,374	53.3%
a4_p0.7（学得行 strict 最高）	0.48395	0.65288	0.16547	0.12454	1,041	42.8%
a4_p0.5（描述性最优）	0.48487	0.65384	0.17011	0.12151	2,134	46.8%

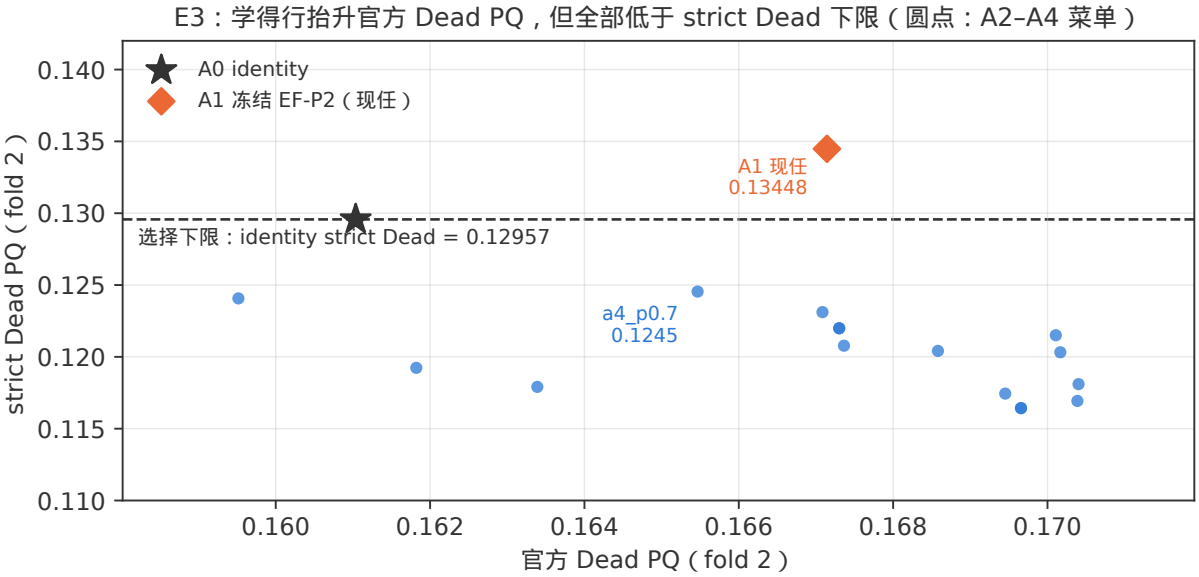


图 3: E3 全部学得行（A2–A4 菜单）的官方 Dead PQ 与 strict Dead PQ。学得行确实抬升官方 Dead PQ，但全部位于 identity strict Dead 选择下限之下；通过下限的只有现任 A1。

选择规则在 A2、A3、A4 的全部 16 个非恒等行上都拒绝了学得行——不是因为官方指标差，而是 strict Dead 门槛：学得行的 strict Dead 最高只到 0.12454，低于 identity 的 0.12957；A1 自己（0.13448）恰是通过这道门槛的少数行。三臂因此全部回落 identity，门值即 identity 相对 A1 之差：ΔDead -0.0061、ΔbPQ -0.0012、ΔmPQ -0.0012（bootstrap 区间全部低于或贴零，mPQ 区间 $[-0.00242, -0.00014]$）。主门、次门在三个臂上均为否，按预注册规则停线。

失败发生在哪一层？逐层看：

1. **效用本身可廉价预测**。fold 1 分组交叉验证 AUC：低维 12 特征 0.721，加支持度 0.737；低维臂在 fold 2 的可靠性曲线良好（均值 0.45 处实际率 0.49，0.65 处 0.62）。E1-C 的单调性假设在学得模型上成立，这一层没有失败。

2. **选择规则与端点冲突**。冻结的 EF 选择规则在 strict 轴上天然偏向少加候选；学得分数排序出的行全部越不过这条线。问题不在学不出效用，而在“候选级效用”与“图像级 strict 惩罚”不是一回事。

3. **描述性对照印证了盲区**。a4_p0.5 相对 A1 官方口径全面占优（ΔmPQ $+0.0014$、ΔbPQ $+0.0017$、ΔDead $+0.0030$，添加 2,134 对 1,374，未匹配占比 46.8% 对 53.3%），但代价是 strict Dead -0.0130。也就是说，官方口径上存在便宜的 Dead/bPQ 改善，但全部以缺类图像上的 Dead 误报为代价——候选级特征（面积、形状、置信度、支持度）看不见“这张图里本来有没有 Dead”。

4. **支持度臂的分布偏移被实测**。加支持度后交叉验证 AUC 提升 $+0.016$，但 fold 1 评审团（6 席 CellViT；HoVer-Net split 2 检查点已在两机磁盘清理中丢失，按 spec 应有的第 7 席缺席，偏差已披露）与 fold 2 评审团（13 席跨折跨架构）构成不同：fold 2 上 0.84 置信箱的实际匹配率只有 0.58，校准劣化，AUC 增益没有转化为端点。

对 10 月 9 日建议稿的映射：E1 支持的“候选质量学习”分支就此收档。简单质量模型（含评审团支持度）不能在官方与 strict 联合口径上替代 EF 规则；若将来重开，需要的是**图像级缺类风险特征**（如该图的 Dead 先验、组织条件），而不是更复杂的候选级头。这构成一个新的可检验解释，但不自动立项。EF-P2 的定位（机制证据/教师候选）不变。

7 过程记录、复核与测试

本阶段的实现遵循先测后码，多起真实缺陷由护栏与断言在运行中捕获后修复重跑，较为关键的几起：分型探针的类别查找差一（缓存标签行确定性修复后特征逐位一致）；逐图重建的类型查找表曾用全局编号错连图像（改为逐图构建）；E1-T 的多数类语义从“唯一值”改为像素多数票（真实数据存在 164 个未类型化实例）；E1-T 条件 bootstrap 两处口径缺陷（组外行计 0 而非 NaN；先判事件后判组员）由迷你夹具单测暴露；E3 的现任绑定曾误用 a30 行——a30 逐位复现暴露现任实为 a30d，改从冻结选择文件派生地板并加断言。

全分支独立评审之后，E1-T 与 E3 的终版工件重跑再生成，与首版逐位一致（E1-T 全部一致；E3 除 bootstrap mPQ 列外一致，该列口径修正为官方 NaN 排除规则后，identity−A1 的 ΔmPQ 区间由 $[-0.00232, -0.00002]$ 改为 $[-0.00242, -0.00014]$，结论不变）；来源记录补全（EF 选择行、依赖模块指纹、fold 2 真值哈希）。文档与产物的一致性审计 56 项全部通过，其中两处描述数字按产物修正（支持度臂 0.84 置信箱实际率 0.58 而非 0.55；支持度 AUC 增益 +0.016 而非 +0.017）。全量回归测试 **335 项通过**（本阶段净增 58 项），依赖环境不变。

8 局限与下一步

8.1 本阶段的局限

1. **全部证据止于单一开发环境**。T、E1-C、E1-M、E1-T、E3 都在 split 1 的验证折上，基模型单一（split1_seed1）；E3 的训练侧虽覆盖 split 2 三种子，应用侧仍是单一候选池。所有比例的置信区间只反映图像抽样不确定性。

2. **共鸣证据不是生物学结论**。评审团与基模型共享训练配方与架构家族；空对照是合成圆盘；两类标签证据都只能说“标签可疑”，不能量化噪声率，也不能区分漏标、单位差异与共享误报。

3. **E3 是开发轮判定**。“三门皆负”针对冻结菜单与冻结规则；它否证的是“廉价候选级特征可替代 EF 规则”，不是所有质量学习。

4. **上限诊断读了测试产物**。第 2 节访问了历史测试预测（只读、无调参、无新推理），其余实验未读测试折；本阶段没有新增三划分测试成绩，测试折多轮复用的历史限制不变。

5. **HoVer-Net 席位不完整**。split 2 检查点丢失使 E3 的 fold 1 评审团缺少跨架构席位；E1-C/E1-T 的跨架构证据依赖仅有的两席。

8.2 下一步

分型轴与存在性轴的标签质量证据链已经闭合，两条学习线（事后读出、候选效用）都以负结果收档。下一步的候选方向按证据强度排序：

1. **把标签模糊写进最终报告的分析框架**。Inf/Conn 边界模糊改变了“分型缺口 = 模型缺陷”的默认解读；组织 × 类别的误差分解应与共鸣证据对照呈现，而不是把缺口全部记为模型损失。

2. **图像级缺类风险特征**。E3 留下的可检验解释：预测“这张图有没有某类”可能比预测“这个候选是不是核”更接近 strict 轴的痛点。若立项，须先写规格（进入条件、对照、停止规则），沿用本轮的预注册纪律。

3. **联合训练假设保持后置**。它同时改容量、特征与优化日程，只有在标签解释与特征解释都被排除后才值得承担这个成本；当前证据不支持启动。

4. **人类评审义务保留**。E1 材料包不变；若未来获得两名合格评审，原协议可直接执行，届时共鸣证据与生物学判断可以对照。

在上述任何一项立项之前，不启动新的训练，也不在已多轮观察的测试图上扩大筛选规则。

9 结论

本阶段把阶段报告四遗留的两个问题推进到了有证据的回答。

第一，**分型缺口不能靠事后读出兑现**。真值辅助的类别修正能把 mPQ 从 0.4995 抬到 0.6632，其中约七成与 Inflammatory/Connective 相关；但固定几何的简单读出（聚合、线性头、上下文环）拿不到任何增量，Dead 反而受损。E1-T 随后给出机制层面的解释：基模型分错的实例上，跨折跨架构评审团以 72.5% [0.706, 0.742] 支持基类、仅 18.2% 支持真值类，而分对实例上的本征翻票率只有 1.9%——Inf/Conn 标签边界模糊的检测器共鸣证据按预注册键成立。读出上限受标签噪声约束，这部分缺口不是当前监督可以消除的。

第二，**未匹配候选不是噪声，效用可预测但替代不了规则**。与真值零重叠的候选中 66–73% 获得跨折跨架构的多检测器支持（空对照 0.75%），标签可疑的共鸣证据在存在性轴上同样成立；支持度单调预测匹配率，学得质量模型的交叉验证 AUC 达 0.721/0.737。但沿用冻结选择规则时，全部学得行被 strict Dead 门槛拒绝，官方口径的改善全部以缺类误报为代价，E3 按预注册规则停线。

过程面：五项实验中四项纯 CPU 重放、一项含两席验证折推理，未读取测试折、无新训练；335 项测试通过，终版工件重跑逐位一致，文档-产物审计 56 项通过。两条学习线的负结果与两条标签证据链的正结果，共同把项目的下一步指向标签条件下的分析框架与图像级风险特征，而不是更多的读出头或更宽的筛选菜单。

A 文件、数字与复现入口

A.1 数值核验

本报告全部表格数字由 `scripts/report5_numbers.py` 从五份冻结产物导出（快照 `runs/analysis/report5_numbers.txt`）；`scripts/verify_report5.py` 从最底层可用产物独立重算并核对——包括：oracle 当前值与官方基线评测逐位一致、T 判定门布尔值由存储数值重推、E1-C 支持度直方图与匹配率从 `per_candidate.npz` 加冻结候选记录重算、E1-M 一致率与 kappa 从两轮 CSV 重算、E1-T 分组计数总和等于 fold 2 真值实例数且区间括住点估计、E3 选择规则在全部行上重放并与冻结选择一致——结果写入本目录 `verified_numbers.json`。bootstrap 区间沿用冻结结果，不重新抽样。第 4.2 节的零重叠分层计数由 `per_candidate.npz` 与候选记录的联表重导，因为 `consensus.json` 只存聚合值。

图表由 `scripts/make_report_figures5.py` 从同一批产物生成，数值与 `figs/` 内冻结 CSV 一致。

A.2 产物与复现命令

表 6: 主要实验产物，均相对仓库根目录；`runs/` 下为本地产物，不随 Git 分发。

路径	本报告用途
`runs/analysis/typing_oracle_20261009/`	分类上限诊断三行表与逐类结果。
`runs/analysis/typing_probe_20261010/`	T0–T3 端点、判定门与诊断列。
`runs/analysis/e1_packet_20261010/`	E1 盲审材料包（200 窗口，两阶段协议，待评审）。
`runs/analysis/e1_consensus_20261010/`	E1-C 共识、空对照、E1-M 两轮盲评。
`runs/analysis/e1t_typing_20261011/`	E1-T 分组、逐格、bootstrap 与敏感性。
`runs/analysis/e3_quality_20261011/`	E3 五臂端点、选择重放、模型诊断。
`runs/analysis/report5_numbers.txt`	本报告逐表数字快照。

在固定依赖环境、仓库根目录执行：

```
python scripts/report5_numbers.py
python scripts/verify_report5.py
python scripts/make_report_figures5.py
python -m pytest -q
```

核验脚本在产物缺失或数值不一致时以错误状态退出，不修改实验产物。

参考文献

[1] bdd26 项目. 阶段报告三、四：跨尺度候选筛选与机制对照 [R]. 2026-10-06/08. `docs/report/stage_report_3/`; `docs/report/stage_report_4/`.

[2] bdd26 项目. 下一步研究计划：先验证能否学到，再决定是否扩展（2026-10-09）[R]. `docs/RESEARCH_NEXT_2026-10-09.md`.

[3] bdd26 项目. 模型结构、实验复盘与后续方向（2026-10-09 修订）[R]. `docs/STRUCTURE_AND_STRATEGY_2026-10-09.md`.

[4] bdd26 项目. 本阶段预注册规格：T 探针、E1 盲审及无专家修订、E1-T 分型共识、E3 候选质量 [R]. 2026-10-10/11. `docs/superpowers/specs/2026-10-10-typing-probe-t-design.md`; `docs/superpowers/specs/2026-10-10-e1-blind-audit-design.md`; `docs/superpowers/specs/2026-10-11-e1t-typing-consensus-design.md`; `docs/superpowers/specs/2026-10-11-e3-candidate-quality-design.md`.

[5] bdd26 项目. 实验日志：2026-10-09 至 10-12 条目 [R]. `docs/findings.md`.

[6] GAMPER J, ALEMI KOOHBANANI N, BENES K, et al. PanNuke Dataset Extension, Insights and Baselines[EB/OL]. 2020[2026-10-06]. `https://arxiv.org/abs/2003.10778`.

[7] HÖRST F, REMPE M, HEINE L, et al. CellViT: Vision Transformers for precise cell segmentation and classification[J]. Medical Image Analysis, 2024, 94: 103143. DOI: 10.1016/j.media.2024.103143.

[8] CHEN R J, DING T, LU M Y, et al. Towards a general-purpose foundation model for computational pathology[J]. Nature Medicine, 2024, 30(3): 850–862. DOI: 10.1038/s41591-024-02857-3.

[9] GRAHAM S, VU Q D, RAZA S E A, et al. Hover-Net: Simultaneous segmentation and classification of nuclei in multi-tissue histology images[J]. Medical Image Analysis, 2019, 58: 101563. DOI: 10.1016/j.media.2019.101563.

[10] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and Psychological Measurement, 1960, 20(1): 37–46. DOI: 10.1177/001316446002000104.