分错的细胞核，是模型没学会，还是标签本身说不清？

阶段报告五导读

课程项目 bdd26

2026 年 10 月 13 日

本阶段结果

上一阶段结束后，我们注意到：模型找核的能力（用不区分类别的 bPQ 衡量，约 0.665）明显好于它认类别的能力（官方 mPQ 约 0.500）。本阶段进一步检查这部分分类误差，得到两个结论：

- **所测试的事后分类方法未带来改善**。如果直接用真值纠正每个已匹配核的类别，mPQ 能从 0.4995 涨到 0.6632；但我们试了四种分类方案，最好的一种只提高 0.0002，未加权线性分类器还降低了最稀有 Dead 类的表现。
- **检测器一致性结果提示部分标签边界可能不清**。模型分错的核里，由 12 个“没见过这批图”的检测器组成的评审团在 **72.5%** 的实例上给出与基模型一致、却与标注不同的类别，只有 18.2% 支持标注答案；而模型分对的核上，评审团改判率只有 1.9%。最集中的模糊带在炎症（Inflammatory）与结缔（Connective）两类之间。

另外，我们原计划请人类专家盲审候选核，但缺少专家评审资源。改用“检测器评审团”后，得到一个附带发现：在标注完全没覆盖的位置，有 66–73% 的候选核能获得多个不同检测器的一致检出——作为随机空对照的圆盘只有 0.75% 的概率出现这种一致。

上限诊断：如果类别全对，能到多少？

先做一个思想实验：保持核的数量和轮廓不变，只把每个与真值匹配上的核的类别改成真值类别，指标能到多少？这种用标准答案做的理想化试验叫 oracle。结果：三划分平均 mPQ 从 0.4995 到 **0.6632**；如果只改真值属于炎症或结缔的核，能到 0.6141，约占全部增益的七成。

这个数字是保持现有轮廓时的理想分类结果，不是模型能达到的成绩。它只说明：类别方向值得查，而且炎症/结缔是需要优先检查的类别组合。（这个诊断读了历史上的测试预测，属于只读的审计操作；后面所有新实验都只用训练和验证数据。）

四种分类方案均未达到预设条件

我们在验证折上比较了四种不改几何的改类方法：现行多数票（T0）、实例内概率平均（T1）、把模型内部特征池化后接一个线性分类器（T2）、再加一圈周边上下文（T3）。事先写好的通过条件是 mPQ 至少提高 0.003、区间不含零、Dead 类不倒退超过 0.002 等。

结果均未达到通过条件。最好的 T2 只有 +0.0002，置信区间跨零；T3 是 −0.0017；T2 的 Dead 还下降了 0.0053，超出预设的容许幅度。失败原因可以从三个准确率看出来：线性头在真值区域上判对 85.3%，在预测实例上判对 85.8%，而现行多数票本来就有约 85.6%——**新分类器未从冻结特征中获得额外的有效分类信息**。加上此前外部病理模型（CONCH）重分类也失败，本阶段结束所测试的事后分类实验。

缺少专家评审后的替代安排

下一步本该请两名合格评审对 200 个窗口盲审（材料包已备好，评审规则事先冻结）。但已确认无法安排专家评审。经批准改为两件事：

让检测器当评审（E1-C）。13 个成员组成评审团：两种架构、多个随机种子、两个训练折，都不曾见过待审的验证折。每个候选核数一数有多少成员也检出了它（IoU≥0.3 记一票）。为估计随机位置获得共同支持的概率，我们做了个空对照：在真值核之外随机放 2,000 个同样大小的圆盘，它们平均只得到 0.07 票，得到 3 票以上的只有 0.75%。

实际候选的支持度明显较高：不管 EF 规则接受还是拒绝，平均都有 5 票上下；与真值匹配的比例随票数单调上升（0–2 票约 9%，5 票以上 45–55%）。其中值得关注的是与标注**零重叠**的那批候选：其中 66–73% 拿到 3 票以上、且票来自不同训练折和不同架构。多个独立训练的检测器在同一位置一致看到“像个核”的东西——这构成**标签可疑的证据**（可能是漏标，可能是标注单位不同，也可能大家共享某种误报模式；我们不下生物学结论）。

让视觉大模型当评审（E1-M）。两轮独立盲评互相之间的一致性极差（kappa 在 −0.09 到 +0.35 之间），其中一轮对几乎全为真核的对照组只判 40.9% 为真。结论：模型评审目前不可用，这次只是验证了流程。

分类审计：多数票更常与基模型一致

有了评审团，可以进一步检查：模型**分错**的核，评审团怎么看？

把验证折上 6,858 个分错的已匹配核拿出来逐个投票（评审团去掉与被审模型同源的成员，剩 12 席）。规则事先冻结：得票最多的类需要总票数至少 3、严格领先、且票来自两个训练折。结果：**72.5% 的核上，评审团的多数类别与基模型一致、却与标注不同**；与标注一致的只有 18.2%，两个比例的置信区间完全分开。作为对照，模型分对的 4 万多个核上，评审团改票的比率只有 1.9%——说明评审团并非完全复制基模型的输出，但仍可能与其共享偏差。

按分错的类型看，模糊带非常集中：真值炎症、模型判结缔的 1,053 例中 74.8% 支持模型的判断；反方向 78.5%。主要混淆组中的例外是真值上皮、模型判肿瘤的实例，那里标注答案反而占优（51.6% 对 30.1%）。Dead 相关的混淆组方向相同但样本少，单独记录。

按事先登记的判读规则，这一结果**支持炎症/结缔标签边界模糊的解释**，也为简单分类器未能改善分型提供了一种可能原因。不过，检测器意见一致并不等于它们的判断在生物

学上正确：多数成员属于 CellViT 家族，可能共享相似的误判。现有实验既不能证明标注错误，也不能断定继续训练无法改善分类；这些问题仍需独立证据。

候选筛选：预测能力未转化为严格指标的改善

E1-C 显示“票数”能预测候选核的好坏。于是我们训练了一个逻辑回归，用面积、形状、置信度等 12 个计算成本较低的特征（另一组方案再加入评审团票数）预测每个候选能否匹配真值。模型有一定预测能力：交叉验证 AUC 0.721，加票数 0.737。

但把它接进实际流程后，按事先冻结的选择规则，三组候选方案全部退回“不加任何候选”。原因在一个具体的门槛上：选择规则要求 strict Dead（对“图里没有 Dead 却报出 Dead”也计罚的严格指标）不能低于不加候选的基线 0.12957，而所有候选配置最高只有 0.12454。反过来说，候选配置在官方口径上其实更好（有一个配置 Dead、bPQ、mPQ 三项全升），代价是 strict Dead 掉 0.013——**现有特征能预测候选是否匹配核，却不足以控制缺类图像上的误报**。按预注册规则，这条线停止，不扩展候选配置，也不更换模型。

这一结果提示：如果将来重开，该学的是**图像级**的缺类风险（比如这张图按组织类型看有没有 Dead），单纯增加候选打分模型的复杂度未必能解决这一问题。

哪些结果核对过，边界在哪里

全部表格数字在写报告前从冻结产物重新导出并独立核验（核验脚本会重放选择规则、重算一致率，对不上就报错退出）；此前全量测试 335 项通过；两项实验的终版产物在独立评审后重跑，除 E3 的 bootstrap mPQ 统计口径修正外，与第一版逐位一致。

边界也要讲清楚：所有新实验都在单一划分（split 1）的验证折上，基模型只有一个；“标签可疑”是统计证据，不能量化漏标率；评审团 12 席中 10 席与被审模型同属 CellViT 家族（两席 HoVer-Net 是仅有的跨架构对照，差异减小，但方向一致）；本轮没有新的测试集成绩；仅拟合了线性分类器和逻辑回归，未新增分割模型训练。人类专家评审仍待完成：材料包不变，将来若有两名合格评审，原协议可以直接执行。

下一步优先做的事，是把“标签模糊”写进最终报告的分析框架（组织 × 类别的误差分解要和评审团证据对照呈现），以及评估图像级缺类风险特征是否值得立项。在这两件事之前，不启动新的训练。

完整数字、判定规则与复现命令见本目录的正式报告。