从“能拟合”到“能可靠地找到”

核实例分割研究阶段报告 6

Xinhao Jin • Biomedical Data Design

研究范围：2026 年 10 月 13 日至 10 月 26 日
日期与作业时间采用美国东部时间

摘要

阶段报告 5 结束时，简单的事后分型与候选质量学习都没有通过预设条件。本阶段把问题进一步移到训练和实例生成过程：裁切造成的可见性变化能否用监督修复？集合查询为何丢失实例？先预测中心点、再生成掩码是否值得推进？

现有结果没有产生可以进入三划分确认的新方法，但让几个容易混淆的问题分开了。裁切敏感性真实存在，所测试的可见性监督却未能修复它；查询模型能产生一部分可用的原始掩码，却在分类保留和像素竞争后丢失很多对象；点检测可以把拟合图像记得很准，换到留出图像后仍缺少可靠的召回与精度。增加训练预算、重采样稀有类、限制骨干更新等具体办法，尚未改变这一局面。

报告围绕每条路线的核心问题展开：实验改变了什么，结果揭示了什么，下一步应当怎样调整。最新 P16 仍只取得一个种子的完整结果；新一轮 P17 将卷积金字塔检测器与原 UNI 检测器作独立对照，检验不同表征配方是否值得继续研究。

进度快照（10 月 26 日 09:27，美东时间）：P16 seed 19 两组完成，seed 1 对照/处理组为 85/73 轮。P17 已通过 V100 验证；正式数组 **55297061** 于 **09:08:19** 提交，四项均在排队。

目录

1 本阶段改变了什么 **3**

1.1 哪些属于方法结果，哪些只是诊断 3

2 可见性：发现脆弱点，不等于找到了修复办法 **4**

2.1 裁切审计给出了什么证据 4

2.2 四组完整训练没有支持选择性监督修复 4

3 集合查询：瓶颈出现在实例生成的整条链上 **5**

3.1 完整训练的退化远大于小幅种子波动 5

3.2 原始掩码为什么没成为最终实例 5

4 小规模诊断把“可表示”和“可推理”分开 **6**

5 门控与高分辨率适配：局部正信号为何没有完成主目标 **7**

5.1 失败交集揭示了哪些对象值得继续研究 7

6 中心点路线：学会训练图像，仍没有学会可靠迁移 **8**

6.1 P1-R1 排除了“原来只是没训够”的充分解释 8

6.2 P3 把表征适配和训练增强分别检验 8

6.3 怎样决定是否继续 9

7 P4–P15：从连续对照中归纳失败模式 **9**

7.1 负结果至少有三种不同形态 10

8 最新结果与下一轮实验 **11**

8.1 P16：完整 Gaussian 回归，目前只报告一个种子 11

8.2 P17：把卷积表示作为独立配方检验 12

9 研究推进与算力迁移 **12**

10 当前能下的判断，以及还缺什么 **13**

A 证据索引与复核范围 **14**

1 本阶段改变了什么

上一份报告主要回答“分错类别是否能靠读出已有特征来修正”。本阶段换了一个更靠前的问题：在不告诉模型真值位置的情况下，它能否先产生一组找得全、报得准的实例，再把这些实例转成可靠的分割结果？这条路径与 Dead 类问题有关，也关系到拥挤区域的实例分离和不同组织上的稳定性。Dead 沿用数据集类别名，包含凋亡和坏死相关细胞核，不等同于“凋亡”。

1.1 哪些属于方法结果，哪些只是诊断

本阶段使用三种口径。第一种是完整分割模型在 fold2 上的开发验证：mPQ 同时考虑实例轮廓、匹配和类别，bPQ 不区分类别，strict Dead 还惩罚缺类图像上的 Dead 误报。第二种是训练折内部按图像留出的点检测研究，衡量预测中心能否在原生图像 3 像素半径内与真值唯一匹配；它不检查掩码轮廓，因此不能当作 PQ。第三种是给定真值位置或对应关系的拟合试验，用来判断网络是否存在可拟合空间；这种帮助在实际推理时拿不到。

下文分别报告分割质量、点匹配和训练内诊断，跨实验比较时以相同任务、相同队列和同轮对照为准。

研究部分	主要证据	目前的判断
可见性监督	受控裁切审计；四组、双种子完整训练	敏感性成立，所测试的监督修复未通过
集合查询分割	E6/E7 完整训练；输出阶段逐对象诊断	配方发生全局退化，简单日程调整未救回
高分辨率适配	E19 双种子对照及失败对象交集	单 skip 残差适配器未修复内部 Dead 召回
中心点检测	P1-R1、P3–P15 的拟合/留出对照	高拟合未形成可靠泛化，现有配方未获扩量资格
最新实验	P16 单种子完整结果；P17 独立新设计	P16 待收齐；P17 检验卷积表示配方

各轮采用提前固定的主目标和质量约束。局部指标的改善会保留记录，但研究是否继续，由整组条件共同决定。

本节依据：阶段报告 5；10 月 15 日研究综合；E 系列 10 月 18 日复盘；P3–P15 综合。历史结果在本轮核对当前文档，未重新运行全部旧模型。

另完成了 Inf/Conn 类别合并审计：合并空间的官方指标增约.0519，理想分类上限差距缩小约 35.2%。这包含合并类别本身的机械收益，不能当作标签模糊损失的估计；五类方法分数不变。

2 可见性：发现脆弱点，不等于找到了修复办法

2.1 裁切审计给出了什么证据

E4 先比较原图贴边与内部对象，再对原本完整的核施加固定裁切。修正后的结果中，按面积分层的原图贴边减内部 Dead 漏检差为 $+0.1738$，95% 区间为 $[0.1060, 0.2528]$；受控裁切的差中差为 $+0.1474$，而插值对照仅约 -0.0006。新截断对象中，小于 30 原生像素的碎片比至少 100 像素的对象，漏检率高 0.8175，区间为 $[0.7968, 0.8393]$。这些结果支持继续研究裁切相关脆弱性。

这一步曾有一次重要修正：早期版本包含 train 模式推理和未按面积分层的判定。正式依据是 10 月 14 日修正后的产物，不能继续引用旧版本作为有效结论。即便修正后通过，也不能由此认定“HV 目标被置零”就是全部漏检的原因；被裁切的图像同时改变了可见面积和上下文。

2.2 四组完整训练没有支持选择性监督修复

随后比较 A0 原始训练、A1 裁切增强、A2 裁切增强加选择性 HV 监督、A3 更广泛的小目标监督。两种子各训练 130 轮，使用最后检查点，在原图和固定裁切图上分别评估。

两种子平均变化	mPQ	bPQ	Dead PQ	strict Dead PQ
A1−A0	−.005284	−.006122	+.037648	+.008833
A2−A0	−.006269	−.005438	+.024565	−.000948
A2−A1	−.000985	+.000685	−.013083	−.009781

表 1: fold2 原图开发结果。平均值描述两个固定种子，不能据此自行补出显著性。

裁切增强 A1 的 Dead 指标确有正信号，但伴随总体分割质量下降。A2 不仅未能消除代价，较 A1 的 Dead 和 strict Dead 还在两个种子上同时下降。原图质量约束因此失败。

更直接的裁切机制检验只由 38 张图中的 116 个符合条件的 Dead 对象支持。A1−A2 的漏检改善在两个种子上分别为 $-.025862$ 和 $+.008621$，平均 $-.008621$，95% 区间 $[-.040918, +.017699]$。正值才代表 A2 少漏检，实测没有达到要求。

这组实验将现象与干预分开了：裁切敏感性有明确证据，而本轮选择性监督没有带来预期改善。研究线索仍在，具体修复配方到此停止。

本节依据：E4_VISIBILITY_PROBE_2026-10-13；VISIBILITY_SUPERVISION_DEV 与 MECHANISM_2026-10-15。E4 修正产物日期为 10 月 14 日。

3 集合查询：瓶颈出现在实例生成的整条链上

3.1 完整训练的退化远大于小幅种子波动

E6 把密集分割基线 B 与查询掩码模型 Q 作匹配对照；E7 再单独将学习率衰减系数从.85 改为.99，检验过快衰减是否足以解释失败。各轮均为两组乘两个种子、每次 130 轮，fold1 训练、fold2 开发验证。

实验	模型	mPQ	bPQ	Dead PQ	合并率
E6	B 密集基线	.481432	.650773	.179635	.045363
E6	Q 查询掩码	.102699	.192614	.005951	.285885
E7	B 密集基线	.472939	.650651	.131493	.051209
E7	Q 查询掩码	.087958	.169912	.006287	.219744

表 2: 各轮两个固定种子的均值。只能与同轮匹配基线比较。

Q 的五类 PQ 和全部 19 个组织的 mPQ 都低于对应 B。E6、E7 内部 Dead 的 IoU> .5 匹配率变化分别为 −.507422 和 −.528340，对应区间都完全低于零。减慢衰减没有恢复基本实例质量。成本检验虽然通过，也不足以使这样的质量损失变得可接受。

这不等同于“模型完全看不到核”。E6 中，内部 Dead 的 IoU 处在.1 到.5 之间的比例从约 9.99% 上升到 55.60%。大量对象有部分重叠，却没有形成合格实例，涉及定位、轮廓及实例分离，不能统称为完全漏检。

3.2 原始掩码为什么没成为最终实例

对 E7 的同一批 16 张训练图、331 个目标，进一步追踪所有查询中的最佳匹配，而非只盯着训练时分配给该目标的查询。

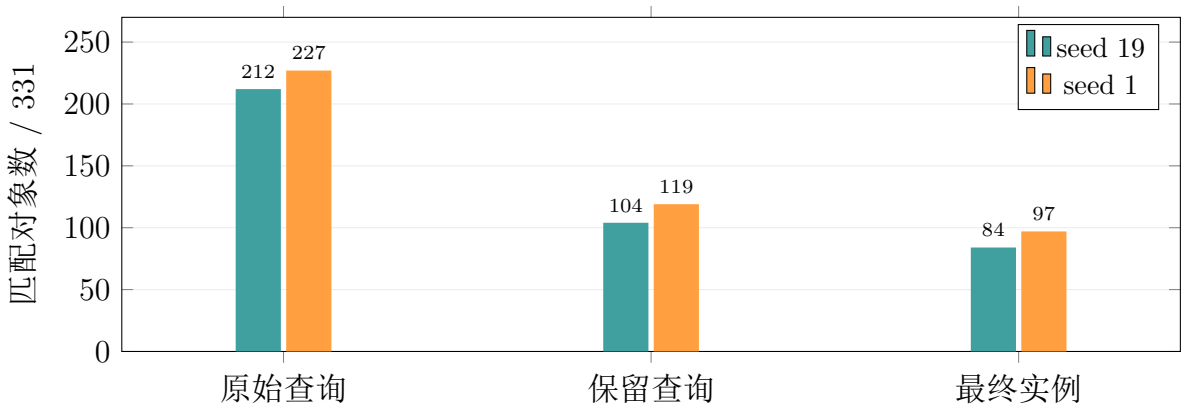


图 1: E7 的固定训练批次诊断。所有原始掩码阶段使用真值寻找最佳重叠，展示真值辅助的原始掩码覆盖情况；各阶段达标对象并非严格包含关系。

seed 19 从 212 个原始达标对象降到保留查询中的 104 个，完整解码后剩 84 个；seed 1 为 227、119、97。原始掩码到查询保留，两种子都损失 108/331，即 32.63 个百分点；像素竞争后的净损失又约 6 个百分点。直接降低置信度阈值不能解决背景 argmax 的拒绝，而且原始掩码覆盖率本身也只有 64%–69%。

后续诊断据此分成三个环节：生成轮廓、判断对象、处理重叠。每个环节都对应可测量的对象损失。

本节依据：SET_MASK_E6_DEV_2026-10-16；SET_MASK_E7_DEV_2026-10-17。

4 小规模诊断把“可表示”和“可推理”分开

E8–E18 没有直接继续扩大完整模型，而是针对分类读出、查询初始化、注意力、监督和对象对应关系做训练内诊断。它们的价值在于排除具体修补方案，也暴露了一种容易误判的正结果：给了真值帮助以后可以拟合，不代表正常推理时能自己找到对象。

实验	改变或检查的部分	结果及其边界
E8	冻结特征，仅调整分类读出	前景拟合准确率约 95%–98%，但留出图像的前景判断下降，未通过分配条件。分类读出改善并未转成可靠实例集合。
E9	用局部内容初始化查询	Dead 几何召回的小幅点估计改善伴随精度下降；两种子均未通过，不能据此直接扩训练。
E10	预测掩码限制注意力	两种子的内部 Dead 变化为 −.067511/ + .008439，总体召回也下降；未解决原问题。
E11	四阶段辅助监督	原分配条件和独立 A0 约束均失败，停止该固定配方。
E12/E13	真值辅助的自由系数或稳定投影	E12 两种子拟合 Dead 为 86.32%/87.37%，证明有限条件下可拟合；E13 冻结投影后质量条件仍失败。
E14	精确的原生匹配	匹配本身完成，但实例分配和 A0 约束仍未通过，不能把更精确的匹配等同于方法有效。
E15/E16	真值点读出及点条件掩码	E16 真值点条件下原始掩码覆盖率（IoU > .5）：拟合图像 Dead 为 84.21%/80.26%，本轮读出留出图像为 31.58%/42.11%；冻结 E7 已见过这些图，不是整模型独立泛化证据。

实验	改变或检查的部分	结果及其边界
E17	预测稀疏点产生候选	固定训练诊断中没有输出候选，当前配方失败。
E18	稠密投票产生候选	候选过多，最终实例推理的审计精度约 3.5%–3.7%；这不是后续 P3 的半径 3 像素点指标。

这些诊断重复使用了很小的队列，既不是独立验证，也不是对查询或点方法整个家族的否证。E6/E7 已有完整训练负结果，不能简单说“只需多训”；E12/E16 的正结果又说明“完全没有表征能力”同样过于绝对。后续研究因此转向更基本的条件：先检验实际预测候选的召回、精度和跨图像泛化，再决定是否接入掩码模型。

本节依据：QUERY_MECHANISM；LOCAL_QUERY_E9；MASKED_QUERY_E10；AUX_QUERY_E11；FREE_MASK_E12；STABLE_MASK_E13；NATIVE_MATCH_E14；POINT_READOUT_E15；GT_POINT_MASK_E16；E17/E18 诊断及 10 月 17 日综合。

5 门控与高分辨率适配：局部正信号为何没有完成主目标

E5 的门控融合曾让 official Dead PQ 平均提高.017897、strict Dead PQ 提高.014202，却没有稳定改善内部 Dead 的几何匹配：平均变化 $-.003374$，95% 区间 $[-.014273, +.007486]$。匹配对象的构成和分型质量发生了变化，不能把 PQ 上涨全部归为缺类规则的漏洞，也不能由此宣称找回了漏检。由于事先选定的主目标未通过，这个配方没有继续扩量。

E19 在 CellViT-UNI 最细的解码 skip 上加入零初始化的 CNN 残差分支。四次完整训练之后，内部 Dead 匹配率平均变化为 $-.008097$，95% 区间 $[-.022566, +.007378]$；official Dead PQ 平均下降.001774。strict Dead PQ 虽提高.008128，主目标仍未通过。

这不是对完整多尺度适配方法的复现，也不能推翻早期放大工作分辨率时观察到的现象；它否定的是这个插入点、结构和预算下的具体配方。

5.1 失败交集揭示了哪些对象值得继续研究

对同一 741 个内部 Dead 对象，四个模型共同未达到 IoU$>.5$ 的有 233 个，占 31.44%；四个模型始终 IoU$<.1$ 的有 149 个，占 20.11%。前者包含粗略定位但形状不合格，不能全部称为完全漏检。

在 233 个持续未匹配对象中，176 个面积小于 100 像素，面积中位数为 64。四模型的匹配并集为 508/741，比最强单模型的 471 个只多 37 个。这一并集利用真值判断，不处理误报和冲突，不能当成可部署集成模型；它只是说明盲目融合这些预测的剩余覆盖空

间有限。

由训练折定义的面积组	训练对象数	开发对象数	四模型共同未匹配
< 67	200	179	123（68.7%）
67–102	196	209	55（26.3%）
103–157	204	189	20（10.6%）
≥ 158	201	164	35（21.3%）

表 4: 固定对象的描述性分组。面积切点来自训练折，未根据开发失败对象重新选切点。

面积和局部对比度的 16 个组合格在训练折都有对象支持，训练/开发边际中位数也接近。这排除了简单的“训练中根本没有这种尺寸或对比度”的解释，却不能排除组织、外观和未知患者因素联合产生的分布差异。小尺寸与失败关联很强，但大对象也有持续失败，因此没有证据把尺寸认定为唯一原因。

组织支持尤其不均衡：这批内部 Dead 中 Lung 占 535/741，Colon 83 个；这与全数据 Dead 标签中 Lung 占 59.5% 是不同分母。七个组织没有 Dead 标签，更不能把没有可评对象写成性能很好。

本节依据：FUSION_GATING_DEV；HIRES_ADAPTER_E19_DEV；E_SERIES_REVIEW 与 RESEARCH_DECISION_CELLVIT_PMNET_2026-10-18；TISSUE_CLASS_AUDIT_2026-10-15。

6 中心点路线：学会训练图像，仍没有学会可靠迁移

6.1 P1-R1 排除了“原来只是没训够”的充分解释

最初的冻结特征点头训练不足时没有产生候选。按提前约定的训练损失停止规则延长后，两个种子分别训练到 55/60 轮，训练内召回达到约 94%–98%，精度约 99.9%。但 fold2 内部 Dead 点召回只有.40756/.39541，低于固定 NP-component 参考的.74899，两个种子的差值区间都低于零。

补足拟合预算没有使它可靠泛化，因此原 P1 到 P2 的前提没有满足。这里的 NP-component 是点候选参考，不是掩码 IoU 或正式 PQ，不能把两者混成模型排名。

6.2 P3 把表征适配和训练增强分别检验

P3 在 fold1 内固定划分 2,134 张拟合图像与 522 张审计图像。审计集只有 11 张内部 Dead 阳性图、145 个内部 Dead，其中 Lung 和 Colon 合计 116 个。所有组都使用原图中心目标和固定解码，比较冻结/适配 UNI 与无/有增强的四种组合，各做两个种子、130 轮训练。

组别	拟合召回	审计召回	审计精度	审计 Dead 召回
F0 冻结、无增强	.999922	.442776	.706998	.351724
F1 冻结、有增强	.538848	.428857	.815171	.396552
T0 适配、无增强	.999833	.509918	.724614	.375862
T1 适配、有增强	.977035	.588939	.692705	.437931

表 5: P3 两个固定种子的算术均值，均为点匹配。

无增强时可以几乎记住拟合图像；有增强时，冻结表征组本身就难以拟合，适配后拟合大幅恢复。T1 相对 F1 的总体审计召回确实提高了约 16 个百分点，但精度下降约 12.25 个百分点。内部 Dead 的提升在两个种子上为 6.90 和 1.38 个百分点，区间都跨零。召回、精度和稳定性不能只选其中一项。

6.3 怎样决定是否继续

原条件要求处理组在两个种子中分别满足：内部 Dead 召回至少.60、较对应对照提高至少.05、原组织分层图像 bootstrap 的区间下界大于零；唯一匹配精度至少.75，且不得比对照低超过.02；总体召回不得低超过.02，并满足样本支持与非退化条件。全部条件同时成立，才有理由讨论下一步。

这个标准并不声称具有理想的统计功效。11 张阳性图的支持本来就很少，多轮选题又反复看同一个审计集。它的作用是约束研究决策，避免把偶然的单种子上涨当成扩量依据。

本节依据：P1R1_RESULT_2026-10-18；PROPOSAL_P3_PHASE_A_2026-10-20；原 admission 实现。

7 P4–P15：从连续对照中归纳失败模式

后续各轮保留固定队列、种子、130 轮、最后检查点及通过条件，每轮只引入一个固定配方，并重新训练本轮对照。表中数字是本轮处理组减去本轮对照；不得把不同轮的处理组直接排名，也不能将种子当成独立患者样本。

实验	固定改变	seed 19	seed 1
P4	稠密前景辅助 BCE	−.027586	+.006897
P5	等容量的原生网格细化	.000000	−.006897
P6	放宽 Gaussian 邻域的负损失抑制	+.020690	+.020690
P7	训练期 RGB 通道扰动	+.034483	−.013793
P8	按图像内对象数归一化损失	−.034483	−.048276
P9	Dead 中心正损失权重 4	+.006897	+.048276
P10	只适配最后 4 层，而非最后 12 层	+.027586	−.013793
P11	重分配精确中心的正 focal 质量	+.041379	.000000
P12	解码 stem 后通道 dropout .2	−.034483	−.027586
P13	25% 训练位置替换为稀有类阳性图	−.137931	−.048276
P14	编码器学习率 10^{-5} 改为 10^{-6}	−.068966	−.089655
P15	训练整数平移 ±16，白色填补	−.193103	−.089655

表 6: 内部 Dead 点召回变化。P4–P15 的原通过条件均未满足。

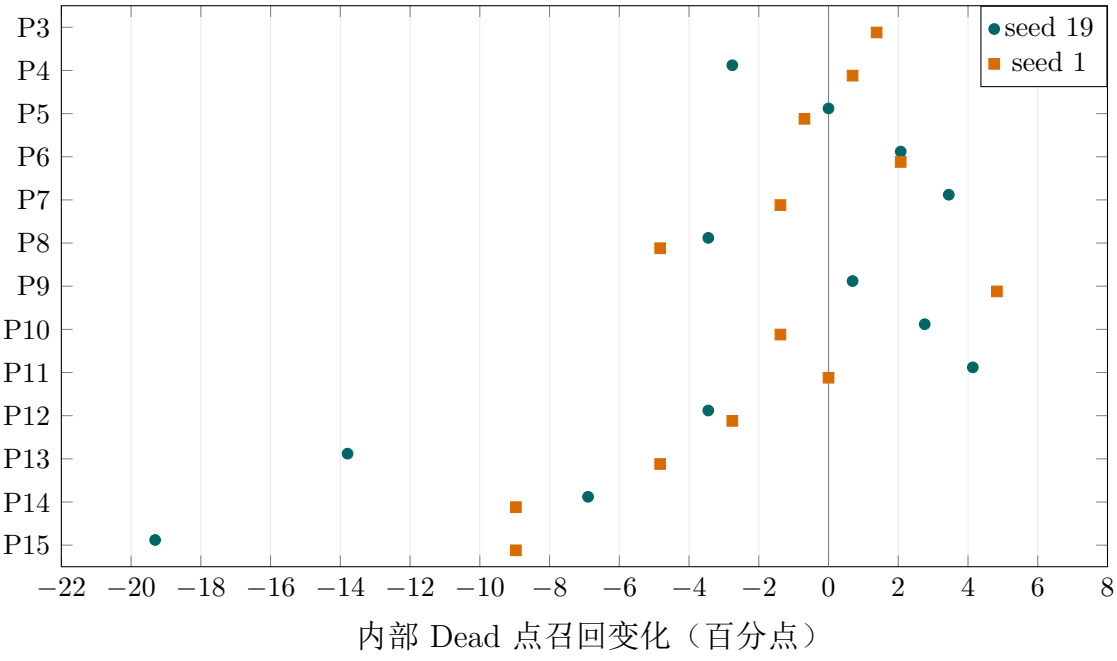


图 2: P3–P15 按时间排列。P3 是 T1−F1，其余是各轮处理 − 新对照。图仅展示点估计，不是显著性或超参数优劣排名。

7.1 负结果至少有三种不同形态

第一种是**拟合很好、审计不够好**。P13 更频繁展示稀有类阳性图后，拟合 Dead 召回为.998476/1，审计却只有.351724/.358621。增加稀有类图像的训练次数并未在这套配方中带来迁移，不能把失败简单归为“样本没看够”。

第二种是**减少适配不等于提高泛化**。只训练更少骨干层、加 dropout、减小骨干学习率都没有通过。P14 的精度提高，却伴随总体召回下降约 8.83/12.01 个百分点。单看精度会误以为模型变可靠，实际上它也少报了很多对象。

第三种是**增强后连拟合任务也明显变难**。P15 在无增强的拟合图像上，总体召回从约.978 降到.470，内部 Dead 从约.952 降到.45。它与“已经拟合但没迁移”的 P13 不同。白边、部分可见核、每轮约 9.94% 中心目标被移出画面，以及位置不变性要求一起变化，不能由这一轮单独归因于位置编码。

P15 的审计精度从.692/.698 提高到.865/.863，但候选数从 10,469/10,428 降到 5,498/5,397，唯一匹配数也从 7,241/7,280 降到 4,758/4,657。两种子内部 Dead 的差值区间均完全低于零。这是覆盖率大幅下降的明确负结果，不能把更高精度写成整体改善。512 候选上限未触发，也不支持“候选被 cap 截断”这一解释。

这些结果已经足以停止扩展上述固定配方。它们没有证明所有增强、重加权、卷积或点检测方法都无效，更没有定位一个适用于全部实验的单一失败原因。

本节依据：P4–P15 各轮结果文档；PROPOSAL_PROGRESS_2026-10-26。本轮对汇总表逐行和当前原始结果文档交叉核对，未重新哈希所有历史大检查点。

8 最新结果与下一轮实验

8.1 P16：完整 Gaussian 回归，目前只报告一个种子

原 focal 损失只把精确中心作为正点，Gaussian 周边值用于减轻附近负损失。P16 保留目标几何，处理组直接最小化 sigmoid 输出与 Gaussian 的平方误差总和，再除以有效批次对象数；系数固定为 1。它同时改变梯度、背景权重和损失尺度，因此不能将结果解释为单独证明了 Gaussian 周边监督或概率校准的作用。

截至本轮首批回收，seed 19 两组已完成 130 轮，SLURM 均为 COMPLETED/0:0。18 个小结果文件的大小和 SHA256 与保存清单一致，401 个封存源码文件逐项核验；拟合/审计图像身份、130 轮日志及逐图聚合结果通过核对。

seed 19	原 focal 对照 C	Gaussian 回归 R
拟合总体召回	.980007	.872135
拟合内部 Dead 召回	.961890	.846037
审计总体召回	.598041	.602531
审计唯一匹配精度	.694079	.701149
审计内部 Dead 召回	.482759	.517241

Dead 提高 +.034483，按原始 1,000 次组织分层图像抽样重算的 95% 区间为

[−.034091, +.131144]。提高对应多匹配 5 个对象；原始单种子条件仍失败：绝对召回不足.60、增益不足.05、区间跨零、精度不足.75。

seed 1 在首批回收时，C/R 分别为第 70/58 轮；09:27 更新至 85/73 轮。双种子汇总待两项结束后完成。seed 19 已未满足原条件，因此 P16 的扩量条件不成立。大型检查点的外部归档另行安排。

8.2 P17：把卷积表示作为独立配方检验

新实验在 P16 的 seed 1 完成之前固定设计，不依赖其尚未完成的结果。对照 C 使用原 UNI 检测器；K 从头训练三阶段卷积金字塔，宽度为 32/64/128，融合多尺度特征后输出原生中心热图。K 不叠加查询、掩码、稀有类重采样或额外监督。

两组保留相同的拟合/审计队列、原 focal 损失、Gaussian 目标、增强、固定解码和通过条件。K 的全部参数学习率为 3×10^{-4}；C 仍使用头部 3×10^{-4}、骨干 10^{-5}。因此这是一套架构、初始化、预训练和优化共同变化的配方比较，不是纯粹“局部性”的因果实验。GroupNorm 还使用空间统计，K 也不是严格有限感受野的局部算子。

这轮检验一个具体问题：从头训练的卷积表示，能否在原预算内改善留出图像上的点检测？结果将决定是否值得设计后续验证。本轮宽度、日程、损失和通过条件均已固定。

实际验证与提交。V100 验证作业 55297045 已于 exp-7-59 完成，状态 COMPLETED/0:0，耗时 6 分 12 秒，291 项节点检查通过。两个种子的原对照初始化及两步完整梯度、参数、AdamW、随机状态与 P3 一致；K 的三个卷积阶段、融合头和输出层均有第二步非零梯度与更新，且排除了纯权重衰减。AMP、最后/最终检查点重载、来源与数据身份、严格 readiness 均通过。25 个小证据文件回收时核验大小及 SHA256。

加入 1.5 倍余量的 130 轮时间外推为 C 6.95 小时、K 4.77 小时；训练峰值显存约 4.07/0.35 GiB。这是外推，不是完工保证。正式数组 **55297061** 于 **09:08:19 EDT** 单次提交，依次 C19/K19/C1/K1，并发上限 2；每项 1 V100、4 CPU、32 GiB、12 小时，gpu-shared / gpu-shared-normal，账户 jhu159，Lustre，禁用自动 requeue。正式预算上限 48 GPU 小时，验证另限 0.5 GPU 小时。训练来源 `5a7e85b`，407 文件源码封存；提交时四项均排队。

9 研究推进与算力迁移

近期正式训练已经迁移到 Expanse。迁移不只是把脚本提交出去：最初的数据副本包含 420 个文件、约 8.10 GB，曾在计算节点核验全部大小和哈希；大文件通过官方 Globus 搬运。后续各轮复用这份数据、UNI 权重和固定环境，分别封存源码、保存配置与提交收据。P3 迁移前因源盘空间保护停止的运行也在保留原检查点后完成，未重新计算已完成的六项。

本轮实时检查中，LM1/LM2 没有本项目训练进程；LM1 根分区无可用空间、项目盘

约余 11 GB，LM2 根分区约余 784 MB、项目盘约余 1.9 GB。因此没有在那里增加训练或回收大型检查点。Expanse 账户可用额度、GPU 分区权限及个人/项目配额已核实。原有无关作业完整保留。

P17 沿用同一持久执行通道和现有 Expanse ControlMaster，未新增认证连接或改变代理。每次提交使用独占创建的标记，记录作业 ID；结果未知时查收据和调度记录，不重复运行提交脚本。验证计算都通过 SLURM，在登录节点只做轻量检查与提交。

10 月 26 日已将 P13–P16 及此前审查修正合并发布到 master，基准提交为 `f67ce20`；当时完整 CPU 回归为 828 项通过、3 项跳过。P17 在独立分支实施，本轮最终完整 CPU 回归为 861 项通过、3 项跳过（19,073 条旧依赖弃用警告），proposal 与节点专项均为 291 项通过。不同计数对应不同版本或检查范围，原回执均保留。

10 当前能下的判断，以及还缺什么

本阶段把“识别不到”拆成了几个可以分别检查的环节。裁切审计与监督修复之间、原始查询掩码与最终实例之间、拟合图像与留出图像之间，都出现了明确落差。后续设计应针对其中一个明确缺口，并用匹配对照检验。

这些负结果也缩小了下一步的解释范围。E19 的持续失败对象与小尺寸有关，但不是唯一尺寸机制；训练折的粗粒度支持存在，不代表联合分布充分覆盖；点检测的高拟合说明能记住图像，不说明它学到了可迁移的核外观。专家评审尚不可用，检测器共识也仍不能替代生物学裁定。

下一步先完成 P16 两个未结束运行的收尾核验，保留原判定。P17 完成后同样先核对 130 轮、来源、输入、配置和保存清单，再按两个种子分别判断。只有真实预测候选在召回与精度上同时成立，才有必要讨论掩码头和联合训练。未达到条件时，保留失败对象和诊断记录，结束该固定配方。

最终研究报告还需要明确保留以下限制：fold2 与 fold1 内部审计集多次复用；图像不等于独立患者；bootstrap 区间条件于固定模型和现有图像，并不覆盖训练种子总体；Dead 标签在组织间分布不均；本阶段没有新的官方三划分测试成绩。阶段报告 5 的人类专家评审义务也没有因技术实验变多而消失。

A 证据索引与复核范围

本报告的历史数字依据 LM1 当前研究文档和各轮收尾记录，属于文档与已保存证据的综合，不声称重新评估了全部旧模型。P16 seed 19 则在本轮回收到逐图记录后重新聚合、重放原 bootstrap，核对了图像队列和 130 轮日志。来源文本摘要哈希及新数字保存在随附 `verified_numbers.json`。

1. 前阶段边界：`docs/report/stage_report_5/README.md`，实验止于 10 月 12 日，报告发布于 10 月 13 日。
2. 可见性：`E4_VISIBILITY_PROBE`、`VISIBILITY_SUPERVISION_DEV`、`VISIBILITY_SUPERVISION_MECHANISM`，均位于 `docs/results/`。
3. 查询路线：`SET_MASK_E6_DEV`、`SET_MASK_E7_DEV`、`QUERY_POINT_CLOSEOUT_E7_E18` 及各训练内诊断。
4. 小对象与组织：`HIRES_ADAPTER_E19_DEV`、`E_SERIES_REVIEW`、`RESEARCH_DECISION_CELLVIT_PMNET`、`TISSUE_CLASS_AUDIT`。
5. 点检测：`P1R1_RESULT`、`PROPOSAL_P3_PHASE_A`、P4–P15 各轮结果、`PROPOSAL_PROGRESS_2026-10-26`。
6. 本轮：P16 小文件回收包、原保存清单、P17 冻结设计、291 项专项日志、真实 V100 验证及正式提交收据。机器路径、PID 与连接证据仅存 ignored ops，不把历史 PID 当作后续操作依据。

本轮提交遵循SDSC Expanse 用户指南并结合实时账户、分区与配额查询。数据、权重、预测和检查点保留原件，外部大产物归档尚未完成。本报告不包含新的文献排名或未经核实的最佳性能主张。