研究范围：2026 年 10 月 13 日至 26 日

怎样让模型
少漏掉细胞核

核实例分割研究 • 阶段报告 6 导读

Xinhao Jin • Biomedical Data Design

病理切片里常能看到一片挨得很近的细胞核。这个项目希望计算机把每个核分别找出来、画出边界，再判断类别。这样才有可能可靠地统计数量，比较不同组织中的核。我们目前做的是公开数据集上的方法研究。

已有模型对某些核找得不错，却容易漏掉较少见的 Dead 类核。这个英文名称来自数据集，包含凋亡、坏死相关核。如果位置都没找到，之后再改类别也补不回来。因此，这两周主要检查“核在哪一步丢了”，并尝试减少漏检。

目前的结论：还没有找到达到预定要求的新方案。不过，实验已找出几个具体问题：裁掉一部分的核更难找；已经画出的轮廓会被后续筛选丢掉；在训练图像上几乎全对，换图后仍会漏很多。

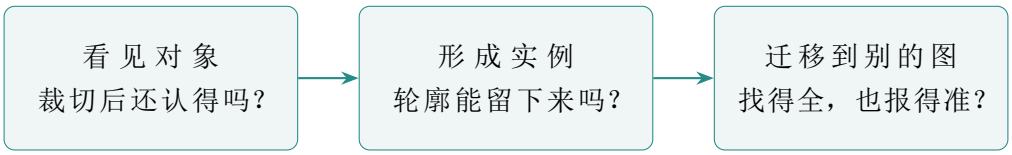


图 1: 本阶段的三条问题线索。流程为概念示意。

最新进度：P16 已全部完成。两次运行分别多找回 5 个、9 个 Dead 核，但仍只找到约一半，误报也偏多。P17 在 10 月 26 日 11:55（美东时间）仍在训练，还不能判断效果。

读图时先记住：**召回率**看真实的核找回多少；**精度**看报出的核有多少能与标注对应；**PQ** 还检查轮廓是否合格。三者不能相互替代。后文用“训练图像”指参与本轮学习的图，用“留出图像”指暂不参与本轮学习、用来比较方案的图。

1 裁掉一角之后，模型还认得吗？

不完整的核更难找，调整训练后是否会改善？

原来完整的核，被画面边缘切掉一块后，留下的面积更小，周围参照也变了。受控裁切实验显示，这样的对象更容易漏掉；很小的残片尤其困难。修正推理模式并按面积分层后，这个现象仍然成立。

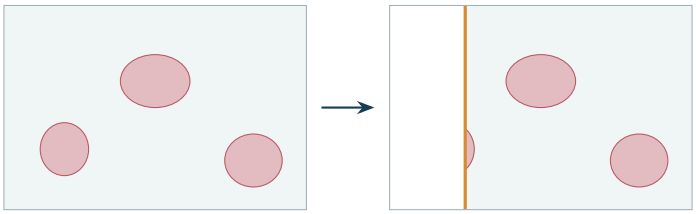


图 2: 裁切如何改变可见面积与上下文：概念示意，椭圆为手绘对象，非真实显微图像、非实验样本。

于是，接下来的干预很自然：训练时多给裁切图，并调整小残片的监督，让模型学会处理不完整对象。四组、两个种子的完整训练给出的答案却更复杂。

相对原始训练的变化	总体分割分数	严格 Dead 分数	读法
裁切增强 A1	−0.0053	+0.0088	Dead 有局部收益，总体质量付出代价
裁切增强 + 调整监督 A2	−0.0063	−0.0009	预期修复没有出现

表 1: fold2 原图开发结果，两个固定种子的均值；这里用的是分割指标。

更直接的检验，来自固定裁切图中 116 个符合条件的 Dead 对象。调整监督相对普通裁切增强，两个种子的漏检改善一负一正；平均为 −0.86 个百分点，95% 区间为 $[-4.09, +1.77]$ 个百分点。

裁切确实增加了困难，但这次调整训练没有减少漏检，因此没有继续扩大这套方案。后续若再研究裁切，需要进一步分清：究竟是核剩下的面积太小，还是失去了周围组织的参照。

数字来源：E4 修正裁切留出；10 月 15 日可见性监督开发评估与机制检验。Dead 沿用数据集类名，涵盖凋亡、坏死相关核。详细计算方法见正式报告。

2 画出来的轮廓，为什么又消失了？

模型在筛选对象和处理重叠时，都可能丢掉核。

一种方案让模型同时准备许多个对象预测，每个预测尝试画出一个核，技术上称为“查询模型”。然后模型要筛掉背景，并决定重叠像素归哪个核。这些步骤会影响最后留下的核数。

完整训练中，这一方案（E7）的总体分割分数约为 0.088，远低于同轮参考模型的 0.473。这个分数综合考虑漏检、误报、轮廓和类别，越高越好。进一步追踪同一批 16 张训练图、331 个目标，能看到对象是怎样逐步丢失的。

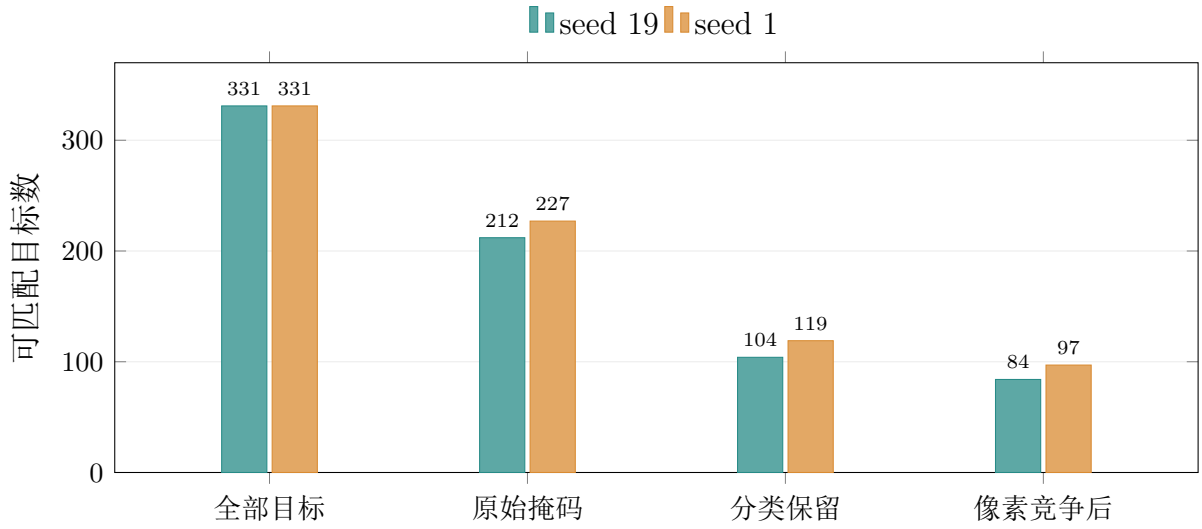


图 3: E7 固定训练批次的实际诊断。原始掩码阶段由真值寻找最佳重叠（IoU> 0.5），展示诊断覆盖空间；后续两阶段在同一批目标上计数，各阶段达标对象并非严格包含关系。

以 seed 19 为例，原始查询掩码能够覆盖 212 个目标；模型分类保留后剩 104 个，处理像素竞争后剩 84 个。另一个种子也有相同走向：227、119、97。

只把筛选标准放宽，不能解决全部问题。原始掩码已覆盖的对象，在后处理中大量流失；与此同时，331 个目标中还有一部分从起点就缺少合格轮廓。需要分别检查**轮廓生成、对象置信度、实例间冲突**，才能知道改动究竟修在哪一处。

给模型正确位置以后，它能画出一部分 Dead 核；但让它自己找位置时，两项小实验分别出现“一个也没报”和“报了很多、正确的很少”。所以后续先单独检查找位置这一步，等位置可靠后再研究轮廓。

数字来源：E6/E7 完整训练、查询机制诊断与 E7–E18 收尾。E18 为最终实例推理指标。详细计算方法见正式报告。

3 练习题几乎全对，换一批图呢？

训练图上接近全对，仍可能只记住了这些图。

中心点方案先给每个核找一个位置，暂时不画轮廓。研究从训练资料中分出 2,134 张用于学习的图、522 张留出来比较方案的图。下图中的“冻结”指保持原图像特征模型不变，“适配”指允许部分参数更新；“增强”指训练时翻转图像、调整颜色等。

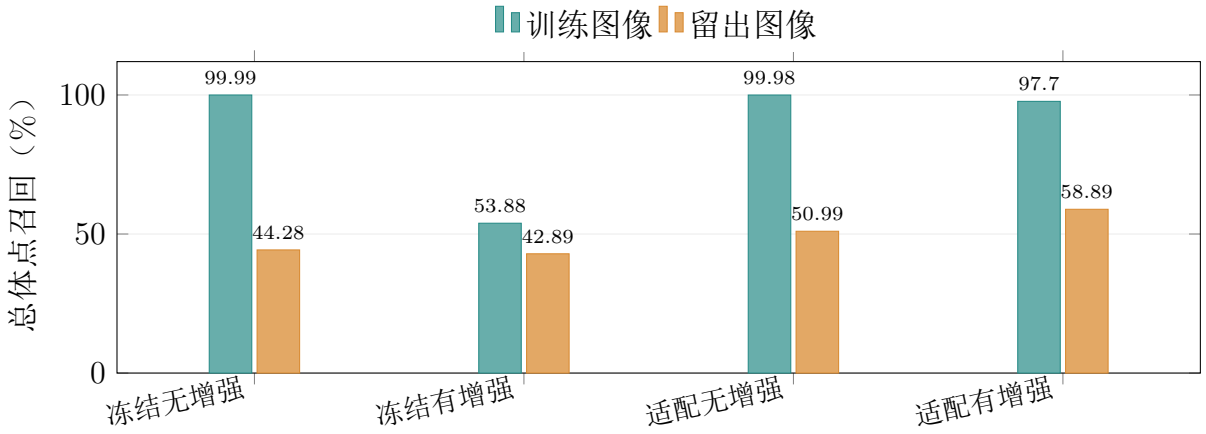


图 4: P3 实际结果，两个固定种子的均值。点匹配采用原生图像 3 像素半径、唯一匹配；图中为所有类别总体召回。

无增强的两组，训练图召回几乎达到 100%，留出召回却只有约 44% 和 51%。加增强后，不更新原图像特征模型的组连训练图也学不好；允许部分参数更新后，训练图上的表现恢复，留出图召回提高到约 59%。

这一步确实有收益。适配加增强相对冻结加增强，留出总体召回提高约 16 个百分点；同时，精度下降约 12.25 个百分点。研究关注的不贴边 Dead 召回，两个种子只提高 6.90 和 1.38 个百分点，区间均跨零。可见，总体核的改善与稀有类别的稳定改善仍是两件事。

固定留出集	图像	含不贴边 Dead 的图	不贴边 Dead 对象
规模	522	11	145

这里的“不贴边”指核没有接触原图边缘，便于排除截断的影响。145 个 Dead 对象中，肺和结肠组织合计占 116 个。这些对象集中在少数组织，结果容易受它们影响。后续多轮都在同一批图上比较新旧办法，所以它能帮助调研问题，还不能充当最终的独立考试。

一个便于理解的类比是：一套练习卷、一套反复查看的诊断卷。诊断卷能帮助发现问题；真正的最终考试仍需另外安排。

数字来源：P3 完整结果。详细计算方法见正式报告。

4 少报一些，精度就可能变高

一张更干净的结果图，也可能漏得更多。

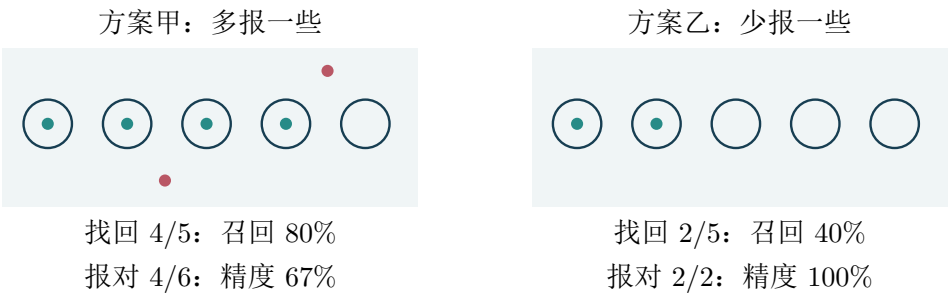


图 5: 概念示意，数值为说明指标而设，非实验结果。圆圈代表真值对象，绿点为匹配预测，红点为误报。少报提高精度时，也可能损失覆盖。

P15 的平移增强就出现了这种实际变化。训练时随机平移图像、用白色补边，原本是希望模型减少对固定位置的依赖。结果它在训练图像上也明显学不好：总体召回由约 98% 降到 47%。

P15，seed 19 留出结果	本轮对照	平移增强
候选数	10,469	5,498
唯一匹配数	7,241	4,758
精度	约 69.2%	约 86.5%

表 2: 实际点检测结果。候选减少，匹配成功的对象也随之减少；另一种子方向一致。

所以，这轮精度上涨的解释是“报得更少、更保守”，同时付出了大量漏检的代价。平移还改变了填边、可见核和每轮保留的中心目标，后续若研究具体机制，需要把这些因素拆开。

另一次实验让模型更频繁地看到含稀有类的图。训练图上的 Dead 几乎全部找到，留出图却只找到约 35%–36%，说明重复看这些图还不够。少更新一些参数、训练时随机停用部分特征、减慢原图像模型的学习速度，也没有同时改善漏检和误报。这些后续方案都没有达到两次运行分别通过的要求。

因此，每次都要一起检查：训练图是否学会了、留出图漏掉多少、又报错多少。只看其中一个上涨的指标，很容易把“少报了很多”误当成进步。

数字来源：P4–P15 各轮结果；各轮比较均采用本轮重新训练的对照。详细计算方法见正式报告。

5 小核最难，大核也有盲区

最小的核最难处理，但大小并不能解释全部失败。

另一个方案（E19）给原模型加了一条补充细节的卷积支路，希望减少小核漏检。两组各做两次完整训练后，不贴边 Dead 的合格匹配率平均反而低了约 0.81 个百分点，抽样区间跨过零，没有显示出预期改善。

我们还检查了四个模型都处理不好的核。741 个不贴边 Dead 中，233 个在四个模型里都没有得到合格轮廓（与标注的重叠比例 IoU 未超过 0.5）；其中 176 个面积小于 100 原生像素。按训练折预先确定的面积组，差异很明显。

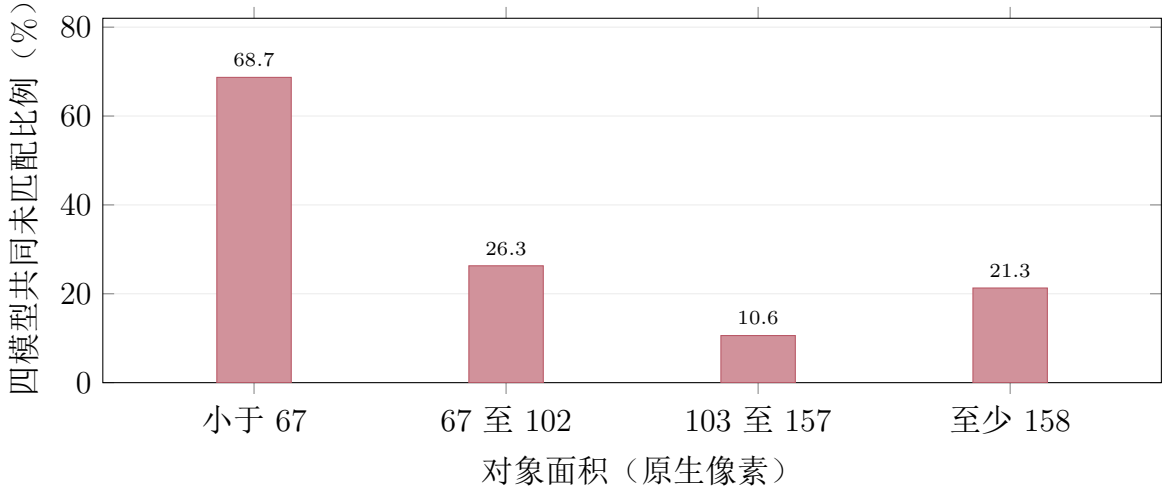


图 6: E19 实际对象检查。各组开发对象数依次为 179、209、189、164；共同未匹配数依次为 123、55、20、35。未匹配包含已有局部重叠但轮廓不合格的对象。

最小组约七成持续未匹配，中间两组明显较低，最大组又回升到约两成。读这张图时，既能看到小核的困难，也能看到“尺寸”尚未解释掉的部分。

用于学习的图像中，四个面积组分别有 200、196、204、201 个对象；按面积和明暗对比度粗分出的 16 组中，也都能找到训练对象。因此，仅凭尺寸相似，还不能判断增加这些样本是否有用。相似面积的核，仍可能来自不同组织、有不同染色与周围结构。

这批 741 个不贴边 Dead 中，肺组织占 535 个，结肠占 83 个。这样的分布意味着：后续复核图像时，需要一起记录核的大小、组织、外观，以及具体错在哪里。四个模型都失败，可以帮助筛选值得复核的对象；生物学判断仍需要专家参与。

数字来源：E19 高分辨率适配与固定对象交集检查；分组切点来自训练折。详细计算方法见正式报告。

6 最新结果：多找回几个核，为什么还不够？

P16 已完成；P17 仍在训练。

P16 改变了教模型找中心点的方式。原先主要强调精确中心，新方案要求它学习中心附近由高到低的一小片平滑区域。两种随机初始化各做新旧两组，共四次训练，现已全部完成 130 轮。种子 19 和 1 是控制随机过程的编号。

随机种子	训练办法	找回 Dead 数 / 145	报出对象的精度
19	原办法	70（48.28%）	69.41%
19	新办法	75（51.72%）	70.11%
1	原办法	63（43.45%）	69.51%
1	新办法	72（49.66%）	70.50%

表 3: P16 实际留出图结果。找回 Dead 数检查不贴边 Dead 的中心；精度检查报出的所有类别中心。

新办法分别多找回了 5 个、9 个，确实有局部改善。第二次的增益抽样区间也完全高于零。不过，两次都只找回约一半 Dead，报出的对象约七成能与标注对应。事先要求是：**每次 Dead 至少找回六成，精度至少七成五**，还需满足增益和其他质量要求。P16 没有达到，所以这个固定方案结束，不继续扩大。

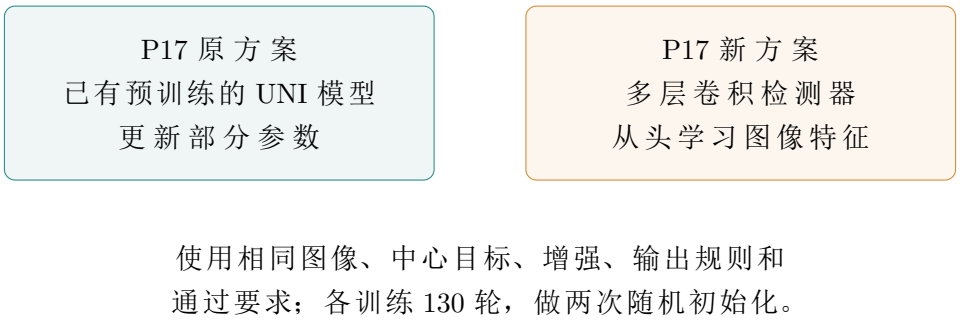


图 7: P17 设计示意。两套方案的结构、预训练和学习速度都不同，比较的是整套办法。

P17 检查另一件事：不用原来的预训练模型，改为从头学习多层卷积特征，能否在换图后更可靠地找到核？截至 **10 月 26 日 11:55（美东时间）**，第一组原方案 / 新方案分别到第 **58 / 81** 轮，第二组还在排队。**目前没有完整结果，不能判断哪套更好。**

下一步等 P17 全部完成，核对训练和评估记录，再看漏检、误报是否同时改善。只有位置找得可靠，才值得接着研究如何画轮廓。

这份报告能说明到哪里？本阶段没有新增官方三划分测试成绩。中心点匹配与轮廓分割是两种检查，不能直接比较数值。留出图已多次用于开发，其中含不贴边 Dead 的只有 11 张，图像也不一定来自不同患者。抽样区间反映现有图像下的波动，不能保证新患者上的表现。图中的手绘核和精度例子为概念示意，实验数字另有明确标注。