研究范围：2026 年 10 月 13 日至 26 日

找到一个核，找全一张图

核实例分割研究 • 阶段报告 6 导读

Xinhao Jin • Biomedical Data Design

我们希望模型交出的，是一张图里完整的一组细胞核：每个核各有轮廓，类别也有依据。上一阶段重点检查“已经找到，为什么分错类”；这两周把目光往前移，追问模型到底在哪一步丢掉了对象。

几条路线给出了相似的提醒：画出一些像样的轮廓，与把它们保留成完整结果，中间还有距离；训练图上找得很全，换一批图也可能漏掉大半。本阶段的收获，是把这些距离量了出来，让下一轮有更具体的问题可问。

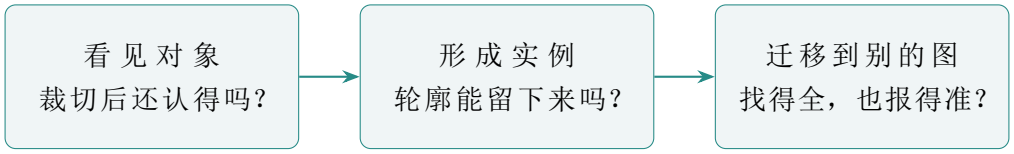


图 1: 本阶段的三条问题线索。流程为概念示意。

这份导读的时间停在这里：2026 年 10 月 26 日 09:27（EDT，美东夏令时）。P16 已取得 seed 19 的完整结果，seed 1 对照 / 处理组已到第 85 / 73 轮；P17 已于 09:08:19 提交，四项任务仍排队。本文保留这份静态记录。

阅读时只需先记住三个词。**召回**问“真有的核找回多少”；**精度**问“报出来的核有多少是真的”；**PQ** 还要检查实例轮廓与类别。三者各自回答不同问题。后文的图会分别标明口径。

目前，已有完整结果的配方都未满足预设的全部通过条件。P16 的局部上涨值得记录，P17 则刚开始检验另一种表示配方。下面按问题读，比按实验编号逐项读更容易看清这段研究。

1 裁掉一角之后，模型还认得吗？

发现脆弱点，是修复工作的起点。

原来完整的核，被画面边缘切掉一块后，留下的面积更小，周围参照也变了。受控裁切实验显示，这样的对象更容易漏掉；很小的残片尤其困难。修正推理模式并按面积分层后，这个现象仍然成立。

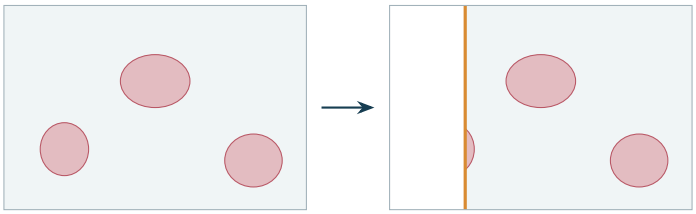


图 2: 裁切如何改变可见面积与上下文：概念示意，椭圆为手绘对象，非真实显微图像、非实验样本。

于是，接下来的干预很自然：训练时多给裁切图，并调整小残片的监督，让模型学会处理不完整对象。四组、两个种子的完整训练给出的答案却更复杂。

相对原始训练的变化	mPQ	strict Dead PQ	读法
裁切增强 A1	−0.0053	+0.0088	Dead 有局部收益，总体质量付出代价
裁切增强＋选择性监督 A2	−0.0063	−0.0009	预期修复没有出现

表 1: fold2 原图开发结果，两个固定种子的均值；这里用的是分割指标。

更直接的检验，来自固定裁切图中 116 个符合条件的 Dead 对象。选择性监督相对普通裁切增强，两个种子的漏检改善一负一正；平均为 −0.86 个百分点，95% 区间为 $[-4.09, +1.77]$ 个百分点。

这组证据把两个问题分开了。**“裁切会增加困难”有观察支持；“这套监督可以修复困难”需要干预结果支持。**后者没有过关，因此这条具体配方停止扩量。保留下来的线索，是可见面积、边界和上下文值得继续细分研究。

数字依据：E4 修正裁切审计；10 月 15 日可见性监督开发评估与机制检验。Dead 沿用数据集类名，涵盖凋亡、坏死相关核。；详细口径见正式报告。

2 画出来的轮廓，为什么又消失了？

查询模型的损失，发生在不止一个环节。

查询模型让一组查询各自尝试负责一个对象。最终交卷前，它还要判断哪些查询可信，并处理轮廓之间的像素争夺。这些步骤共同决定图里最后剩下多少个核。

完整训练中，E7 查询模型的 mPQ 约为 0.088，同轮密集基线约为 0.473。进一步追踪同一批 16 张训练图、331 个目标，能看到对象是怎样逐步丢失的。

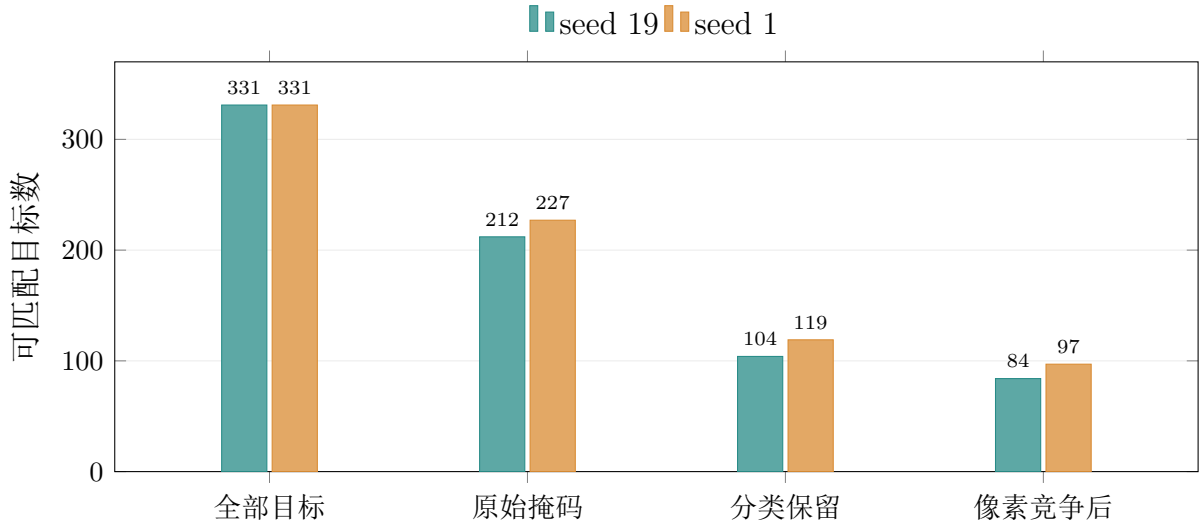


图 3: E7 固定训练批次的实际诊断。原始掩码阶段由真值寻找最佳重叠（IoU> 0.5），展示诊断覆盖空间；后续两阶段在同一批目标上计数，各阶段达标对象并非严格包含关系。

以 seed 19 为例，原始查询掩码能够覆盖 212 个目标；模型分类保留后剩 104 个，处理像素竞争后剩 84 个。另一个种子也有相同走向：227、119、97。

这解释了为什么“把置信度阈值降一点”很难独自解决问题。原始掩码已覆盖的对象，在后处理中大量流失；与此同时，331 个目标中还有一部分从起点就缺少合格轮廓。需要分别检查**轮廓生成、对象置信度、实例间冲突**，才能知道改动究竟修在哪一处。

后续真值辅助的小实验，还表明给定正确位置或对应关系时，网络能够拟合一部分 Dead 核。真正自己预测候选时，E17 没有候选，E18 的最终实例审计精度仅约 3.5%–3.7%。因此研究转向更基础的一关：先让实际预测出来的候选足够可靠，再考虑接上轮廓生成。

数字依据：E6/E7 完整训练、查询机制诊断与 E7–E18 收尾。E18 为最终实例推理指标。；详细口径见正式报告。

3 练习题几乎全对，换一批图呢？

高拟合说明模型记得住，迁移还要另看。

中心点路线先给每个核找一个位置，再考虑如何画轮廓。后续 P3 起，研究在训练折内部固定分出 2,134 张拟合图像和 522 张审计图像。前者参与本轮参数学习，后者用于比较同轮配方。

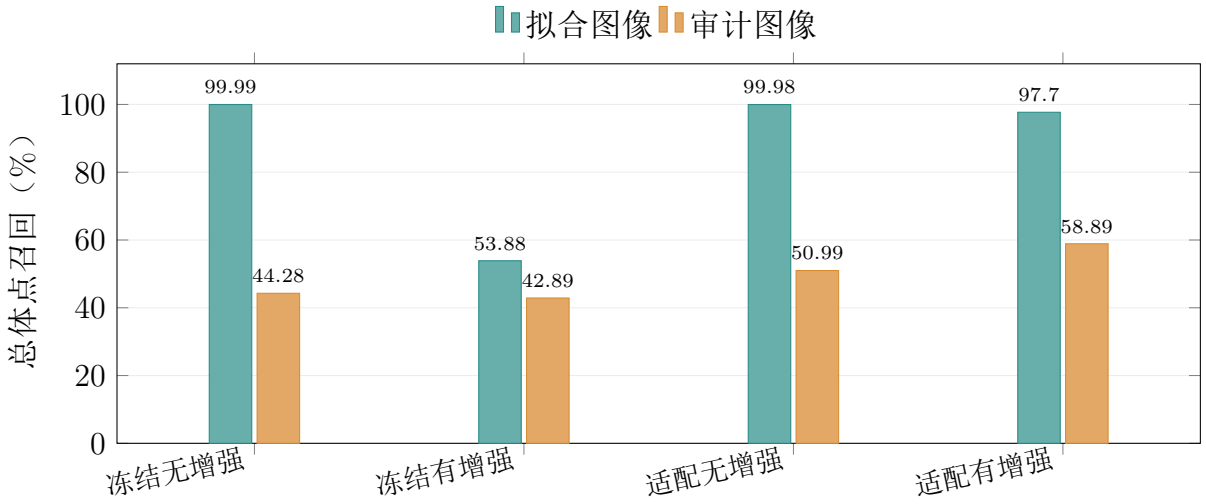


图 4: P3 实际结果，两个固定种子的均值。点匹配采用原生图像 3 像素半径、唯一匹配；图中为所有类别总体召回。

无增强的两组，拟合召回几乎达到 100%，审计召回却只有约 44% 和 51%。加增强后，冻结表征本身难以拟合；允许 UNI 适配，拟合能力大幅恢复，审计总体召回也提高到约 59%。

这一步确实有收益。适配加增强相对冻结加增强，审计总体召回提高约 16 个百分点；同时，精度下降约 12.25 个百分点。研究关注的内部 Dead 召回，两个种子只提高 6.90 和 1.38 个百分点，区间均跨零。可见，总体核的改善与稀有类别的稳定改善仍是两件事。

固定审计集	图像	内部 Dead 阳性图	内部 Dead 对象
规模	522	11	145

145 个 Dead 对象中，Lung 与 Colon 合计 116 个。这批图适合控制变量，支持却很集中。后续每轮都用它比较处理和对照，因而每次“换一套训练办法”并没有同时得到一份新的独立验证。

一个便于理解的类比是：一套练习卷、一套反复查看的诊断卷。诊断卷能帮助发现问题；真正的最终考试仍需另外安排。

数字依据：P3 Phase A；早期 P1-R1 延长拟合后，fold2 内部 Dead 点召回仍约 40%。；详细口径见正式报告。

4 少报一些，精度就可能变高

一张更干净的结果图，也可能漏得更多。

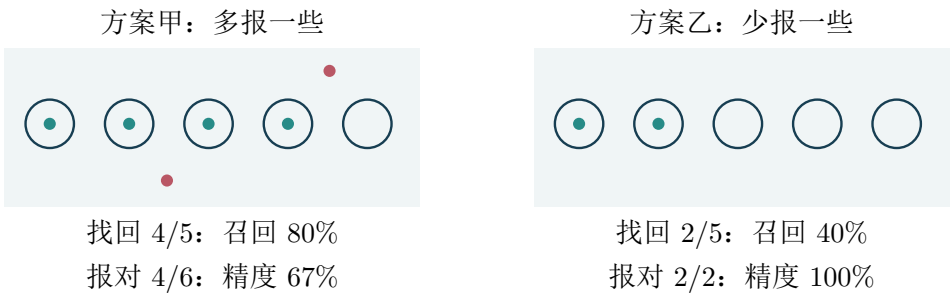


图 5: 概念示意，数值为说明指标而设，非实验结果。圆圈代表真值对象，绿点为匹配预测，红点为误报。少报提高精度时，也可能损失覆盖。

P15 的平移增强就出现了这种实际变化。训练时随机平移图像、用白色补边，原本是希望模型减少对固定位置的依赖。结果它在拟合图像上也明显学不好：总体召回由约 98% 降到 47%。

P15，seed 19 审计结果	本轮对照	平移增强
候选数	10,469	5,498
唯一匹配数	7,241	4,758
精度	约 69.2%	约 86.5%

表 2: 实际点检测结果。候选减少，匹配成功的对象也随之减少；另一种子方向一致。

所以，这轮精度上涨的解释是“报得更少、更保守”，同时付出了大量漏检的代价。平移还改变了填边、可见核和每轮保留的中心目标，后续若研究具体机制，需要把这些因素拆开。

连续试验也呈现了另外两类失败。P13 让模型更频繁地看到稀有类阳性图，拟合 Dead 召回几乎 100%，审计却只有约 35%–36%；它属于“记住了，但迁移不足”。减少适配层、加 dropout、降低骨干学习率，则没有同时改善覆盖和精度。更细网格、颜色扰动、损失重加权等 P4–P15 固定配方，也都未满足双种子通过条件。

这给下一轮一个实用判断顺序：先看模型是否学得动，再看审计召回，最后同时检查误报。只有两个方向都站得住，候选才能成为后续分割的可靠起点。

数字依据：P4–P15 各轮结果；各轮比较均采用本轮重新训练的对照。；详细口径见正式报告。

5 小核最难，大核也有盲区

尺寸提供了一条线索，组织与外观仍在其中。

E19 在高分辨率解码分支加入卷积残差适配器，希望补充细节。双种子完整训练后，内部 Dead 匹配率平均变化约为 −0.81 个百分点，区间跨零。这套适配器没有完成预设的主要目标。

更值得细看的，是四个模型反复失败的对象。741 个内部 Dead 中，233 个在四模型里都未达到 IoU> 0.5；其中 176 个面积小于 100 原生像素。按训练折预先确定的面积组，差异很明显。

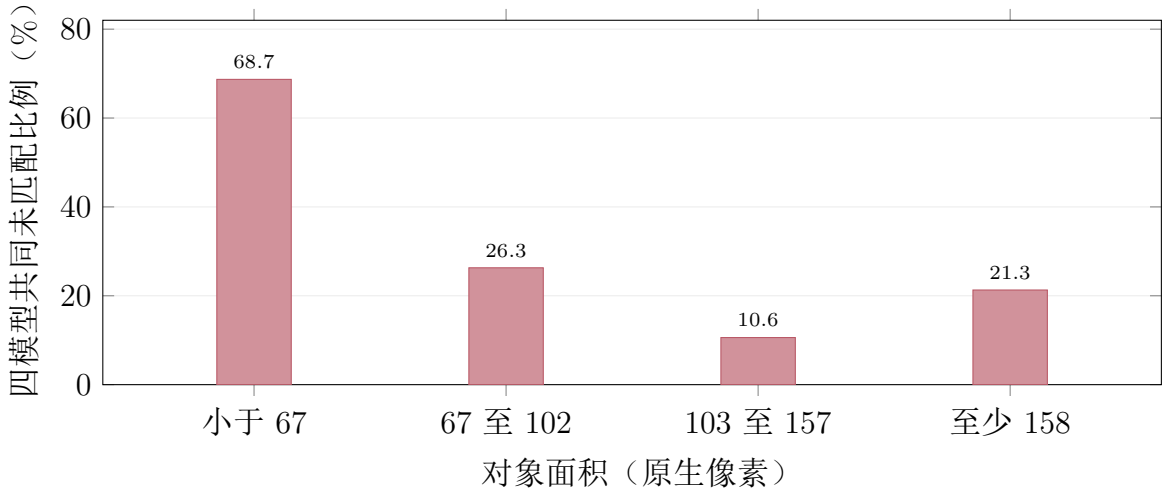


图 6: E19 实际对象审计。各组开发对象数依次为 179、209、189、164；共同未匹配数依次为 123、55、20、35。未匹配包含已有局部重叠但轮廓不合格的对象。

最小组约七成持续未匹配，中间两组明显较低，最大组又回升到约两成。读这张图时，既能看到小核的困难，也能看到“尺寸”尚未解释掉的部分。

训练折中，四个面积组分别有 200、196、204、201 个对象；面积与局部对比度组成的 16 个粗分格也都有训练支持。因此，简单增加同尺寸样本未必就能补上缺口。相似面积的核，仍可能来自不同组织、有不同染色与周围结构。

这批 741 个内部 Dead 中，Lung 占 535 个，Colon 占 83 个。这样的组织集中度提醒我们：接下来真正有价值的图像复核，应把大小、组织、外观与失败类型放在一起看。四个模型都失败，可以帮助筛选值得复核的对象；生物学判断仍需要专家参与。

数字依据：E19 高分辨率适配与固定对象交集审计；分组切点来自训练折。；详细口径见正式报告。

6 最新一轮：多找回五个，下一问是什么？

P16 记录局部变化，P17 检验另一套表示。

P16 改变中心热图的学习方式：原损失把精确中心当正点，Gaussian 周边主要用于减轻附近负损失；新损失直接拟合整张 Gaussian 热图。seed 19 两组都已完成 130 轮，并核验逐图结果、日志与小文件清单。

P16 seed 19	原 focal 对照	Gaussian 回归
审计内部 Dead 匹配数	70/145	75/145
审计内部 Dead 召回	48.28%	51.72%
审计总体召回	59.80%	60.25%
审计精度	69.41%	70.11%

表 3: 实际点检测结果。Dead 增益为 3.45 个百分点，即多匹配 5 个对象。

这个变化的 95% 区间为 $[-3.41, +13.11]$ 个百分点。按原条件，两个种子需分别达到 Dead 召回至少 60%、比对照提高至少 5 个百分点、增益区间下界大于零，同时精度至少 75%，并满足其他质量约束。已完成的 seed 19 尚未满足这些要求；截至 09:27，seed 1 对照 / 处理组分别为第 85 / 73 轮。



图 7: P17 设计示意。比较整套表示配方；初始化、预训练与学习率也有差异。

P17 问得更直接：在同一批图、同一任务和原预算内，换成从头训练的卷积金字塔，是否值得继续？真实 V100 验证已经通过，正式数组 **55297061** 于 10 月 26 日 09:08:19 EDT 单次提交，四项任务、最多同时运行两项。提交时均排队；截至本文静态快照，尚无 P17 效果结论。

下一步先收齐 P16，再核验 P17 的来源、配置、130 轮日志和保存清单，按两个种子分别判断。候选同时做到找得全、报得准，才值得讨论掩码头与后续联合训练。

阅读边界。本阶段没有新的官方三划分测试成绩。分割 PQ、半径 3 像素点匹配和真值辅助诊断各有口径；小规模审计集被多轮复用，图像级区间也不代表患者级保证。历史结果来自已保存证据的综合，本文没有重新评估全部旧模型。所有示意图均已标明；实际数字可在正式报告及 `verified_numbers.json` 中追溯。