找到更多细胞核中心之后

核实例分割研究阶段报告 7

bdd26 研究记录

2026 年 11 月 10 日

摘要

本报告回顾 P17 至 P26 点定位实验。P25 让全部编码器层以分层学习率适配：两个随机种子的总体找点率和精度均明显提高，死亡核（Dead）的命中数也分别净增 7 和 10。但两个种子的死亡核召回与精度都未达到预先规定的最低要求，配对区间下界也未严格大于零。这组设置未通过事先定好的条件，不再继续。P26 检验让训练参数保持在预训练值附近，两种子均未通过原判定门。

目录

1 研究问题：先把核找出来 **2**

2 P17–P24：哪些问题已经试过？ **2**

3 P25：全层分层适配带来了什么？ **3**

4 P26：检验预训练参数锚定 **8**

A 逐轮对照：改变什么，得到什么 **9**

B P25 四跑明细 **9**

C 11 张含死亡核的图及固定样例的对象变化 **10**

D 结果如何核验 **11**

1 研究问题：先把核找出来

项目最终希望在显微图像中找出每个细胞核的轮廓并判断类别。本阶段先研究较小的问题：为每个核预测一个中心点。找到位置是形成实例的基础，但点对了并不意味着轮廓或类别也对了。

标注中的 Dead 指死亡核，包括凋亡或坏死核。这类目标稀少、形态复杂，也是本系列特别关注的漏检对象。模型输出候选点后，以固定规则与标注中心做一对一匹配。**召回率**是标注核中成功找到的比例；**精度**是预测点中成功匹配的比例。多画点可能减少漏检，也可能增加额外点，所以两者需要一起看。

主点头只预测中心位置，不给每个点预测类别。Dead 召回是在匹配后依据真实标注的 Dead 标签统计的子组召回；这里的精度是全部主图预测点的匹配比例，不是 Dead 分类精度。内部核指实例掩码不接触图像边缘；小 Dead 指内部 Dead 中标注掩码面积小于 67 个原始像素的对象。匹配允许原始坐标中不超过 3 像素的欧氏距离，先使一对一匹配数最大，再使距离平方的总和最小。

所有下述数据来自反复用于开发的 PanNuke fold 1。训练图参与模型拟合；审计图用于比较方案。随机种子控制训练中的随机过程，种子 19 和 1 代表两次不同的训练起点。审计集有 522 张图，其中 11 张含 145 个内部 Dead。它们不能视为新的独立患者样本，点匹配也不是实例分割 PQ 或官方三折测试成绩。每个处理臂与同轮新训练的对照配对；不把不同轮次的处理臂当作同一个受控比较。

2 P17–P24：哪些问题已经试过？

P17–P24 分别尝试改变图像信息、训练设置和模型更新方式。这些方案都没有在两个种子上同时满足事先定好的通过条件，但它们揭示的问题各不相同。

从头换一个卷积模型（P17）。该模型的训练图总体召回只有 14.41% 和 11.92%，审计覆盖也低，表现为拟合不足。这次比较同时改变了预训练、结构和优化，反映的是整组设置的结果。

补充原图信息与改变优化（P18–P19）。 P18 保留 UNI 编码器并加入 RGB 残差，Dead 召回与精度仍低于最低要求；P19 将有效批量从 16 增至 32，两个种子的 Dead 命中分别从 66 降到 57、从 63 保持 63。较大批量使每轮更新次数减半，也改变了训练过程。

输入放大与辅助分类（P20–P21）。 P20 将 256 图插值到 512 后重新编码，Dead 命中在两种子分别从 66 到 79、69 到 75，但召回和精度仍低于最低要求，训练成本也更高。插值没有创造原图中不存在的细节。P21 训练时增加五类核中心的辅助目标，推理仍用原中心图；Dead 命中为 64 到 65、70 到 65。结果说明训练图拟合与审计图表现应分开看。

适配深度、参数平均和学习率（P22–P24）。 P22 让全部 24 层参与适配，两个种子分别

净增 18 和 20 个 Dead；对象分析中同时出现新增和丢失。P23 将训练过程中参数做指数移动平均，分别净增 1 和 3 个。P24 把最后 12 层统一学习率从 10^{-5} 提到 3×10^{-5}，精度在两种子均提高，Dead 却分别由 67 到 78、68 到 66。其小 Dead 两种子均由 7/32 到 11/32，但较大目标的变化抵消了部分收益。

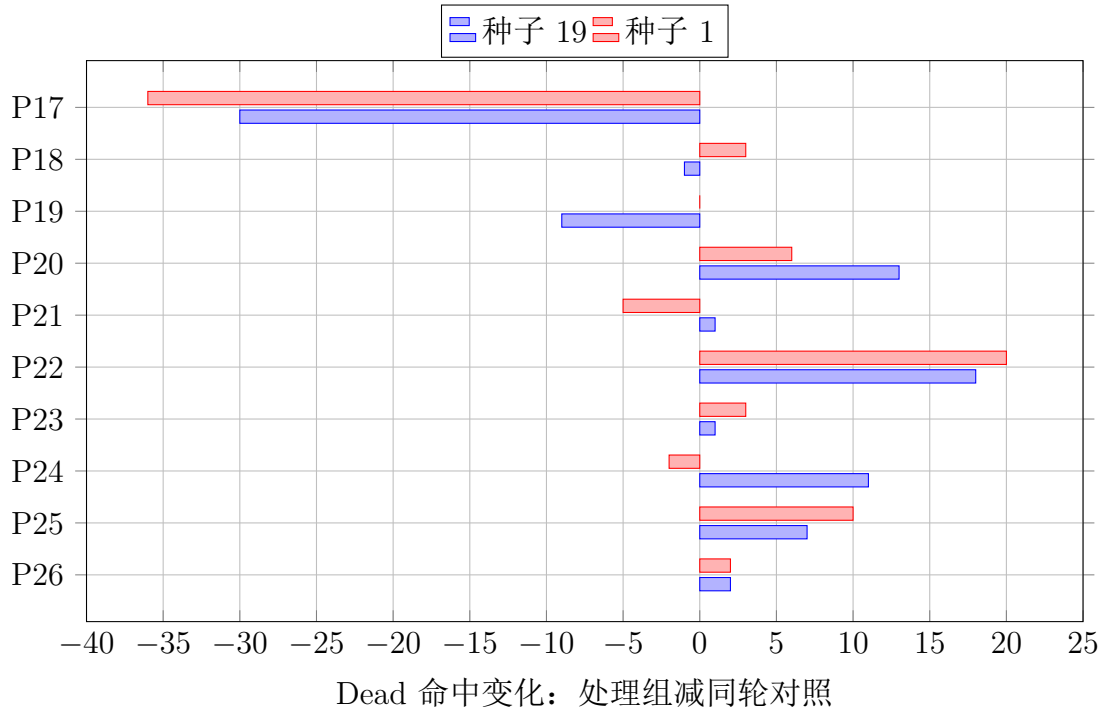


图 1: P17–P26 每轮与自己的对照相比，145 个审计 Dead 的命中数变化。不同轮次并非同一随机对照实验；P22 两种子的增幅最大，但仍未通过完整判定门。

3　P25：全层分层适配带来了什么？

模型中负责提取图像信息的编码器共有 24 层。对照 C 训练最后 12 层，编码器学习率为 10^{-5}；新方案 D 训练全部 24 层，并让前面的层变化更温和。D 的第 b 层初始学习率为 $3 \times 10^{-5} \cdot 0.95^{23-b}$，从底层约 9.22×10^{-6} 逐渐升至顶层 3×10^{-5}。两组使用相同数据、训练轮数、损失、点读取规则和通过条件。D 同时改变可训练深度和各层学习率，因此比较的是两项变化的组合。

四次训练均完成 130 轮和 17,420 次参数更新，使用最后检查点。表中总体召回的分母为 12,250 个标注核；Dead 分母为 145。精度分母是各臂实际输出的候选数。

种子/组	Dead 命中	Dead 召回	总体召回	精度	小 Dead 命中/32
19 C	69	.475862	.589878	.690031	8
19 D	76	.524138	.650367	.744371	10
1 C	65	.448276	.598041	.691850	7
1 D	75	.517241	.639837	.742446	12

表 1: P25 审计结果：四次独立训练，固定解码。

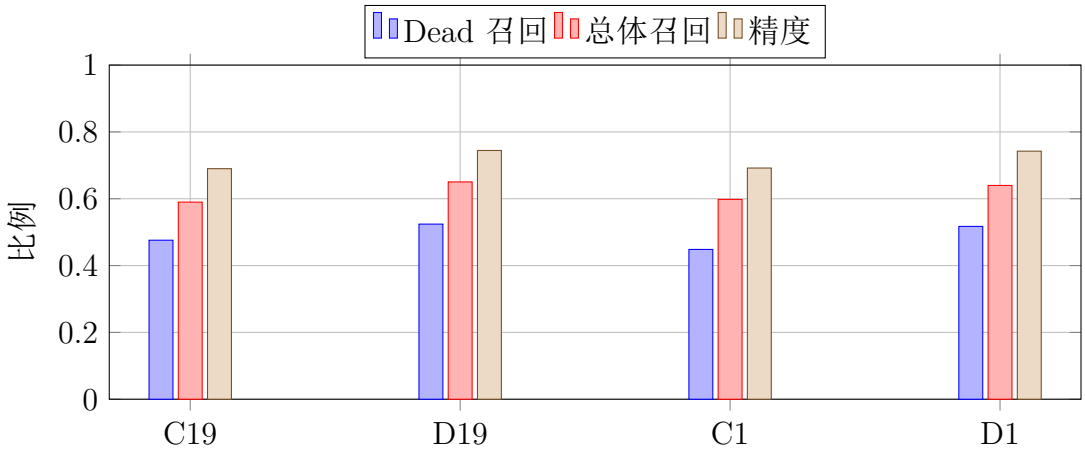


图 2: 三个指标各自回答不同问题。D 在两个种子均提高总体召回和精度，Dead 召回仍低于原定 0.60。

种子 19 的 D 相比 C 多匹配 741 个核（7,226 到 7,967），候选增加 231 个（10,472 到 10,703）；种子 1 多匹配 512 个（7,326 到 7,838），候选反而少 32 个（10,589 到 10,557）。两种子的精度和总体召回都同时提高。

3.1 为什么仍未满足通过条件

事先规定两种子都要满足全部条件：Dead 召回至少 0.60、相比同种子对照增益至少 0.05、原配对 bootstrap 95% 区间下界严格大于零、精度至少 0.75，并满足支持量、相对表现及非退化要求。其他条件合格不能替代其中一项。

配对 bootstrap 区间按组织对含 Dead 的审计图重采样 1,000 次（随机种子 20261018），描述本图集上的增益波动，不是患者层面的独立验证。种子 19 的 Dead 增益为 $7/145 = 0.048276$，区间 $[-0.010417, 0.164835]$；种子 1 为 $10/145 = 0.068966$，区间 $[0, 0.194031]$。两种子的绝对 Dead 召回与精度均未达到最低要求；两个区间下界都不严格大于零，种子 19 的增益也略低于 0.05。种子 1 区间下界恰好为零，不能写成正数。原函数和独立复算一致，整体判定失败；关闭的是这一精确组合方案。

3.2 进步和损失发生在哪里

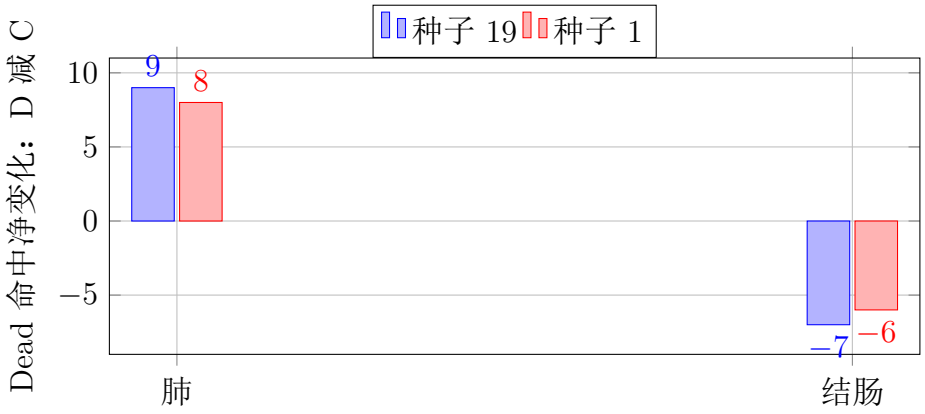


图 3: 按组织汇总的 Dead 命中净变化：肺有 60 个，结肠有 56 个。这是看到总体结果后的分组描述。

肺图中两个种子分别净增 9 和 8 个，结肠图中分别净减 7 和 6 个。对种子 19 而言，肺图的 9 个净增几乎被结肠图的 7 个净减抵消。这些数字是逐图命中数之差：净增 7 不等于恰好 7 个新对象被找回，也不能说明其余对象全部保留。审计中的 145 个 Dead 有 116 个集中在这五张肺和结肠图中，少数图就可能改变总体结论。

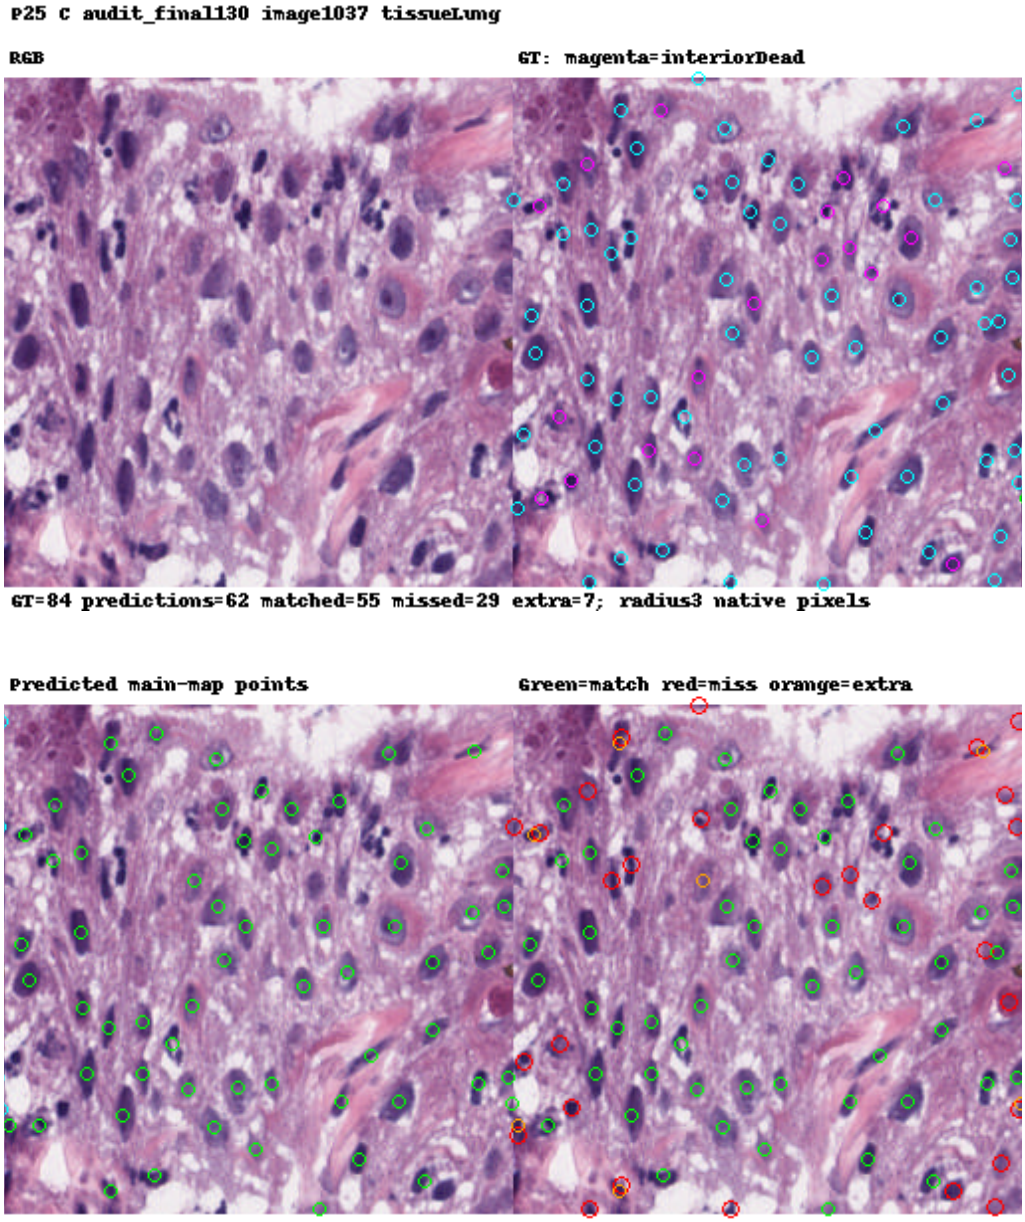


图 4: 种子 19 对照 C：原图、标注、预测和匹配情况。

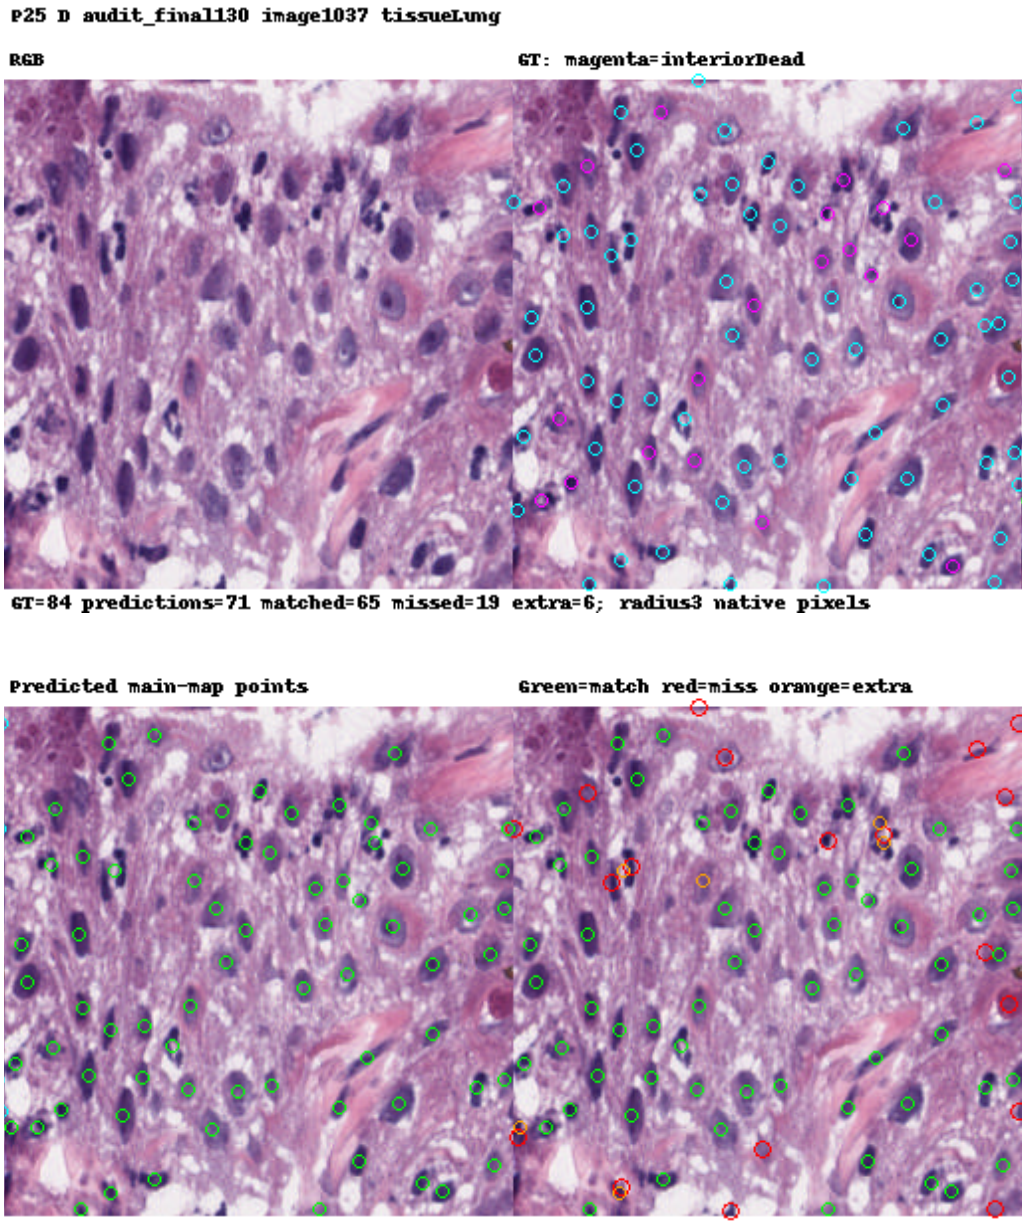


图 5: 预先固定的审计图 1037，种子 19：这里展示 D；两行依次展示原图、标注中心、预测点和匹配结果；标注栏洋红色为内部 Dead、青色为其他标注；匹配栏绿色为匹配、红色为漏检、橙色为额外点。图内汇总统计所有核，正文的 10 到 15 专指死亡核。单张图不代表全体。

3.3 训练图很好，为什么仍需看新图

D 在拟合图的 Dead 均为 649/656，约 98.9%；审计图分别为 76/145 和 75/145，约 52%。模型在训练图上拟合充分，在审计图上的表现则低得多。图像差异、模型提取的信息、训练目标和优化都可能参与其中。

4 P26：检验预训练参数锚定

P26 以 C 为对照，R 只在训练目标中增加编码器参数到预训练初值的 L2SP 锚定项：

$$L_R = L_C + \frac{0.01}{2} \sum_{\theta \in \text{trainable encoder}} (\theta - \theta_0)^2.$$

这里只约束可训练的编码器参数，不约束点检测头；原 AdamW 权重衰减 0.01 保留，每个有效批次计算一次。两组都训练最后 12 层，两个种子各 130 轮，使用最后检查点及原先的通过条件。拟合与审计差距本身并不能说明模型遗忘了预训练知识。L2SP 的原始方法见 Li 等人在 ICML 2018 的论文：`https://proceedings.mlr.press/v80/li18a.html`。

P26 最终 CPU 全回归为 1,096 项通过、3 项跳过；V100 验收作业 55661530 以 COMPLETED/0:0 完成，耗时 689 秒，节点专项 97 项通过。验收核对了双种子对照的梯度、参数、优化器与随机状态，以及新约束的梯度和实际更新、BF16、冻结状态及检查点重载。C/R 各自 130 轮时间的 1.5 倍安全外推为 7.07/7.20 小时，训练峰值显存为 4.09/4.66 GiB。490 份封存源码和 29 个验收小文件通过哈希核验。

P26 四项均完成 130 轮，SLURM 均为 COMPLETED/0:0。种子 19 的 C 和 R 分别命中 67 和 69 个 Dead；种子 1 分别命中 64 和 66 个（分母均为 145）。两种子增益均为 0.013793，配对 95% 区间分别为 $[-0.006173, 0.053793]$ 和 $[-0.071429, 0.061224]$。R 的总体召回为 0.570857/0.569224，低于 C 的 0.583673/0.596245；R 的精度为 0.678537/0.688080，低于 C 的 0.697221/0.692519。两种子均未通过原判定门，独立复算一致。四跑的摘要、完成记录和评估文件均匹配保存清单；大检查点尚未独立重算哈希。

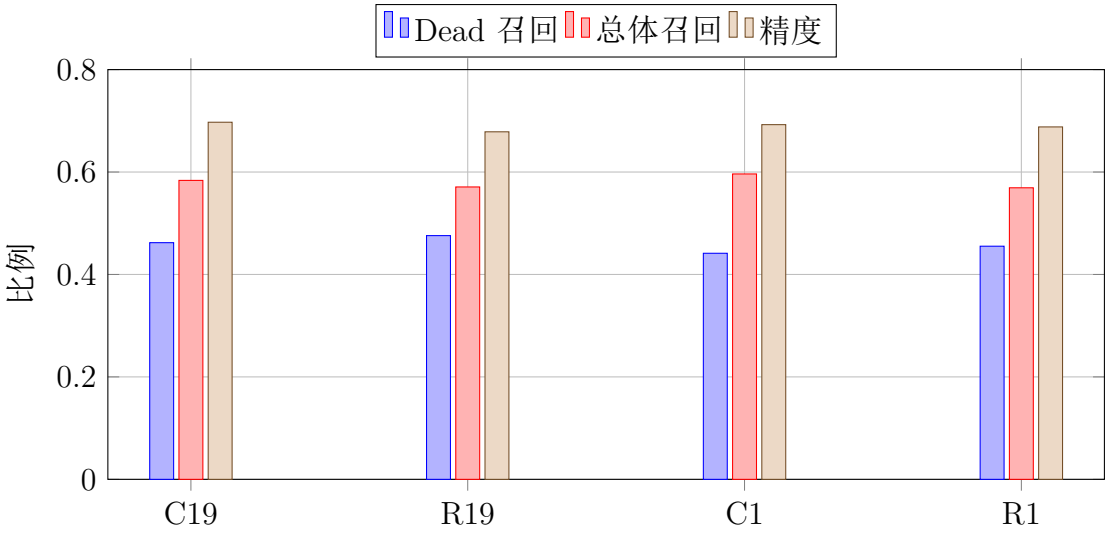


图 6: P26 四跑审计：锚定组每个种子多命中两个 Dead，总体召回和精度下降。

A 逐轮对照：改变什么，得到什么

表中每个单元格先写同轮对照 C，再写处理结果，格式为“Dead 命中数 / 精度”。Dead 分母均为 145。P23 的 E 是同一训练轨迹的指数移动平均权重，不是另一次独立训练。全部处理均未通过原双种子完整条件，右栏列出最直接的失败原因；详细逐项规则见正文。

轮次	改动	种子 19 C → 处理	种子 1 C → 处理	未通过的主要条件
P17	从头训练卷积模型	60/.684 → 30/.952	67/.695 → 31/.949	覆盖严重不足
P18	增加 RGB 残差	71/.691 → 70/.694	64/.696 → 67/.696	死亡核召回、精度、增益及区间
P19	有效批量 16 到 32	66/.695 → 57/.689	63/.694 → 63/.695	死亡核召回、精度、增益及区间
P20	输入从 256 插值至 512	66/.691 → 79/.712	69/.696 → 75/.724	死亡核召回及精度最低要求
P21	五类中心辅助监督	64/.692 → 65/.699	70/.696 → 65/.697	死亡核召回、精度、增益及区间
P22	全 24 层同率适配	67/.692 → 85/.728	62/.699 → 82/.734	死亡核召回及精度最低要求
P23	指数移动平均	69/.692 → 70/.694	60/.694 → 63/.691	Dead、增益及精度不足
P24	后 12 层学习率提高	67/.688 → 78/.732	68/.694 → 66/.731	死亡核召回及精度最低要求
P25	全层分层学习率	69/.690 → 76/.744	65/.692 → 75/.742	死亡核召回、精度及区间
P26	预训练参数锚定	67/.697 → 69/.679	64/.693 → 66/.688	死亡核召回、精度、增益和区间

表 2: 各轮保留各自新对照；精度四舍五入到三位小数。

P22 的处理组 Dead 命中 85/82，高于 P25 的 76/75，但这不是同一次试验中的随机配对。P22 各自的对照为 67/62，P25 为 69/65；两个方案的层间学习率、训练轨迹与对照均不同。P22 全层同率，P25 全层分层率，因此较低的 P25 Dead 数不能识别是哪一项改变造成，也不能推断二者排序具有独立确认性。P25 对所有核的匹配改善明显，并不自动意味着它是更好的稀有死亡核方案：总体指标的分母是 12,250 个核，而目标亚组只有 145 个。

B P25 四跑明细

拟合集共 50,968 个核、656 个内部 Dead，其中 168 个小 Dead；审计集共 12,250 个核、145 个内部 Dead，其中 32 个小 Dead。额外点等于候选数减去成功匹配数；训练时间为日志中训练段累计，显存为训练期峰值，不等于整个调度作业时间。

指标	C19	D19	C1	D1
拟合总体召回	.976162	.991701	.980576	.993388
拟合 Dead /656	627	649	629	649
拟合小 Dead /168	148	163	148	162
审计总体召回	.589878	.650367	.598041	.639837
审计 Dead /145	69	76	65	75
审计小 Dead /32	8	10	7	12
审计匹配 /12250	7226	7967	7326	7838
审计候选	10472	10703	10589	10557
审计额外点	3246	2736	3263	2719
训练秒数	14384	20306	14365	20371
峰值显存 GiB	4.047	6.745	4.047	6.745

表 3: 最后检查点的拟合与审计汇总，以及训练日志中的成本。

D 的额外点减少 510 和 544 个，尽管匹配数分别增加 741 和 512。D 的纯训练时间约为 C 的 1.41 和 1.42 倍，峰值显存约多 2.70 GiB。作业级时间包含初始化、评估和保存等开销；不同节点及共享存储也影响时间，不能把差额全部归给模型计算。

C 11 张含死亡核的图及固定样例的对象变化

图像	组织	Dead 数	种子 19 C→D	种子 1 C→D
178	乳腺	1	0→0	0→1
776	结肠	7	4→3	5→3
1025	肺	25	18→19	19→18
1037	肺	20	10→15	10→16
1038	肺	15	9→12	9→12
1482	结肠	49	15→9	14→10
1756	宫颈	15	6→9	5→8
2076	食管	8	6→7	1→6
2482	胃	3	0→0	0→0
2485	胃	1	0→1	1→0
2587	子宫	1	1→1	1→1

表 4: 全部 Dead 阳性审计图；每个数字是该图的命中总数。

依次去掉一张阳性图，种子 19 的 D 减 C Dead 召回变化范围为 +.016 至 +.135417，种子 1 为 +.032 至 +.145833。这是事后单图影响分析，不是新的置信区间，也不改变原门；全部 11 图原差仍为 +.048276 和 +.068966。

原 bootstrap 在含内部 Dead 的图中按组织分别抽图。七个组织中，乳腺、宫颈、食管和子宫各只有一张阳性图，这些单图组织在组内重采样时不会发生变化。区间反映的是现有组织和图像中可重采样部分的变化。

八张预先固定的审计样例覆盖 53/145 个 Dead。按同一图像和标注对象逐个对照：种子 19 为保留 26、新增 11、丢失 6、两边均漏 10；种子 1 为保留 30、新增 8、丢失 4、两边均漏 11。每种子四类相加均为 53，且逐图命中数与原评分断言一致。样例内净增分别 5 和 4，与全部审计图的 7 和 10 不同；样例能解释具体对象的变化，不能代替总体频率。

D 结果如何核验

P25 四个 SLURM 顶层任务均为 COMPLETED/0:0，耗时分别为 4:07:51、5:49:40、4:08:06、5:53:40；每项一张 GPU，相加 19:59:17，即 19.9881 GPU 小时，包含作业级开销。回收的 114 个小文件（其中包括 48 张最终图）按清单核对，封存源码 485 项核验。大检查点核对现存大小与原保存清单，本次未独立回传重算大文件哈希。完整数字与来源映射见随附 `NUMBER_SOURCES.md`。