# 模型找到了更多点，为什么还要继续？

## 阶段报告 7 中文导读

bdd26 研究记录

2026 年 11 月 10 日

## 先看结论

P25 实验有一个清楚的进步：模型在两次独立训练中都找到了更多核，预测点的精度也更高。但对于特别关注的死亡核，145 个中分别只找到 76 个和 75 个；原先的条件包括至少找到 60%，且精度至少 75%。两个种子均未满足完整条件，因此这组设置不再继续。我们保留它提供的线索，再检验一个新的问题。

## 什么叫“找点”？

想象一张有许多细胞核的显微图：研究人员已经给每个核标了中心，模型要在图上画点。一个点只能和一个标注中心配对。**找点率（召回）**看有多少标注核被找到；**精度**看画出的点有多少真正对应一个核。只顾多画点，虽然可能少漏，但也可能在空白处乱点。

Dead 是死亡核，包括凋亡和坏死核。这类核少、外形也可能破碎，比较难找。我们最终还要画出每个核的边界并分类；目前的点结果只是其中一步。

当前模型只画中心点，并不为每个点判断类别。死亡核召回是在匹配后，根据人工标注中的死亡核标签单独计算的；这里的精度则是所有预测点的匹配比例，并非死亡核分类精度。

## 前几轮试出了什么？

从头训练的卷积模型（P17）连训练图也没拟合好。保留原模型加一条 RGB 通路（P18），以及把有效批量加大（P19），也没有达到要求。把图放大后再送进模型（P20）找回了一些死亡核，但仍不够，训练也更贵；给模型增加训练时的类别辅助任务（P21）则没有稳定改善。

让全部 24 层参与训练（P22）在两个种子里都有净增，但仍没有满足通过条件；参数平均（P23，把训练过程中参数做平均）作用很小。只提高最后 12 层的学习率（P24）稳定提高了精度，死亡核的变化却一个种子上升、另一个下降。这些尝试提供了下一步研究的线索。

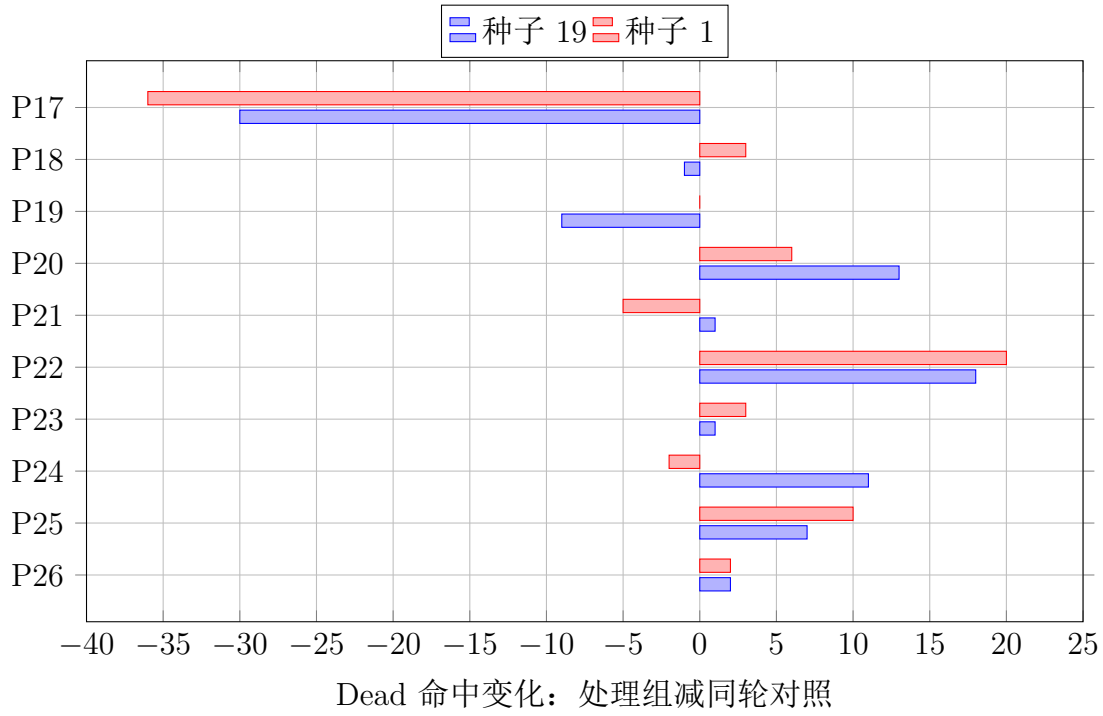



图 1: P17–P26 每轮与自己的对照相比，145 个审计 Dead 的命中数变化。不同轮次并非同一随机对照实验；P22 两种子的增幅最大，但仍未通过完整判定门。

## P25 换了什么？

可以把模型想成 24 层逐步提取图像信息的处理环节。对照 C 只更新后 12 层；新方案 D 更新全部 24 层，同时让前面的层变化更温和、后面的层变化更充分。数据、训练轮数、点的读取规则和通过条件保持一致。

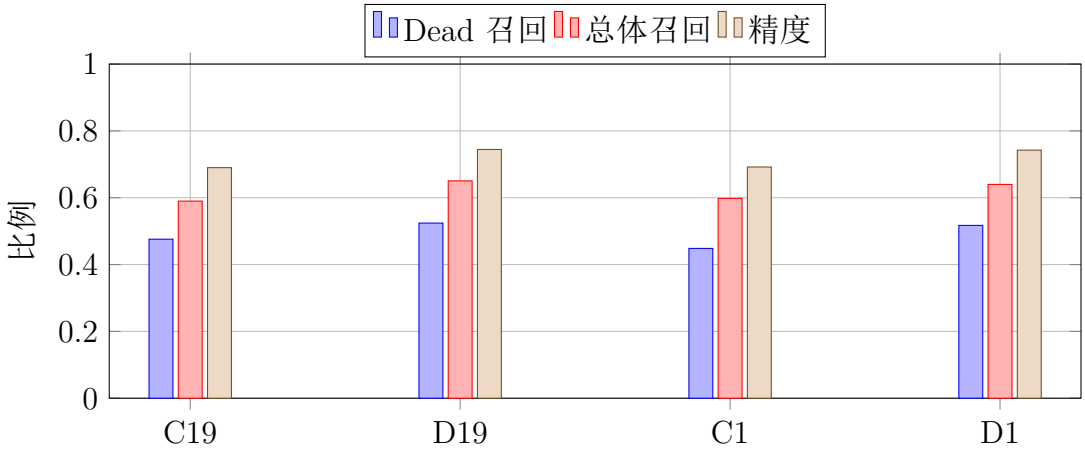



图 2: 四组审计结果。C19 表示种子 19 的对照，D19 表示同一种子的方案 D；种子 1 同理。随机种子对应不同训练起点。

种子 19：对照找到 69/145 个死亡核，D 找到 76/145；种子 1：65/145 到 75/145。与此同时，总体找点率分别提高约 6.0 和 4.2 个百分点，精度提高约 5.4 和 5.1 个百分点。种子 19 多找到 741 个各类核，只多画 231 个点；种子 1 多找到 512 个核，反而少画 32 个点。这是值得保留的改善。

## 为什么还是没通过？

事先写好的规则要求两个种子分别满足一组条件：死亡核召回至少 60%，比同种子对照提高至少 5 个百分点，配对不确定性区间的下界严格大于零，点精度至少 75%，以及其他基本条件。两个种子的 D 死亡核召回约 52%，精度约 74%，都未达到前述绝对要求。

两个种子的死亡核增益约 4.83 和 6.90 个百分点。对应区间分别从负 1.04 到正 16.48 个百分点、从 0 到正 19.40 个百分点。第二个区间的下界是零，不能当成大于零；第一个种子的增益也稍低于 5 个百分点。把两个种子平均起来，无法代替每个种子都满足通过条件。

# 为什么总数会掩盖变化？

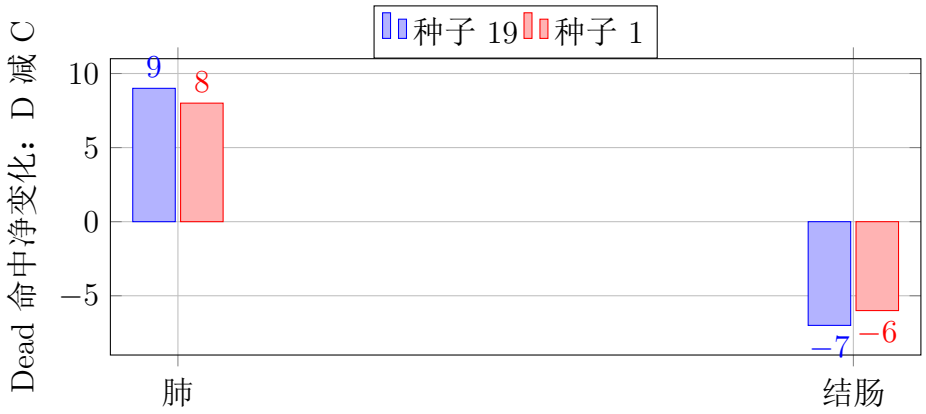



图 3: D 相对 C 的死亡核命中净变化；负数表示新方案命中更少。

种子 19 在肺图中净多找到 9 个，却在结肠图中净少 7 个；种子 1 分别净多 8 个和净少 6 个。就像两门课一门进步、一门退步，总分会把两件事压缩成一个数字。这里比较的是各图的命中净变化，不是完整的逐对象得失清单。

下面是预先选定的一张肺图，种子 19 的对照和新方案都展示出来。每组两行依次展示原图、标注中心、模型预测和匹配情况。标注栏洋红色是内部死亡核，青色是其他标注；匹配栏绿色是匹配，红色是漏检，橙色是额外点。图内数字汇总所有核；死亡核命中从 10 增至 15。另一张图可以出现相反变化，所以它不能代替全部审计图。

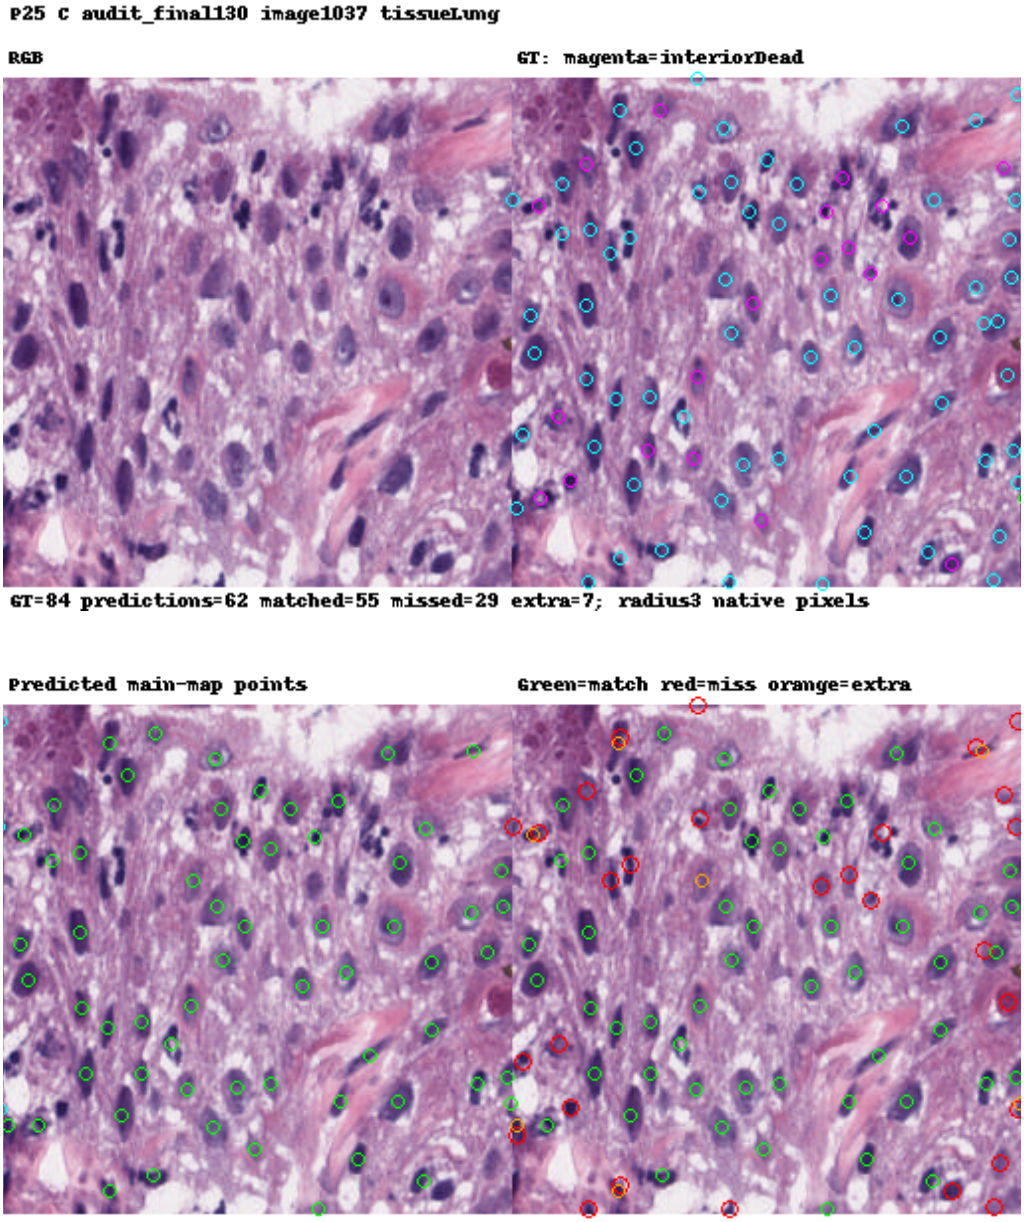



图 4: 种子 19 对照 C：原图、标注、预测和匹配情况。

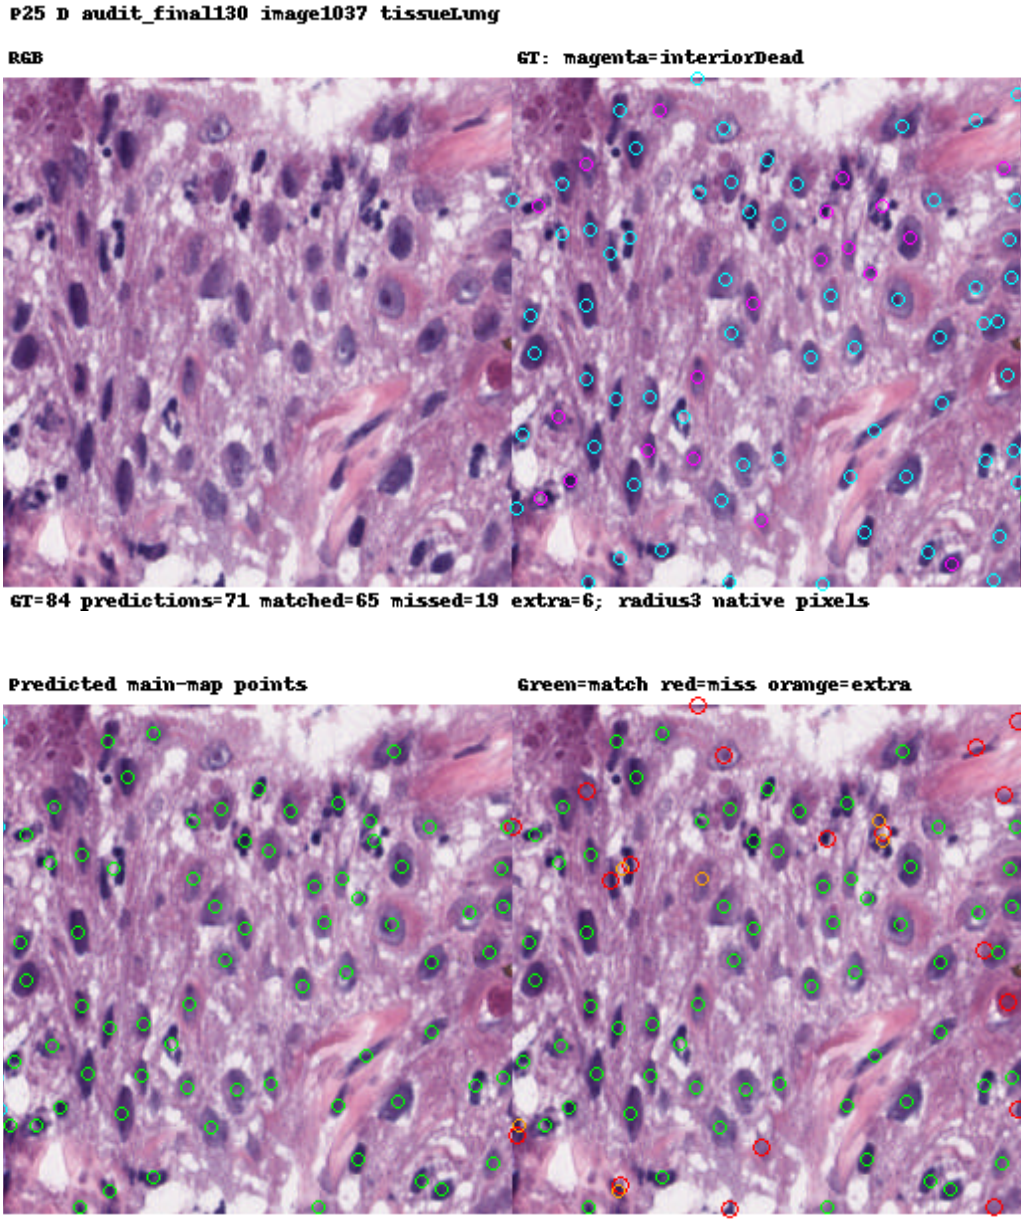



图 5: 固定审计图 1037：这里展示 D。

## 训练图几乎都找到了，为什么新图还是漏？

D 在训练使用的图上，两个种子都找到 649/656 个死亡核，约 99%；审计图则约 52%。好比学生把练习题做得很好，换一套题仍会漏掉不少。这提示我们需要研究从训练图到其他图的迁移，但单靠这个差距还不能断定原因。

## 接下来准备检验什么？

P26 仍从原对照出发，只增加一个约束：训练时让编码器参数不要离预训练时的位置太远。可以把它想成一根有弹性的绳，允许模型学习新任务，也对偏离原起点施加一定拉力。检测头不加这根绳，原有权重衰减保留。

P26 四项均完成 130 轮，SLURM 均为 COMPLETED/0:0。种子 19 的 C 和 R 分别命中 67 和 69 个 Dead；种子 1 分别命中 64 和 66 个（分母均为 145）。两种子增益均为 0.013793，配对 95% 区间分别为 $[-0.006173, 0.053793]$ 和 $[-0.071429, 0.061224]$。R 的总体召回为 0.570857/0.569224，低于 C 的 0.583673/0.596245；R 的精度为 0.678537/0.688080，低于 C 的 0.697221/0.692519。两种子均未通过原判定门，独立复算一致。四跑的摘要、完成记录和评估文件均匹配保存清单；大检查点尚未独立重算哈希。

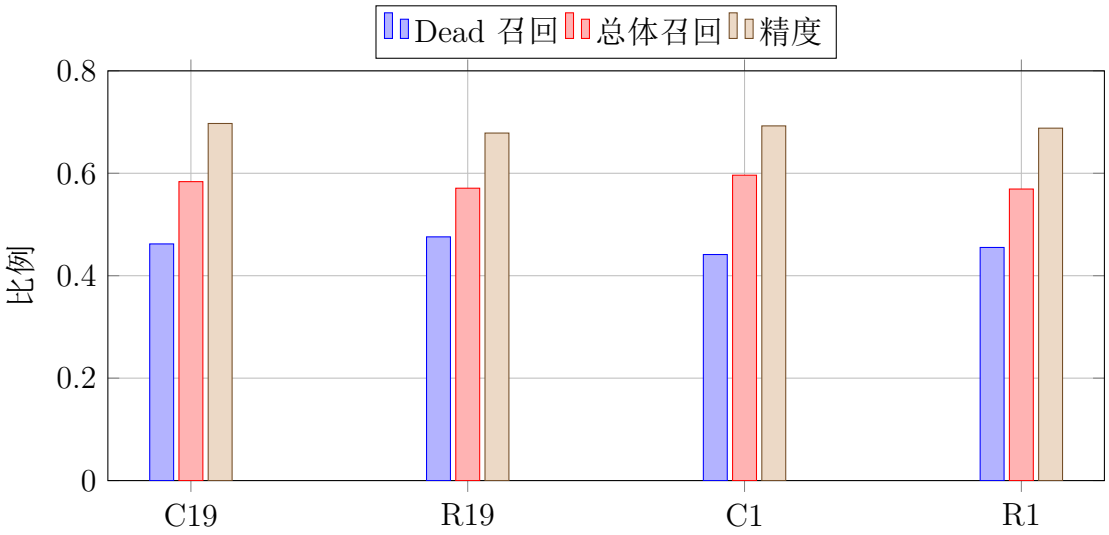



图 6: P26 四跑审计：锚定组每个种子多命中两个 Dead，总体召回和精度下降。

## 这些结果能说明多大范围？

这些实验反复使用同一个 fold 1 开发集；522 张审计图中仅 11 张含有 145 个内部死亡核。因此它们帮助我们比较方案和提出下一步问题，但不能当作独立患者验证、最终轮廓质量 PQ 或官方三折测试成绩。详细中英文报告给出完整判定门、数字来源和计算记录。